

Optimizacijske metode u razvoju i upravljanju sustava

Skripta za učenje

Cjelovita obrada gradiva — od nule do ispita

Skripta je sastavljena **isključivo** iz materijala kolegija: predavanja 01--08 i vježbi 1--5.

Svaka definicija, formula, izvod i postupak rješavanja preuzeti su iz izvornika i raspisani korak po korak. Ništa nije nadopunjeno iz drugih izvora; sva odstupanja od izvornika izričito su označena.

Sveučilište u Zagrebu — Fakultet strojarstva i brodogradnje

Nositelj kolegija: prof. dr. sc. Andrej Jokić

Kako koristiti ovu skriptu

Skripta pretpostavlja **nikakvo** predznanje iz optimizacije. Svaki pojam objašnjen je pri prvom spominjanju: što je, kako se označava i zašto je bitan.

Kako je gradivo posloženo. Poglavlja slijede redoslijed predavanja (01--08). Zадaci s vježbi *nisu* skupljeni na kraju, nego su ugrađeni odmah iza teorije koju koriste. Zadatak koji dodiruje više tema razlomljen je po podzadacima, pa svaki podzadatak stoji uz svoju teoriju.

Tipovi okvira u tekstu:

- **Definicija** — pojam koji morate znati točno onako kako je zapisan.
- **Teorem** — tvrdnja iz predavanja, s objašnjenjem što znači i kako se koristi.
- **Zadatak** — zadatak s vježbi, s potpunim rješenjem raspisanim korak po korak.
- **Napomena** — upozorenje, česta greška ili tipfeler u izvorniku.
- **Kako to nacrtati rukom** — inkrementalne upute za crtanje grafa, korak po korak, do potpune slike.

Oznake stranica. Uz naslove i tvrdnje stoji oznaka poput [str. 15] koja pokazuje stranicu izvornog PDF-a odakle je sadržaj preuzet, da možete provjeriti original.

Napomena o izvorniku. Prezentacije su rađene u Beameru, pa se većina slajdova pojavljuje u više „inkrementalnih” verzija (isti slajd koji se gradi natuknicu po natuknicu). Takvi nizovi ovdje su sažeti u jedan potpuni odjeljak, ali nijedna natuknica nije izostavljena.

Sadržaj

Kako koristiti ovu skriptu	1
1 Uvod	5
1.1 Što je optimizacija?	5
1.2 Optimizacijski problem — standardna forma	6
1.2.1 Zapis s pojedinačnim ograničenjima	6
1.2.2 Objašnjenje svakog simbola od nule	6
1.2.3 Kompaktni („vektorski”) zapis	7
1.2.4 Što je optimalno rješenje	8
1.2.5 Dozvoljeni skup	8
1.3 Uvodni primjer s potpunim grafom	8
1.3.1 Postavka problema	8
1.3.2 Prepoznavanje elemenata standardne forme	9
1.3.3 Rješenje	9
1.3.4 Graf	10
1.4 Gdje i zašto se optimira?	12
1.4.1 Optimiranje rada sustava / procesa („on-line”)	12
1.4.2 U fundamentalnim fizikalnim zakonima / problemima	13
1.4.3 U prirodi	13
1.4.4 Optimalno projektiranje	13
1.5 Sadržaj kolegija i ishodi učenja	13
1.6 Motivacijski primjeri iz prakse	14
1.6.1 Planiranje proizvodnje u elektroenergetskoj mreži	14
1.6.2 Upravljanje tokovima snage i energijom u hibridnom automobilu	14
1.6.3 Prediktivno upravljanje dinamičkim sustavima	15
1.6.4 Optimalno upravljanje — pozicioniranje glave tvrdog diska	15
1.6.5 Ravnotežni položaj sustava u potencijalnom polju	15
1.6.6 Primjeri iz prirode	16
1.6.7 Raspodjela vjetroturbina u vjetroparku	16
1.7 Primjer: problem proizvodnje i distribucije robe	16
1.7.1 Opis problema	17
1.7.2 Projektne varijable	17

1.7.3	Potpuna formulacija	17
1.8	Klasični primjeri optimiranja s potpunim rješenjima	18
1.8.1	Optimalno iskorištavanje materijala — posuda iz limene ploče	18
1.8.2	Minimizacija troškova izgradnje — tlocrt kuće	19
1.8.3	Maksimizacija volumena lijevka I	20
1.8.4	Maksimizacija volumena lijevka II	21
1.8.5	Dimenzioniranje otvora vrata	22
1.8.6	Optimalna ograda	23
1.9	Vrste optimizacije konstrukcija	24
1.9.1	Dimenzionalna optimizacija (<i>size optimization</i>)	24
1.9.2	Optimiranje oblika (<i>shape optimization</i>)	24
1.9.3	Topološka optimizacija (<i>topology optimization</i>)	24
1.10	Postavka problema	25
1.10.1	Jednostavan primjer koji to ilustrira	25
1.10.2	Brojčana usporedba triju oblika, $L = 500$ m	25
1.11	Projektiranje kao proces	26
1.11.1	Slijed projektiranja	27
1.11.2	Strukturalna sinteza	27
1.11.3	Cilj projektiranja?	27
1.11.4	Proces projektiranja	28
1.11.5	Elementi optimizacijskog modela: projektni parametri i varijable	28
1.11.6	Optimizacijski model — pravila izbora parametara	29
1.12	Neki korisni „trikovi”	30
1.12.1	Minimizacija $\Leftrightarrow$ maksimizacija	30
1.12.2	Provjera je li dozvoljeni skup prazan (problem dopustivosti)	30
1.13	Sažetak poglavlja	31
2	Definicije, klasifikacija, konveksnost	33
3	Uvjeti optimalnosti	34
4	Lagrangeova dualnost	35
5	Linearno i kvadratno programiranje	36
6	Konicno kvadratno i semidefinitno programiranje	37
7	Dinamicki sustavi, Ljapunov, disipativnost	38

8 Robusno optimiranje**39**

POGLAVLJE 1

Uvod

Izvor: 01_Uvod.pdf, stranice 1--79 (obrađeno u cijelosti).

1.1 Što je optimizacija?

[str. 2--7]

Etimologija. Riječ *optimizacija* potječe od latinske riječi „**optimus**”, što znači *najbolji*.

Definicija 1.1: opisna, sa slajda

Optimizacija sadrži skup aktivnosti čiji je cilj pronaći „**najbolje rješenje**”, tzv. **optimum**, uz poštivanje zadanih **ograničenja**.

Uočite da su u toj rečenici već sadržana **tri** ključna sastojka svakog optimizacijskog problema, i vrijedi ih odmah imenovati jer ćemo se na njih vraćati kroz cijeli kolegij:

1. **Nešto se bira** — postoje veličine koje mi možemo mijenjati (npr. dimenzije konstrukcije, količina proizvedene robe, iznosi struja).
2. **Postoji mjerilo „najboljeg”** — moramo imati broj koji svakom izboru pridružuje ocjenu (cijena, masa, potrošnja...), inače riječ „najbolje” nema značenja.
3. **Ne smije se birati što god** — izbori moraju zadovoljiti ograničenja (npr. ne možemo proizvesti više nego što tvornica može, dimenzija ne može biti negativna).

Optimizacija kao matematička disciplina. Sa slajda:

Optimizacija = matematička teorija i algoritmi („matematička mašinerija”) ne samo za donošenje najboljih odluka, već često i ključna za donošenje odluka općenito (izabrati najbolje rješenje od svih mogućih *vs.* da li uopće postoji rješenje).

Ta je zagrada važnija nego što se čini. Kod složenih inženjerskih problema često uopće **nije očit** postoji li **ijedan izbor** koji zadovoljava sva ograničenja. Pitanje „postoji li dopušteno rješenje?” je samo po sebi optimizacijski problem — i to ćemo formalno riješiti već na kraju ovog poglavlja (odjeljak 1.12).

Povijest. Ljudi teže „optimiranju” od davnina, ali korijeni **moderne** optimizacije smještaju se u vrijeme **2. svjetskog rata** — tada nastaju metode *operacijskih istraživanja* (engl. *operations research*).

Terminologija. Pojam „**matematičko programiranje**” (engl. *mathematical programming*) često se koristi kao sinonim za optimiranje. Odatle nam dolaze i imena cijelih klasa problema koje ćemo obrađivati:

- *linear programming* (linearno programiranje, LP) → poglavlje 5,

- *nonlinear programming* (nelinearno programiranje),
- *quadratic programming* (kvadratno programiranje, QP) → poglavlje 5,
- ... i tako dalje.

Riječ „programiranje” ovdje **nema veze s računalnim programiranjem**. Potječe iz vojnog konteksta 1940-ih, gdje je „program” značio *plan* ili *raspored* (npr. program opskrbe). To je uobičajen izvor zabune kod ljudi koji se prvi put susreću s temom.

Jezična opaska sa slajda [str. 7]. Predavač posebno ističe riječ *najoptimalnije* — kao primjer *pogrešne* upotrebe. Razlog: „optimalno” već znači *najbolje*. Ne postoji „optimalnije” ni „najoptimalnije”, kao što ne postoji „najnajbolje”. Ispravno je reći **optimalno**.

1.2 Optimizacijski problem — standardna forma

[str. 8--9]

Ovo je **središnja definicija cijelog kolegija**. Sve što slijedi u poglavljima 2–8 samo je razrada ovog zapisa.

1.2.1 Zapis s pojedinačnim ograničenjima

Definicija 1.2: Optimizacijski problem

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h_i(x) = 0, \quad i = 1, \dots, m \\ &&& g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{1.1}$$

1.2.2 Objašnjenje svakog simbola od nule

Vektor projektnih varijabli x .

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- To su **projektne varijable** (engl. *decision variables*, hrv. i *varijable odluke*).
- Ovo su veličine koje **mi biramo** — one su „nepoznanice” problema.
- n je broj tih veličina. Vektor x je dakle stupac od n realnih brojeva; pišemo $x \in \mathbb{R}^n$.
- Notacija $\mathbb{R}$ označava skup realnih brojeva, a $\mathbb{R}^n$ skup svih uređenih n -torki realnih brojeva. Npr. $\mathbb{R}^2$ je obična ravnina.

Funkcija cilja f .

$$f : \mathbb{R}^n \rightarrow \mathbb{R}$$

- Naziva se **funkcija cilja**, **ciljna funkcija** ili **kriterij** (engl. *objective function*, *cost function*).
- Zapis $f : \mathbb{R}^n \rightarrow \mathbb{R}$ čita se: „ f je funkcija koja uzima vektor iz $\mathbb{R}^n$ i vraća **jedan realan broj**”. Baš zato što vraća **jedan** broj, možemo dva različita izbora x međusobno usporediti i reći koji je bolji.
- Konvencija je da **minimiziramo**. Ako želimo maksimizirati, koristimo trik iz odjeljka 1.12.

Ograničenja jednakosti h_i .

$$h_i : \mathbb{R}^n \rightarrow \mathbb{R}, \quad i = 1, \dots, m$$

- Engl. *equality constraints*.
- Uvjet $h_i(x) = 0$ mora biti zadovoljen **točno**, bez ikakvog odstupanja.
- Tipično dolaze iz fizikalnih zakona ili definicijskih veza (npr. „površina mora biti točno A ”, „proizvodnja mora biti jednaka potrošnji”).
- m je broj ograničenja jednakosti.

Ograničenja nejednakosti g_j .

$$g_j : \mathbb{R}^n \rightarrow \mathbb{R}, \quad j = 1, \dots, p$$

- Engl. *inequality constraints*.
- Uvjet $g_j(x) \leq 0$ dopušta „rezervu”: dovoljno je da vrijednost ne prijeđe nulu.
- Tipično dolaze iz tehničkih ili resursnih ograničenja („naprezanje ne smije prijeći dopušteno”, „ne možemo proizvesti više od kapaciteta”).
- p je broj ograničenja nejednakosti.

Projektni prostor. Općenito pišemo $x \in X$, gdje je X **projektni prostor**. U svemu što slijedi u ovom kolegiju bit će $X = \mathbb{R}^n$.

1.2.3 Kompaktni („vektorski”) zapis

[str. 9]

Umjesto da nabrajamo ograničenja jedno po jedno, sve h_i složimo u jedan vektorski zapis, i isto za g_j :

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h(x) = 0 \\ &&& g(x) \leq 0 \end{aligned} \tag{1.2}$$

gdje je sada

$$h : \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad h(x) = \begin{pmatrix} h_1(x) \\ \vdots \\ h_m(x) \end{pmatrix}, \quad g : \mathbb{R}^n \rightarrow \mathbb{R}^p, \quad g(x) = \begin{pmatrix} g_1(x) \\ \vdots \\ g_p(x) \end{pmatrix}$$

Nejednakost između vektora ovdje se čita **po komponentama**: $g(x) \leq 0$ znači $g_1(x) \leq 0$ i $g_2(x) \leq 0$ i ... i $g_p(x) \leq 0$. Sve nejednakosti moraju vrijediti istovremeno. Nula na desnoj strani je nul-vektor odgovarajuće dimenzije.

1.2.4 Što je optimalno rješenje

[str. 9]

Definicija 1.3: Optimalno rješenje

Optimalno rješenje x^* je vektor projektnih varijabli koji, od svih vektora iz projektnog prostora koji zadovoljavaju ograničenja, ima **najmanju** vrijednost funkcije cilja f .

Uočite da definicija ima dva dijela i oba su nužna:

1. x^* mora **sam zadovoljavati ograničenja** (inače nije kandidat),
2. među svim takvim kandidatima ima **najmanji** f .

Zvjezdica $*$ je standardna oznaka za optimalnu vrijednost; koristit ćemo je kroz cijelu skriptu (x^* , $f(x^*)$, kasnije p^* , λ^* , ...).

1.2.5 Dozvoljeni skup

[str. 78]

Skup svih x koji zadovoljavaju **sva** ograničenja zove se **dozvoljeni skup** (ili *dozvoljeno područje*, *dozvoljeni projektni prostor*; engl. *feasible set*):

Definicija 1.4: Dozvoljeni skup

$$\mathcal{F} = \{ x \mid h(x) = 0, g(x) \leq 0 \} \quad (1.3)$$

Notacija $\{ x \mid \text{uvjet} \}$ čita se: „skup svih x **takvih da** vrijedi uvjet”. Uspravna crta $|$ znači „takvih da”.

Uz tu oznaku problem se piše najkraće:

$$\min_{x \in \mathcal{F}} f(x)$$

1.3 Uvodni primjer s potpunim grafom

[str. 10--15]

Ovo je prvi konkretan problem u kolegiju i vrijedi ga proći vrlo pažljivo, jer se na njemu vidi *sve* iz prethodnog odjeljka odjednom.

1.3.1 Postavka problema

[str. 10]

$$\begin{aligned} \min_x \quad & (x_1 - 2)^2 + (x_2 - 1)^2 \\ \text{uz ograničenja} \quad & \begin{cases} x_1^2 - x_2 \leq 0 \\ x_1 + x_2 \leq 2 \end{cases} \end{aligned} \quad (1.4)$$

Projektni prostor [str. 10]: $X = \mathbb{R}^n$ s varijablama $x = (x_1, x_2)$, dakle $n = 2$.

1.3.2 Prepoznavanje elemenata standardne forme

[str. 11--12]

Dozvoljeni skup [str. 11]:

$$\mathcal{F} = \{x \mid g(x) \leq 0\}, \quad g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \end{pmatrix} = \begin{pmatrix} x_1^2 - x_2 \\ x_1 + x_2 - 2 \end{pmatrix} \leq 0$$

Obratite pažnju na **prebacivanje na standardnu formu**: ograničenje je zadano kao $x_1 + x_2 \leq 2$, a standardna forma traži oblik $g_j(x) \leq 0$. Zato **oduzmemo 2 s obje strane**:

$$x_1 + x_2 \leq 2 \iff x_1 + x_2 - 2 \leq 0 \implies g_2(x) = x_1 + x_2 - 2$$

Prvo ograničenje već je u pravom obliku: $g_1(x) = x_1^2 - x_2$.

Funkcija cilja [str. 12]:

$$f(x) = (x_1 - 2)^2 + (x_2 - 1)^2$$

Geometrijsko značenje funkcije cilja. $f(x)$ je **kvadrat udaljenosti** točke $x = (x_1, x_2)$ od točke $(2, 1)$. (Po Pitagorinu poučku, udaljenost je $\sqrt{(x_1 - 2)^2 + (x_2 - 1)^2}$, a f je taj izraz na kvadrat.) Dakle problem glasi: „**nađi točku dozvoljenog skupa koja je najbliža točki $(2, 1)$** ”. Bez ograničenja rješenje bi trivijalno bilo $x = (2, 1)$ s $f = 0$; ograničenja to zabranjuju i zato problem nije trivijalan.

1.3.3 Rješenje

[str. 15]

$$x^* = \begin{pmatrix} x_1^* \\ x_2^* \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad f(x^*) = 1$$

Provjera da je x^* doista dozvoljena točka (uvrštavanje korak po korak):

$$g_1(x^*) = (x_1^*)^2 - x_2^* = 1^2 - 1 = 1 - 1 = 0 \leq 0 \quad \checkmark \quad (1.5)$$

$$g_2(x^*) = x_1^* + x_2^* - 2 = 1 + 1 - 2 = 2 - 2 = 0 \leq 0 \quad \checkmark \quad (1.6)$$

Oba ograničenja su zadovoljena s **jednakošću** — kažemo da su **aktivna** u x^* (taj ćemo pojam formalno uvesti u poglavlju 3).

Provjera vrijednosti funkcije cilja:

$$f(x^*) = (1 - 2)^2 + (1 - 1)^2 = (-1)^2 + 0^2 = 1 + 0 = 1 \quad \checkmark$$

1.3.4 Graf

Slajdovi 13, 14 i 15 grade upravo ovaj crtež u tri koraka: prvo ograničenje g_1 , zatim ograničenje g_2 , pa oba zajedno s nivo krivuljama.

Kako to nacrtati rukom: dozvoljeni skup i nivo krivulje

Korak 1 — prazan koordinatni sustav. Nacrtajte vodoravnu os i označite je x_1 , te okomitu os i označite je x_2 . Raspon kao na slajdu: x_1 od -2 do 3 , x_2 od -2 do 4 . Označite jedinice na obje osi (cijeli brojevi). Koristite **jednako mjerilo** na obje osi — inače će kružnice iz koraka 5 izgledati kao elipse i izgubit će se geometrijsko značenje.

Korak 2 — prvo ograničenje g_1 (odgovara slajdu 13). Granica ograničenja g_1 je krivulja gdje vrijedi jednakost:

$$g_1(x) = 0 \iff x_1^2 - x_2 = 0 \iff x_2 = x_1^2$$

To je **obična parabola** s tjemenom u ishodištu $(0, 0)$, otvorena prema gore. Nacrtajte je kroz nekoliko točaka koje lako izračunate:

x_1	-2	-1	0	1	2
$x_2 = x_1^2$	4	1	0	1	4

Koju stranu sjenčati? Ograničenje traži $x_1^2 - x_2 \leq 0$, tj. $x_2 \geq x_1^2$. Dakle dopušteno je ono što je **iznad** parabole. Provjera testnom točkom: uzmimo $(0, 1)$ — tada je $g_1 = 0^2 - 1 = -1 \leq 0$ ✓, a točka $(0, 1)$ leži iznad parabole. Dakle: **osjenčajte (kao nedopušteno) područje ispod parabole**, a zadržite područje iznad nje.

Korak 3 — drugo ograničenje g_2 (odgovara slajdu 14). Granica je pravac:

$$g_2(x) = 0 \iff x_1 + x_2 - 2 = 0 \iff x_2 = 2 - x_1$$

Pravac s nagibom -1 . Najlakše ga je nacrtati kroz dvije točke — sjecišta s osima:

- za $x_1 = 0$: $x_2 = 2 \rightarrow$ točka $(0, 2)$,
- za $x_2 = 0$: $x_1 = 2 \rightarrow$ točka $(2, 0)$.

Povucite pravac kroz te dvije točke.

Koju stranu sjenčati? Ograničenje traži $x_1 + x_2 - 2 \leq 0$, tj. $x_2 \leq 2 - x_1$, dakle dopušteno je **ispod** pravca. Provjera testnom točkom: ishodište $(0, 0)$ daje $g_2 = 0 + 0 - 2 = -2 \leq 0$ ✓, a ishodište je ispod pravca. Dakle: **osjenčajte (kao nedopušteno) područje iznad pravca**.

Korak 4 — odnos dviju krivulja i dozvoljeni skup. Parabola i pravac se sijeku ondje gdje vrijedi i $x_2 = x_1^2$ i $x_2 = 2 - x_1$:

$$x_1^2 = 2 - x_1 \implies x_1^2 + x_1 - 2 = 0 \implies (x_1 + 2)(x_1 - 1) = 0 \implies x_1 = -2 \text{ ili } x_1 = 1$$

Pripadni x_2 :

- za $x_1 = -2$: $x_2 = 2 - (-2) = 4 \rightarrow$ sjecište $(-2, 4)$,
- za $x_1 = 1$: $x_2 = 2 - 1 = 1 \rightarrow$ sjecište $(1, 1)$.

Dozvoljeni skup je presjek dvaju područja: **iznad parabole i ispod pravca**. To je oblik „leće” (na slajdu bijelo područje) omeđen odozdo parabolom, a odozgo pravcem, s vrhovima točno u dvjema sjecišnim točkama $(-2, 4)$ i $(1, 1)$. Sve ostalo na crtežu je nedopušteno (na slajdu obojeno crveno).

Korak 5 — nivo krivulje funkcije cilja (odgovara slajdu 15). **Nivo krivulja** (engl. *level curve, contour*) funkcije f za razinu c je skup svih točaka u kojima f ima istu vrijednost c : $\{x \mid f(x) = c\}$. (Pojam se detaljnije obrađuje u poglavlju 2.) Ovdje:

$$(x_1 - 2)^2 + (x_2 - 1)^2 = c$$


To je **kružnica sa središtem u $(2, 1)$ i polumjerom $\sqrt{c}$** . Nacrtajte nekoliko koncentričnih kružnica oko točke $(2, 1)$, npr. za

$$c = 0,25 \ (r = 0,5), \quad c = 1 \ (r = 1), \quad c = 2 \ (r \approx 1,41), \quad c = 4 \ (r = 2), \quad c = 9 \ (r = 3)$$

Što je kružnica manja, to je vrijednost funkcije cilja manja — jer je f kvadrat udaljenosti od središta.

Korak 6 — očitavanje optimuma. Označite točku $(2, 1)$ (križić) — to bi bio minimum *da nema ograničenja*, ali ona leži u crvenom (nedopuštenom) području: provjerimo, $g_1(2, 1) = 2^2 - 1 = 3 > 0$, dakle nedopustiva. Sada „napuhajte” kružnice od polumjera 0 prema van i gledajte **koja prva dotakne bijelu leću**. Ta prva dodirna točka je optimum. To je točno kružnica $c = 1$, a dodiruje leću u vrhu $(1, 1)$ — dakle $x^* = (1, 1)$, $f(x^*) = 1$.

Korak 7 — što graf znači. Optimum leži u **vrhu** dozvoljenog skupa, ondje gdje se sijeku obje granice, dakle **oba ograničenja su aktivna**. Optimalna vrijednost $f(x^*) = 1$ strogo je veća od nule (vrijednosti neograničenog minimuma) — to je „cijena” koju plaćamo zato što nas ograničenja tjeraju dalje od željene točke $(2, 1)$. U poglavlju 3 naučit ćemo algebarski uvjet (KKT uvjete) koji formalno opisuje upravo ovakvu situaciju.



Slika 1.1: Dozvoljeni skup (bijela „leća”), nivo krivulje funkcije cilja (koncentrične kružnice oko $(2, 1)$) i optimum $x^* = (1, 1)$. Nedopušteno područje je crveno.

Na slajdu 15 prvo ograničenje je otipkano kao $g_1(x) = x_1^2 - x^2 \leq 0$, dok na slajdovima 10--14 svugdje piše $g_1(x) = x_1^2 - x_2 \leq 0$. Ispravno je $x_1^2 - x_2$ — to potvrđuje i sam crtež na slajdu (parabola $x_2 = x_1^2$) i rješenje $x^* = (1, 1)$.

1.4 Gdje i zašto se optimira?

[str. 16--17]

1.4.1 Optimiranje rada sustava / procesa („on-line”)

- Planiranje proizvodnje u elektroenergetskoj mreži
- Upravljanje motorom automobila
- Upravljanje tokovima snage i energijom u hibridnom automobilu
- Traženje najkraćeg puta (npr. GPS u autu, „preračunavam”)
- Gibanje robota prilikom obavljanja zadatka
- Plan bušenja rupa na ploči za elektroniku

- Web tražilica
- Optimalno upravljanje dinamičkim sustavima (bogata inženjerska / znanstvena grana za sebe)
- ...

1.4.2 U fundamentalnim fizikalnim zakonima / problemima

- Traženje **ravnotežnog položaja** minimizacijom potencijalne energije
- **Stabilnost dinamičkih sustava** — traženje Ljapunovljeve funkcije

Ove dvije stavke nisu samo ilustracija: prva se detaljno rješava u poglavlju 3, a druga je tema cijelog poglavlja 7.

1.4.3 U prirodi

- Oblik stabla (optimiranje oblika obzirom na vlastitu težinu i vanjska opterećenja)
- Struktura kosti
- Trajektorija šišmiša u lovu na plijen
- Oblik jabuke
- Prilagodba vrste na uvjete života u zadanoj okolini
- ...

1.4.4 Optimalno projektiranje

- Optimalna raspodjela vjetroturbina u vjetroparku
- Optimiranje topologije, oblika, dimenzija mehanizama i nosivih konstrukcija — **u ovom kolegiju**
- ...

... i još puno, puno toga.

1.5 Sadržaj kolegija i ishodi učenja

[str. 18--32]

Kompletna popis tema sa slajdova (gradi se inkrementalno kroz 15 slajdova):

1. **Uvod:** Ciljevi kolegija i ishodi učenja.
2. **Optimizacijski problem:** definicije i klasifikacija. Konveksni opt. problemi.
3. **Uvjeti optimalnosti.** Geometrijska interpretacija i primjene.
4. **Lagrangeova dualnost,** alternative i analiza osjetljivosti.
5. **Linearno programiranje.** pristupi rješavanju i primjeri.
6. **Kvadratno programiranje** s primjenama. Formulacija i značajke.
7. **Linearne matrične nejednadžbe i semidefinitno programiranje.**
8. **Numerički algoritmi** za rješavanje opt. problema (pregled).

9. **Optimiranje mehatroničkih sustava** — od linearnog do semidefinitnog programiranja: primjeri iz prakse.
10. **Formulacija stabilnosti i disipativnost dinamičkih sustava** kao opt. problema.
11. Formulacije kriterija i analiza učinkovitosti dinamičkih sustava.
12. Formulacije **optimalnog upravljanja** i pristupi rješavanju.
13. **Robusno optimiranje 1**
14. **Robusno optimiranje 2**
15. **Višeciljna optimizacija** i višeciljno upravljanje

Kako se to preslikava na ovu skriptu: teme 1--2 → poglavlja 1--2; tema 3 → poglavlje 3; tema 4 → poglavlje 4; teme 5--6 → poglavlje 5; teme 7 i 9 → poglavlje 6; teme 10--12 → poglavlje 7; teme 13--14 → poglavlje 8.

1.6 Motivacijski primjeri iz prakse

[str. 33--43]

1.6.1 Planiranje proizvodnje u elektroenergetskoj mreži

[str. 33--34]

Problem: planiranje rada električnih generatora.

Sa slajda, sa svrstavanjem svake stavke u element standardne forme:

Sa slajda	Element opt. problema
tipično noć prije dana proizvodnje	(vremenski okvir odluke)
proizvodnja = predviđenoj potrošnji	ograničenje jednakosti $h(x) = 0$
minimiziranje troškova proizvodnje	funkcija cilja $f(x)$
ograničenja na tok snage u dalekovodima	ograničenja nejednakosti $g(x) \leq 0$
planovi u slučaju kvara	robustnost (poglavlje 8)

Dodatno [str. 34]:

- Optimiranje (optimalno upravljanje) je „**skrivena tehnologija**” za razvoj naprednih mreža u budućnosti.
- Matematička formulacija tržišta i kreiranja tržišnih cijena: **Lagrangeova dualnost**.

Zadnja rečenica je najava Vježbi 3, gdje se cijeli „Primjer 1: Tržište i formiranje cijena” rješava upravo preko dualnosti — vidi poglavlje 4.

1.6.2 Upravljanje tokovima snage i energijom u hibridnom automobilu

[str. 35]

- Nije dobro imati napunjenu bateriju: želimo je (polu)praznu da bismo je mogli puniti prilikom kočenja (rekuperacija).

- **dobro** $\rightarrow$ **optimalno**
- Optimiranje je „skrivena tehnologija” koja daje „inteligenciju” procesu: pojmovi *dobro--loše* moraju biti vezani uz neki kriterij $\rightarrow$ **formalizacija funkcije cilja**.

1.6.3 Prediktivno upravljanje dinamičkim sustavima

[str. 36--37]

Slajdovi su ilustracija koncepta MPC-a (engl. *Model Predictive Control*): u svakom koraku se, na temelju modela, riješi optimizacijski problem na konačnom horizontu predikcije, primijeni se prvi upravljački potez, pa se postupak ponovi.

1.6.4 Optimalno upravljanje — pozicioniranje glave tvrdog diska

[str. 38]

Slajd prikazuje mehanizam tvrdog diska (ruka s glavom, *pivot, voice coil motor* VCM) i regulacijsku petlju: regulator K prima signal pogreške e i daje upravljanje u ; y_r je referenca, y izlaz, d poremećaj.

Podaci sa slajda: $>15\,000$ o/min, $12\,000$ traka na 1 cm.

Formulacija problema (sa slajda):

$$\min_K \max_{\|d\| \neq 0} \frac{\|e\|}{\|d\|}, \quad K \in \{ \text{stabilizirajući regulatori} \} \quad (1.7)$$

Kako to čitati. $\|\cdot\|$ je **norma** — mjera „veličine” signala (formalno u poglavlju 2). Omjer $\|e\|/\|d\|$ je „koliko se poremećaj d pojača u pogrešku e ”. Unutarnji $\max$ uzima **najgori mogući** poremećaj, a vanjski $\min$ bira regulator koji taj najgori slučaj čini što manjim. Ovakav **min--max** zapis je tipičan za robusno projektiranje i vratit ćemo mu se u poglavljima 7 i 8.

1.6.5 Ravnotežni položaj sustava u potencijalnom polju

[str. 39--40]

Postavka [str. 39]. Točka mase m obješena je u vertikalnoj ravnini o dvije elastične opruge zanemarive mase s konstantama k_1, k_2 i duljinama l_1, l_2 , dok je razmak objesišta jednak d .

Geometrija sa slajda: koordinatni sustav (x, y) ; lijevo objesište je u ishodištu $(0, 0)$, desno objesište je na osi x na udaljenosti d , tj. u $(d, 0)$; masa m visi ispod, u točki (x, y) (s $y < 0$). Lijeva opruga ima parametre k_1, l_1 , desna k_2, l_2 .

Zadatak: izračunati ravnotežni položaj mase.

Rješenje [str. 40]. Potencijalna energija mase m u položaju (x, y) je

$$V(x, y) = mgy + \frac{k_1}{2} \left(l_1 - \sqrt{x^2 + y^2} \right)^2 + \frac{k_2}{2} \left(l_2 - \sqrt{(d-x)^2 + y^2} \right)^2 \quad (1.8)$$

Rastav izraza član po član (svaki je član oblika „energija”):

- mgy — **gravitacijska potencijalna energija** mase u polju sile teže (g = ubrzanje sile teže). Budući da masa visi ispod osi x, y je negativan pa je taj član negativan — spuštanjem mase energija pada.

- $\sqrt{x^2 + y^2}$ — trenutna **duljina lijeve opruge**, tj. udaljenost od objesišta $(0, 0)$ do mase (x, y) (Pitagorin poučak).
- $l_1 - \sqrt{x^2 + y^2}$ — **deformacija** lijeve opruge (razlika nedeformirane duljine l_1 i trenutne duljine).
- $\frac{k_1}{2}(\cdot)^2$ — **elastična energija** lijeve opruge; standardna formula $E = \frac{1}{2}k \Delta l^2$.
- Analogno za desnu oprugu, samo je njezino objesište u $(d, 0)$, pa je udaljenost do mase $\sqrt{(d-x)^2 + y^2}$.

Ravnotežna točka (x^*, y^*) je ona koja **minimizira** potencijalnu energiju:

$$(x^*, y^*) = \arg \min_{x, y} V(x, y) \quad (1.9)$$

$\min_x V(x)$ je **najmanja vrijednost** koju V poprima (broj), dok je $\arg \min_x V(x)$ **argument** u kojem se taj minimum postiže (točka). Za nas je obično zanimljiv $\arg \min$ — želimo znati *gdje* je optimum, a ne samo *koliko* iznosi.

Ovo je važan konceptualni primjer: **fizikalni zakon (ravnoteža) izražen je kao optimizacijski problem bez ograničenja**. Isti primjer se u poglavlju 3 proširuje na slučaj s ograničenjima i rješava preko uvjeta optimalnosti.

1.6.6 Primjeri iz prirode

[str. 41]

Slajd je fotografska ilustracija tvrdnji iz odjeljka o prirodi (oblici koje priroda „optimira”). Nema dodatnih formula.

1.6.7 Raspodjela vjetroturbina u vjetroparku

[str. 42--43]

Slajd 43 prikazuje dva 3D grafa (površina prinosa nad tlocrtom parka, s ucrtanim pozicijama turbina kao točkama i označenim smjerom sjevera **N**):

- lijevo: **optimalni položaji sa zanemarenim interakcijama preko vrtloga**,
- desno: **optimalni položaji s uračunatim interakcijama preko vrtloga**.

Poanta: ista funkcija cilja (ukupna proizvedena energija), ali bogatiji model (uzimanje u obzir da turbina u vjetrenoj sjeni druge turbine daje manje) daje **bitno drukčiji optimalni raspored**. Model ulazi u optimizaciju kroz ograničenja i funkciju cilja — kvaliteta modela izravno određuje kvalitetu optimuma.

1.7 Primjer: problem proizvodnje i distribucije robe

[str. 44--45]

Ovo je prvi potpuno formuliran „inženjersko-poslovni” problem u kolegiju i ujedno prvi primjer **linearnog programa** (LP), koji ćemo formalno obraditi u poglavlju 5.

1.7.1 Opis problema

[str. 44]

- Tvrtka ima **2 tvornice** i **7 trgovina**.
- U jednom proizvodnom vremenskom intervalu tvornica i može proizvesti do a_i tona.
- Svaka trgovina j redovito ima potražnju od b_j tona.
- Troškovi transporta od tvornice i do trgovine j su c_{ij} kuna/toni.
- **Kako optimalno voditi tvrtku (minimizirati trošak)?**

1.7.2 Projektne varijable

[str. 45]

$x_{ij} \in \mathbb{R}$: koliko tvornica i dobavlja robe trgovini j , $x_{ij} \geq 0$

Budući da imamo 2 tvornice i 7 trgovina, ukupno je $2 \times 7 = 14$ varijabli. Uvjet $x_{ij} \geq 0$ je fizikalne prirode: ne može se isporučiti negativna količina.

1.7.3 Potpuna formulacija

[str. 45]

$$\begin{aligned}
 & \min \quad \sum_{i=1}^2 \sum_{j=1}^7 c_{ij} x_{ij} \\
 & \text{uz ograničenja} \quad \sum_{j=1}^7 x_{ij} \leq a_i, \quad i = 1, 2 \\
 & \quad \sum_{i=1}^2 x_{ij} \geq b_j, \quad j = 1, \dots, 7 \\
 & \quad x_{ij} \geq 0
 \end{aligned} \tag{1.10}$$

Čitanje svakog retka:

- **Funkcija cilja** $\sum_i \sum_j c_{ij} x_{ij}$: za svaku moguću relaciju tvornica $\rightarrow$ trgovina pomnožimo prevezenu količinu x_{ij} [t] s jediničnim troškom c_{ij} [kn/t] i sve zbrojimo. Rezultat je **ukupan trošak transporta** u kunama. (Simbol $\sum$ znači „zbroji po svim vrijednostima indeksa”; dvostruka suma znači da prolazimo po svim parovima (i, j) , dakle po svih 14 relacija.)
- **Kapacitet tvornice** $\sum_j x_{ij} \leq a_i$: sve što tvornica i pošalje (zbroj po svim trgovinama) ne smije prijeći njezin kapacitet a_i . Dva takva ograničenja (po jedno za svaku tvornicu).
- **Potražnja trgovine** $\sum_i x_{ij} \geq b_j$: sve što trgovina j primi (zbroj po objema tvornicama) mora biti barem b_j . Sedam takvih ograničenja.
- **Nenegativnost** $x_{ij} \geq 0$: 14 ograničenja.

Standardna forma traži $g_j(x) \leq 0$, pa nejednakost „ $\geq$ ” pomnožimo s -1 (što okreće smjer):
 $\sum_i x_{ij} \geq b_j \Leftrightarrow b_j - \sum_i x_{ij} \leq 0$, i $x_{ij} \geq 0 \Leftrightarrow -x_{ij} \leq 0$. Kapacitet je već u pravom obliku
 nakon premještanja: $\sum_j x_{ij} - a_i \leq 0$.

Uočite: i funkcija cilja i sva ograničenja su **linearne** funkcije varijabli x_{ij} . To je definicija linearnog programa (poglavlje 5).

1.8 Klasični primjeri optimiranja s potpunim rješenjima

[str. 46--52]

Slajdovi 46--52 rješavaju šest školskih ekstremalnih problema. Svi se rješavaju istim receptom, pa ga vrijedi jednom izreći:

Definicija 1.5: Recept klasične analize — ekstrem funkcije jedne varijable

1. Uvedi varijablu i izrazi **funkciju cilja** preko nje.
2. Ako postoji ograničenje jednakosti, iz njega **izrazi jednu varijablu** i **uvrsti** u funkciju cilja (eliminacija) — tako problem s ograničenjem postaje problem bez ograničenja.
3. Deriviraj i izjednači s nulom: $\frac{dF}{dx} = 0 \rightarrow$ **stacionarne točke**.
4. Provjeri drugom derivacijom: $F'' > 0 \rightarrow$ **minimum**, $F'' < 0 \rightarrow$ **maksimum**.
5. Izračunaj vrijednost cilja u nađenoj točki.

Ovaj recept vrijedi za jednostavne, glatke probleme jedne varijable. U poglavlju 3 generalizirat ćemo ga na više varijabli i na probleme gdje se ograničenja *ne mogu* tako lako eliminirati — tada nastupaju Lagrangeovi multiplikatori i KKT uvjeti.

1.8.1 Optimalno iskorištavanje materijala — posuda iz limene ploče

[str. 46--47]

Problem. Iz kvadratne limene ploče stranice a potrebno je izrezati uglove tako da se iz preostalog dijela načini posuda što većeg volumena. Izrezuju se četiri kvadratića stranice x u uglovima; preostali „križ” se savine prema gore.

Ciljna funkcija je volumen:

$$V = (a - 2x)^2 \cdot x$$

Odakle to: nakon izrezivanja uglova stranice x i savijanja, baza posude je kvadrat stranice $a - 2x$ (s obje strane oduzimamo po x), a visina posude je x .

Derivacija:

$$\frac{dV}{dx} = 12x^2 - 8ax + a^2$$

Provjera računa (raspis međukoraka koji na slajdu nije napisan):

$$V = x(a - 2x)^2 = x(a^2 - 4ax + 4x^2) = a^2x - 4ax^2 + 4x^3 \quad (1.11)$$

$$\frac{dV}{dx} = a^2 - 8ax + 12x^2 \quad \checkmark \quad (1.12)$$

Izjednačavanje s nulom daje kvadratnu jednadžbu $12x^2 - 8ax + a^2 = 0$, čija su rješenja (sa slajda):

$$x_{1,2} = \frac{a}{3} \pm \frac{a}{6}; \quad x_1 = a/2, \quad x_2 = a/6$$

Provjera preko formule za kvadratnu jednadžbu:

$$x_{1,2} = \frac{8a \pm \sqrt{(8a)^2 - 4 \cdot 12 \cdot a^2}}{2 \cdot 12} = \frac{8a \pm \sqrt{64a^2 - 48a^2}}{24} = \frac{8a \pm \sqrt{16a^2}}{24} = \frac{8a \pm 4a}{24} \quad (1.13)$$

$$x_1 = \frac{12a}{24} = \frac{a}{2}, \quad x_2 = \frac{4a}{24} = \frac{a}{6} \quad \checkmark \quad (1.14)$$

Provjera drugom derivacijom:

$$V'' = \frac{d^2V}{dx^2} = 24x - 8a$$

$$V''\left(\frac{a}{2}\right) = 24 \cdot \frac{a}{2} - 8a = 12a - 8a = 4a > 0 \rightarrow \mathbf{min.} \quad (1.15)$$

$$V''\left(\frac{a}{6}\right) = 24 \cdot \frac{a}{6} - 8a = 4a - 8a = -4a < 0 \rightarrow \mathbf{max.} \quad (1.16)$$

Vrijednosti:

$$V_{\max} = \left(a - \frac{a}{3}\right)^2 \cdot \frac{a}{6} = \frac{2}{27}a^3; \quad V_{\min} = 0$$

Provjera: za $x = a/6$ je $a - 2x = a - a/3 = \frac{2a}{3}$, pa je $V = \left(\frac{2a}{3}\right)^2 \cdot \frac{a}{6} = \frac{4a^2}{9} \cdot \frac{a}{6} = \frac{4a^3}{54} = \frac{2a^3}{27} \checkmark$.
Za $x = a/2$ je $a - 2x = 0$, pa je $V = 0$ — geometrijski jasno: izrezali smo cijelu ploču, baza je nestala.

1.8.2 Minimizacija troškova izgradnje — tlocrt kuće

[str. 48]

Problem. Kuća ima 3 prostorije površine A [m²]. Troškovi izgradnje vanjskih zidova iznose C [EUR/m], a troškovi za unutrašnje zidove iznose $2/3$ tih troškova. Odrediti mjere tlocrta tako da troškovi izgradnje zidova budu minimalni.

Geometrija sa slajda: pravokutnik širine x i visine y ; unutar njega jedan okomiti zid (duljine y) koji odvaja desni dio, te u lijevom dijelu vodoravni zid duljine $2x/5$ — tako se dobiju 3 prostorije.

Ograničenje jednakosti:

$$A = x y \text{ [m}^2\text{]} \rightarrow y = A/x$$

Ciljna funkcija $\rightarrow$ minimalni troškovi:

$$F(x) = C \left(2x + 2\frac{A}{x} \right) + \frac{2}{3}C \left(\frac{2}{5}x + \frac{A}{x} \right)$$

Rastav: prvi član su vanjski zidovi — opseg pravokutnika je $2x + 2y = 2x + 2A/x$, uz cijenu C . Drugi član su unutarnji zidovi — vodoravni duljine $\frac{2}{5}x$ i okomiti duljine $y = A/x$, uz cijenu $\frac{2}{3}C$.

Sređivanje (sa slajda):

$$F(x) = \frac{2}{3}C \left(\frac{17}{5}x + 4\frac{A}{x} \right)$$

Raspis međukoraka koji na slajdu nije prikazan:

$$F(x) = 2Cx + \frac{2CA}{x} + \frac{2}{3}C \cdot \frac{2}{5}x + \frac{2}{3}C \frac{A}{x} \quad (1.17)$$

$$= C \underbrace{\left(2 + \frac{4}{15}\right)}_{=\frac{30+4}{15}=\frac{34}{15}} x + C \underbrace{\left(2 + \frac{2}{3}\right)}_{=\frac{6+2}{3}=\frac{8}{3}} \frac{A}{x} = \frac{34}{15}Cx + \frac{8}{3}C \frac{A}{x} \quad (1.18)$$

a s druge strane

$$\frac{2}{3}C \left(\frac{17}{5}x + \frac{4A}{x} \right) = \frac{2 \cdot 17}{3 \cdot 5}Cx + \frac{2 \cdot 4}{3}C \frac{A}{x} = \frac{34}{15}Cx + \frac{8}{3}C \frac{A}{x} \quad \checkmark$$

Konstante prebacimo na lijevu stranu (jer konstantni pozitivni faktor ne mijenja položaj minimuma — ovo je važan i često korišten trik):

$$F_0 = \frac{3F(x)}{2C} = \left(\frac{17}{5}x + 4\frac{A}{x} \right)$$

Derivacija i izjednačavanje s nulom:

$$\frac{dF_0}{dx} = \frac{17}{5} - \frac{4A}{x^2} = 0 \quad \rightarrow \quad x^2 = \frac{20}{17}A = \frac{20}{17}xy$$

Međukorak: iz $\frac{17}{5} = \frac{4A}{x^2}$ slijedi $x^2 = \frac{4A \cdot 5}{17} = \frac{20A}{17}$; zatim se uvrsti $A = xy$.

Odakle treba biti:

$$\frac{x}{y} = \frac{20}{17}$$

Međukorak: iz $x^2 = \frac{20}{17}xy$ podijelimo obje strane s x (dopušteno jer $x > 0$) i dobijemo $x = \frac{20}{17}y$, tj. $x/y = 20/17$.

1.8.3 Maksimizacija volumena lijevka I

[str. 49]

Problem. Neka se iz okrugle ploče izreže isječak tako da se iz ostatka načini lijevak (stožac) što većeg volumena.

Geometrija: iz kruga polumjera r izreže se kružni isječak, a preostali dio (središnjeg kuta φ) se smota u plašt stošca. Nastali stožac ima polumjer baze R , izvodnicu r (jer je to polumjer polazne ploče) i visinu h .

Polumjer baze (1): duljina luka preostalog dijela postaje opseg baze:

$$2R\pi = r\varphi \quad \rightarrow \quad R = \frac{r\varphi}{2\pi} \quad (1.19)$$

Visina stošca (2): iz pravokutnog trokuta (izvodnica, polumjer baze, visina):

$$h = \sqrt{r^2 - R^2} \quad (1.20)$$

Ciljna funkcija (3): volumen stošca

$$V = \frac{\pi R^2 h}{3} \quad (1.21)$$

Uvrštenjem (1) i (2) u (3):

$$V = \frac{r^3}{12\pi} \varphi^2 \sqrt{1 - \frac{\varphi^2}{4\pi^2}}$$

Raspis međukoraka:

$$R^2 = \frac{r^2 \varphi^2}{4\pi^2}, \quad h = \sqrt{r^2 - \frac{r^2 \varphi^2}{4\pi^2}} = r \sqrt{1 - \frac{\varphi^2}{4\pi^2}} \quad (1.22)$$

$$V = \frac{\pi}{3} \cdot \frac{r^2 \varphi^2}{4\pi^2} \cdot r \sqrt{1 - \frac{\varphi^2}{4\pi^2}} = \frac{r^3 \varphi^2}{12\pi} \sqrt{1 - \frac{\varphi^2}{4\pi^2}} \quad \checkmark \quad (1.23)$$

Prebacivanjem konstanti na lijevu stranu i kvadriranjem, uređena ciljna funkcija je:

$$F(\varphi) = \left(\frac{12\pi V}{r^3} \right)^2 = \varphi^4 \left(1 - \frac{\varphi^2}{4\pi^2} \right)$$

Funkcija $t \mapsto t^2$ je **strogo rastuća** za $t \geq 0$, a $V \geq 0$. Strogo rastuća transformacija ne mijenja *položaj* maksimuma, samo njegovu vrijednost. Isto vrijedi za množenje pozitivnom konstantom. Ovaj postupak (uklanjanje korijena kvadriranjem) koristit ćemo često — vidi i Vježbe 2, gdje se isto radi s normama.

Derivacija:

$$\frac{dF}{d\varphi} = 4\varphi^3 - \frac{3}{2\pi^2} \varphi^5 = 0$$

Provjera: $F(\varphi) = \varphi^4 - \frac{\varphi^6}{4\pi^2}$, pa je $F' = 4\varphi^3 - \frac{6\varphi^5}{4\pi^2} = 4\varphi^3 - \frac{3\varphi^5}{2\pi^2} \quad \checkmark$

Iz toga slijedi:

$$\varphi^2 = \frac{8}{3}\pi^2 \quad \rightarrow \quad \varphi = \sqrt{\frac{2}{3}} \cdot 2\pi \text{ rad} = 293,939^\circ$$

Međukoraci: podijelimo jednadžbu s φ^3 (za $\varphi \neq 0$): $4 = \frac{3}{2\pi^2} \varphi^2$, dakle $\varphi^2 = \frac{8\pi^2}{3}$. Zatim $\varphi = \sqrt{\frac{8\pi^2}{3}} = 2\pi \sqrt{\frac{2}{3}}$. Brojčano: $\sqrt{2/3} = 0,8165$, pa $\varphi = 0,8165 \cdot 6,2832 = 5,1302$ rad; u stupnjevima $5,1302 \cdot \frac{180}{\pi} = 293,94^\circ \quad \checkmark$

1.8.4 Maksimizacija volumena lijevka II

[str. 50]

Problem. Kakav oblik treba imati lijevak (stožac) da kod **zadane površine plašta** ima što veći volumen?

Površina plašta:

$$A = 2\pi r \cdot R/2 = \pi Rr \quad \rightarrow \quad r = \frac{A}{\pi R}$$

(Ovdje je r izvodnica stošca, R polumjer baze.)

Volumen:

$$V = \frac{\pi R^2}{3} \sqrt{r^2 - R^2} = \frac{\pi R^2}{3} \sqrt{\frac{A^2}{\pi^2 R^2} - R^2}, \quad V = \frac{R}{3} \sqrt{A^2 - \pi^2 R^4}$$

Raspis zadnjeg koraka: izlučimo $\frac{1}{\pi^2 R^2}$ iz korijena:

$$\sqrt{\frac{A^2}{\pi^2 R^2} - R^2} = \frac{1}{\pi R} \sqrt{A^2 - \pi^2 R^4} \quad (1.24)$$

$$V = \frac{\pi R^2}{3} \cdot \frac{1}{\pi R} \sqrt{A^2 - \pi^2 R^4} = \frac{R}{3} \sqrt{A^2 - \pi^2 R^4} \quad \checkmark \quad (1.25)$$

Volumen V bit će maksimalan kad i $(3V)^2$, pa je (isti trik kao prije):

$$F(R) = (3V)^2 = A^2 R^2 - \pi^2 R^6$$

Derivacija:

$$\frac{dF}{dR} = 2A^2 R - 6\pi^2 R^5 = 0 \quad \rightarrow \quad A = \sqrt{3\pi^2 R^4} = \pi\sqrt{3} R^2$$

Međukorak: podijelimo s $2R$ ($R \neq 0$): $A^2 = 3\pi^2 R^4$, pa korjenovanjem $A = \pi R^2 \sqrt{3}$.

Iz $R^2 = \frac{A}{\pi\sqrt{3}}$ i $h^2 = r^2 - R^2 = \frac{A^2}{\pi^2 R^2} - R^2$, slijedi:

$$\frac{h^2}{R^2} = 2 \quad \rightarrow \quad \frac{h}{R} = \sqrt{2}$$

Raspis:

$$\frac{h^2}{R^2} = \frac{1}{R^2} \left(\frac{A^2}{\pi^2 R^2} - R^2 \right) = \frac{A^2}{\pi^2 R^4} - 1 \stackrel{A^2=3\pi^2 R^4}{=} \frac{3\pi^2 R^4}{\pi^2 R^4} - 1 = 3 - 1 = 2 \quad \checkmark$$

Zaključak: optimalan lijevak ima omjer visine i polumjera baze $h/R = \sqrt{2}$.

1.8.5 Dimenzioniranje otvora vrata

[str. 51]

Problem. Kako visoka moraju biti vrata tornja (h) da se ljestve duljine L mogu uvući u toranj?

Geometrija sa slajda: zid tornja je okomit; ljestve $\overline{AB} = L$ naslonjene su tako da im donji kraj B klizi po podu na udaljenosti x od zida, a gornji kraj A je uz vanjski zid; a je vodoravni odmak zida, y je visina na kojoj ljestve prelaze preko brida vrata, a h je tražena visina vrata.

Rješenje: traži se **maksimalna visina y za vrijeme uvlačenja** ljestvi u toranj.

Iz sličnosti trokuta (1):

$$\frac{y}{x-a} = \frac{\sqrt{L^2 - x^2}}{x} \quad \rightarrow \quad y = \frac{x-a}{x} \sqrt{L^2 - x^2} \quad (1.26)$$

(Ovdje je $\sqrt{L^2 - x^2}$ visina gornjeg kraja ljestvi A nad podom — Pitagorin poučak na trokutu s hipotenuzom L i vodoravnim katetom x .)

Derivacija i stacionarna točka (2):

$$\frac{dy}{dx} = \frac{aL^2 - x^3}{x^2 \sqrt{L^2 - x^2}} = 0 \quad \rightarrow \quad x_m = \sqrt[3]{aL^2} \quad (1.27)$$

Međukorak: razlomak je nula kad je brojnik nula: $aL^2 - x^3 = 0 \Rightarrow x^3 = aL^2 \Rightarrow x = \sqrt[3]{aL^2}$.

Uvrštenjem (2) u (1):

$$h \geq y_m = \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{3/2} \cdot L$$

Raspis uvrštavanja (na slajdu nije prikazan): uz $x_m = a^{1/3}L^{2/3}$,

$$\frac{a}{x_m} = \frac{a}{a^{1/3}L^{2/3}} = \frac{a^{2/3}}{L^{2/3}} = \left(\frac{a}{L} \right)^{2/3} \quad (1.28)$$

$$\sqrt{L^2 - x_m^2} = \sqrt{L^2 - a^{2/3}L^{4/3}} = L\sqrt{1 - \left(\frac{a}{L} \right)^{2/3}} \quad (1.29)$$

$$y_m = \left(1 - \frac{a}{x_m} \right) \sqrt{L^2 - x_m^2} = \left[1 - \left(\frac{a}{L} \right)^{2/3} \right] \cdot L \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{1/2} = L \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{3/2} \quad \checkmark \quad (1.30)$$

Brojčani primjer sa slajda:

$$a = 2,7 \text{ m}; \quad L = 12,5 \text{ m} \rightarrow y_m = 6,4 \text{ m}; \quad x_m = 7,5 \text{ m}$$

Provjera računa:

$$\frac{a}{L} = \frac{2,7}{12,5} = 0,216 = 0,6^3 \Rightarrow \left(\frac{a}{L} \right)^{2/3} = 0,6^2 = 0,36 \quad (1.31)$$

$$y_m = 12,5 (1 - 0,36)^{3/2} = 12,5 \cdot 0,64^{3/2} = 12,5 \cdot 0,8^3 = 12,5 \cdot 0,512 = 6,4 \text{ m} \quad \checkmark \quad (1.32)$$

$$x_m = \sqrt[3]{2,7 \cdot 12,5^2} = \sqrt[3]{2,7 \cdot 156,25} = \sqrt[3]{421,875} = 7,5 \text{ m} \quad \checkmark \quad (1.33)$$

Slajd uz to prikazuje graf $y(x)$ za te brojke: krivulja kreće od nule pri $x = a = 2,7$, raste do vrha $y \approx 6,4$ pri $x = 7,5$, i pada natrag na nulu pri $x = L = 12,5$ (tada su ljestve okomite uz zid).

1.8.6 Optimalna ograda

[str. 52]

Problem. Površinu od 1 ha treba ograditi na način prema skici (pravokutnik $x \times y$ s jednim unutarnjim pregradnim zidom duljine y). Troškovi postavljanja ograde proporcionalni su duljini ograde. Odrediti dimenzije x i y tako da troškovi budu minimalni.

Ciljna funkcija je duljina ograde:

$$L = 2x + 3y \quad (1.34)$$

Odakle: vanjski opseg je $2x + 2y$, a unutarnja pregrada je još jedan komad duljine y ; ukupno $2x + 3y$.

Ograničenje je površina:

$$A = xy = 10\,000 \text{ m}^2 \rightarrow h = xy - 10\,000 = 0 \quad (1.35)$$

(1 ha = 10 000 m². Zapis $h = xy - 10\,000 = 0$ je upravo standardna forma ograničenja jednakosti iz odjeljka 1.2.)

Uvrštenjem (2) u (1), tj. $y = 10\,000/x$, ciljna funkcija postaje:

$$L = 2x + \frac{3 \cdot 10\,000}{x} \quad \rightarrow \quad \frac{dL}{dx} = 2 - \frac{30\,000}{x^2} = 0$$

pa je:

$$x_{\text{opt}} = 100\sqrt{\frac{3}{2}}, \quad y_{\text{opt}} = 100\sqrt{\frac{2}{3}}, \quad \left(\frac{x}{y}\right)_{\text{opt}} = \frac{3}{2}$$

Raspis:

$$2 = \frac{30\,000}{x^2} \Rightarrow x^2 = 15\,000 \Rightarrow x = \sqrt{15\,000} = \sqrt{10\,000 \cdot 1,5} = 100\sqrt{\frac{3}{2}} \approx 122,47 \text{ m} \quad (1.36)$$

$$y = \frac{10\,000}{x} = \frac{10\,000}{100\sqrt{3/2}} = \frac{100}{\sqrt{3/2}} = 100\sqrt{\frac{2}{3}} \approx 81,65 \text{ m} \quad (1.37)$$

$$\frac{x}{y} = \frac{100\sqrt{3/2}}{100\sqrt{2/3}} = \sqrt{\frac{3/2}{2/3}} = \sqrt{\frac{9}{4}} = \frac{3}{2} \quad \checkmark \quad (1.38)$$

Interpretacija: omjer stranica nije 1:1 (kao kod običnog pravokutnika bez pregrade) nego 3:2 — jer pregradni zid „poskupljuje” smjer y , pa se isplati taj smjer skratiti.

1.9 Vrste optimizacije konstrukcija

[str. 53--56]

1.9.1 Dimenzionalna optimizacija (*size optimization*)

[str. 53]

Optimiranje **dimenzija** objekata **poznate strukture i oblika**.

Primjeri:

- dimenzije elemenata nosivih konstrukcija (presjeci štapova, debljine limova, ...)
- dimenzije članova mehanizama

1.9.2 Optimiranje oblika (*shape optimization*)

[str. 54]

Osnovni **oblik** objekta mijenja se postupkom optimizacije ovisno o zadanim parametrima problema (alat je često **FEM** analiza — metoda konačnih elemenata).

1.9.3 Topološka optimizacija (*topology optimization*)

[str. 55--56]

Traži se optimalna **topologija (struktura)** konstrukcije u zadanoj domeni.

Na slajdovima 55 i 56 topološka optimizacija je numerirana kao „2.” (očiti tipfeler u prezentaciji — dvije uzastopne stavke nose broj 2). Sadržajno je to **treća** vrsta.

Razlika u tri riječi: *dimenzionalna* mijenja **brojeve** (koliko je štap deo), *oblikovna* mijenja **konture** (kako je rub zaobljen), *topološka* mijenja **raspored materijala** (gdje uopće ima materijala, a gdje su rupe). Topološka je najslobodnija i najteža.

1.10 Postavka problema

[str. 57--58]

Teorem 1.1: Ključna poruka slajda 57

Pravilna definicija, formulacija i točna matematička postavka optimizacijskog problema je često **najveći korak** prilikom rješavanja problema.
Iz formulacije problema treba raspoznati o **kojoj se vrsti optimizacije radi**.

1.10.1 Jednostavan primjer koji to ilustrira

[str. 57--58]

Problem. Površinu uz postojeću prirodnu ogradu (zid, stijena i sl.) treba ograditi s raspoloživom duljinom žičane ograde L tako da ogradena površina bude **maksimalna**.

Na slajdu su prikazana **tri oblika**:

- **a)** pravokutnik naslonjen na zid (jedna stranica x uz zid, dvije stranice y),
- **b)** polukrug polumjera r naslonjen na zid,
- **c)** pola pravilnog mnogokuta (n -terokut, konkretno $n = 8$) naslonjenog na zid.

Poanta (sa slajda):

Iz gornje formulacije nije jasno da li se oblik ograde može odabrati po volji ili se postavlja i neki drugi zahtjevi. Svaki od pokazanih oblika daje za istu duljinu ograde svoje rješenje, pri čemu se oblikom b) ograđuje **najveća** površina, a oblikom a) **najmanja**. Međutim, ako se radi o ogradi pašnjaka koju treba seliti duž zida, tada je oblik a) u „tehnološkoj” prednosti, jer se iskoristi sva raspoloživa površina.

Zaključak: ista rečenica („ogradi maksimalnu površinu”) daje **tri različita optimizacijska problema**, ovisno o tome što smo prešutno pretpostavili. Zato je formulacija najvažniji korak.

1.10.2 Brojčana usporedba triju oblika, $L = 500$ m

[str. 58]

Oblik b) — polukrug

$$L = r\pi \rightarrow A = \frac{\pi r^2}{2} = \frac{L^2}{2\pi} = \frac{500^2}{2\pi} = 39\,788,7 \text{ m}^2$$

Raspis: iz $L = r\pi$ slijedi $r = L/\pi$, pa je $A = \frac{\pi}{2} \cdot \frac{L^2}{\pi^2} = \frac{L^2}{2\pi} = \frac{250\,000}{6,2832} = 39\,788,7 \text{ m}^2 \checkmark$

Oblik c) — polovica pravilnog n -terokuta, $n = 8$ (osmerokut)

$$L = \frac{n}{2}a \rightarrow \varphi = \frac{2\pi}{n}; \quad a = 2r \sin \frac{\varphi}{2} = 2r \sin \frac{\pi}{n}$$

(a je duljina jedne stranice, φ središnji kut nad jednom stranicom, r polumjer opisane kružnice. Uz zid je polovica mnogokuta, pa ograda ima $n/2$ stranica.)

$$r = \frac{L}{n \cdot \sin \frac{\pi}{n}}$$

Raspis: iz $L = \frac{n}{2}a = \frac{n}{2} \cdot 2r \sin \frac{\pi}{n} = n r \sin \frac{\pi}{n}$ slijedi $r = \frac{L}{n \sin(\pi/n)}$ $\checkmark$

$$A = \frac{1}{2} a r \cos \frac{\varphi}{2} \cdot \frac{n}{2} = \frac{n}{4} \cdot 2 \frac{L}{n} \cdot \frac{L}{n \cdot \sin \frac{\pi}{n}} \cos \frac{\pi}{n} = \frac{L^2}{2n \cdot \tan \frac{\pi}{n}}$$

$$A = \frac{500^2}{2 \cdot 8 \cdot \tan \frac{\pi}{8}} = 37\,722,1 \text{ m}^2 \quad \left(\text{za } n \rightarrow \infty, \lim_{n \rightarrow \infty} \left(n \cdot \tan \frac{\pi}{n} \right) = \pi \right)$$

Provjera brojki: $\tan(\pi/8) = \tan 22,5^\circ = 0,41421$, pa je $2 \cdot 8 \cdot 0,41421 = 6,6274$ i $A = 250\,000/6,6274 = 37\,722 \text{ m}^2 \checkmark$

Značenje granice: kad $n \rightarrow \infty$, $n \tan(\pi/n) \rightarrow \pi$, pa formula za mnogokut prelazi u $A \rightarrow L^2/(2\pi)$ — točno rezultat polukruga b). Mnogokut s mnogo stranica je praktički polukrug, što potvrđuje da je b) najbolji oblik.

Oblik a) — pravokutnik

$$L = x + 2y \rightarrow x = L - 2y \quad (\text{ograničenje jednakosti})$$

$$A = xy = (L - 2y)y; \quad \frac{dA}{dy} = L - 4y = 0 \rightarrow y = \frac{L}{4} = 125 \text{ m}; \quad x = \frac{L}{2} = 250 \text{ m}$$

Raspis derivacije: $A = Ly - 2y^2$, pa je $\frac{dA}{dy} = L - 4y \checkmark$

$$A = xy = 250 \cdot 125 = 31\,250 \text{ m}^2 \quad (x : y = 2 : 1)$$

Rangiranje: b) $39\,788,7 >$ c) $37\,722,1 >$ a) $31\,250 \text{ m}^2$. Razlika između najboljeg i najlošijeg oblika je oko **27 %** — a sve uz istu duljinu ograde. Odabir *strukture* (oblika) donosi veći dobitak nego optimiranje *dimenzija* unutar zadane strukture. To je uvod u sljedeći odjeljak.

1.11 Projektiranje kao proces

1.11.1 Slijed projektiranja

[str. 59]

Projektiranje tehničkog sustava ostvaruje se u **dva koraka**:

1. **izbor strukture** sustava, odnosno **strukturne sinteze**;
2. **izbor brojčanih vrijednosti parametara** odabrane strukture (sinteza parametara ili **dimenzionalna sinteza**).

Strukturalna sinteza jest (glavni) zadatak **stvaralačkog djelovanja inženjera** koji je općenito teško ili nemoguće automatizirati (algoritmizirati).

To se izravno poklapa s primjerom ograde: odabir između oblika a), b), c) je strukturalna sinteza (kreativni čin), a računanje $x = 250$, $y = 125$ je dimenzionalna sinteza (algoritamski dio) — i baš je taj drugi dio ono što ovaj kolegij formalizira.

1.11.2 Strukturalna sinteza

[str. 60]

Struktura projektiranog tehničkog sustava ili objekta (**topologija konstrukcije**) određena je poznatim **skupom elemenata strukture** i **vezama među njima**.

Poteškoće koje se pojavljuju u formalizaciji problema strukturalne sinteze:

- nemjerljive karakteristike elemenata strukture;
- formalno nedefinirane veze između pojedinih elemenata i zahtjeva;
- kvalitativni kriteriji;
- neformalan opis funkcioniranja projektiranog objekta;
- zahtjevi koji se odnose na funkcioniranje objekta.

Temelj sinteze tehničkih sustava jest: skup znanja i iskustva projektanata, intuicija, kreativnost, literatura, izvedeni projekti, sheme mogućih rješenja, metode projektiranja, računalna i programska podrška.

Opis elemenata strukture, opis veza među njima kao i formiranje matematičkog modela strukture definira se pomoću prikladnog (konačnog) skupa veličina: to su **projektni parametri**.

1.11.3 Cilj projektiranja?

[str. 61--67]

1. Gradnja sustava s besprijekornim funkcioniranjem se **danās podrazumijeva**.
2. U uvjetima konkurencije od presudne je važnosti projektirati **najbolji ili što bolji** sustav (objekt ili proizvod).
3. Kriteriji po kojima je neki sustav najbolji su različiti, primjerice: **cijena, težina, efikasnost, oblik, praktičnost, kompleksnost, originalnost, pouzdanost, trajnost** i sl.
4. **Izbor dominantnog kriterija** predstavlja **stratešku odluku** na početku samog procesa projektiranja. Kvaliteta rješenja ocjenjuje se **kvantitativnom** usporedbom odabranih kriterija, koji stoga moraju biti **funkcijom projektnih parametara**.

5. Izbor projektnih parametara najčešće **nije slobodan**, već njihove veličine moraju zadovoljiti neke unaprijed zadane uvjete ili **ograničenja**. Također trebaju biti ispunjeni uvjeti **međusobne ovisnosti** parametara koji slijede iz strukture projektiranog sustava.
6. Projektiranje je stoga **iterativni proces** određivanja strukture i projektnih parametara projektiranog sustava, konstrukcije ili proizvoda.
7. Konačnim projektnim rješenjem trebaju se ispuniti **svi** kriteriji i tehnički zahtjevi projekta.

Točka 4 je zapravo definicija **funkcije cilja** rečena inženjerskim jezikom („kriterij mora biti funkcija projektnih parametara”), a točka 5 definicija **ograničenja**. Time se zatvara krug s odjeljkom 1.2.

1.11.4 Proces projektiranja

[str. 68]

Prema primijenjenim metodama i projektnim zahtjevima proces projektiranja može biti:

- a) **Proces konvencionalnog projektiranja.** Osnovni cilj: besprijeckorno funkcioniranje sustava ili proizvoda u okviru uvjeta postavljenih projektnim zadatkom (*funkcionalno projektiranje*). Ovaj proces baziran je na **iskustvu i intuiciji**.
- b) **Proces optimalnog projektiranja.** Pored besprijeckornog funkcioniranja sustava ili proizvoda, **jedan ili više projektnih kriterija treba biti ispunjen na optimalan način**. Postupak optimalnog projektiranja zahtijeva **strogu matematičku formulaciju problema** — postavku matematičkog modela ili optimizacijskog problema.

1.11.5 Elementi optimizacijskog modela: projektni parametri i varijable

[str. 69--70]

Definicija 1.6: Projektni parametri

Projektni parametri su veličine pomoću kojih se **jednoznačno definiraju dimenzije i svojstva** konstrukcije ili projektiranog sistema.

Projektni parametri dijele se na **konstantne projektne parametre** i **projektne varijable**.

Konstantni projektni parametri se u postupku optimizacije **ne mijenjaju**, a mogu se podijeliti na dvije vrste:

- **taktički projektni parametri** (z) — zadani su **projektnim zadatkom** i ne mogu se mijenjati u cijelom procesu projektiranja. Oni su konstante strukturalne i dimenzionalne sinteze konstrukcije, tj. predstavljaju **taktičke performanse** projektiranog sustava.
- **tehnički projektni parametri** (y) — projektne su konstante **po zamisli projektanta**, i to prvenstveno iz **konstrukcijskih ili tehnoloških** razloga.

Hijerarhija sa slajda 70:

PROJEKTNİ PARAMETRI	
PROJEKTNE VARIJABLE	PROJEKTNE KONSTANTE
x	y, z
	TEHNIČKI y TAKTIČKI z
	(odabrani od pro- (zadani projekt- jektanta) nim zadatkom)

Dodatne tvrdnje sa slajda 70:

- Tehnički parametri su konstante **samo kod dimenzionalne sinteze već poznate strukture (topologije)** objekta.
- Projektant može mijenjati broj tehničkih parametara njihovim **prebacivanjem u projektne varijable i obrnuto**.
- Projektni parametri koji se **mijenjaju** u postupku sinteze nazivaju se **projektnim varijablama** (x).
- **Suma broja projektnih varijabli i tehničkih parametara** u postupku optimizacije iste strukture sistema je **konstantna**.
- Ispravan izbor projektnih parametara i odgovarajuća matematička formulacija problema glavne su poteškoće i preduvjeti uspješnog postupka optimalnog projektiranja.

Vektor x iz standardne forme = projektne varijable. Parametri y i z ne pojavljuju se kao nepoznanice, nego kao **brojevi** u izrazima za f , h i g . U primjeru ograde: x i y (dimenzije) su projektne varijable, a 10 000 m² je taktički parametar (zadan zadatkom).

1.11.6 Optimizacijski model — pravila izbora parametara

[str. 71--77]

Kod izbora projektnih parametara važno je sljedeće:

1. Projektant treba dobro **proučiti problem** i matematički ga opisati pomoću projektnih varijabli;
2. Projektni parametri trebaju biti **nezavisni**;
3. Problem treba opisati sa **što manje** projektnih parametara;
4. Matematičku formulaciju problema treba u **početnoj fazi** provesti sa **što manjim brojem tehničkih parametara**; to je važno radi fleksibilnosti algoritma i otklanjanja eventualnih pogrešnih procjena o utjecaju nekih tehničkih parametara na rezultat. U **kasnijoj fazi** mogu se neke od varijabli odabrati kao konstante, i to:
 - iz **konstrukcijskih ili tehnoloških** razloga;
 - jer je utvrđeno da **ne utječu bitno** na konačni rezultat optimizacije;
 - jer je utvrđeno da optimalno rješenje odgovara **uvijek vrijednosti neke varijable na rubu ograničenja**.

Zašto pravilo 2 (nezavisnost)? Ako su dvije varijable povezane (npr. uvedemo i promjer r i promjer $d = 2r$), ograničenje $d = 2r$ postaje suvišna jednadžba, a problem numerički degenerira (rješenje nije jedinstveno u parametrima). Bolje je odabrati samo jednu od njih.

Zašto pravilo 3 (što manje parametara)? Broj varijabli n izravno određuje dimenziju prostora u kojem tražimo optimum i time složenost rješavanja.

Zadnja alineja pravila 4 najavljuje pojam **aktivnog ograničenja** iz poglavlja 3: ako znamo da optimum uvijek leži na rubu, možemo tu nejednakost zamijeniti jednakošću i eliminirati varijablu.

1.12 Neki korisni „trikovi“

[str. 79]

Ovaj slajd zatvara predavanje 1 i ponavlja se na početku predavanja 2.

1.12.1 Minimizacija $\Leftrightarrow$ maksimizacija

$$\begin{array}{ccc} \max_x f(x) & \Longleftrightarrow & \min_x -f(x) \\ \text{uz ogr. } x \in \mathcal{F} & & \text{uz ogr. } x \in \mathcal{F} \end{array} \quad (1.39)$$

Zašto to vrijedi. Ako f postiže svoju **najveću** vrijednost u točki x^* , onda $-f$ u istoj toj točki postiže svoju **najmanju** vrijednost (jer množenje s -1 „okreće“ os vrijednosti). Dakle:

- **argument** je isti: $\arg \max f = \arg \min(-f)$,
- **vrijednosti** su suprotne: $\max f = -\min(-f)$ — na to treba paziti kad izvještavate optimalnu vrijednost!

Zbog ovog trika **cijela teorija se može razviti samo za minimizaciju**, što i činimo u standardnoj formi iz odjeljka 1.2.

1.12.2 Provjera je li dozvoljeni skup prazan (problem dopustivosti)

Pitanje: Je li skup $\mathcal{F} = \{x \mid g_i(x) \leq 0, i = 1, \dots, p\}$ prazan? Ako nije, kako naći neki $x \in \mathcal{F}$?

Rješenje: riješi optimizacijski problem

$$\begin{array}{ccc} \min_{x,t} & t & \\ \text{uz ograničenja} & g_i(x) \leq t, & i = 1, \dots, p \end{array} \quad (1.40)$$

Neka je t^*, x^* rješenje. **Ako je $t^* \leq 0$, tada $\mathcal{F}$ nije prazan skup i $x^* \in \mathcal{F}$.**

Detaljno objašnjenje (jer je ideja lukavija nego što izgleda):

- Uvodimo **novu, pomoćnu varijablu** $t \in \mathbb{R}$. Sada minimiziramo po paru (x, t) , dakle problem ima $n + 1$ varijablu umjesto n .

- Za *bilo koji* x uvijek možemo naći dovoljno velik t da svi uvjeti $g_i(x) \leq t$ budu zadovoljeni (npr. $t = \max_i g_i(x)$). Zato **novi problem nikad nije nedopustiv** — uvijek ima rješenje, za razliku od polaznog.
- Funkcija cilja je samo t : guramo t što niže. Za fiksni x najmanji dopušteni t je točno $\max_i g_i(x)$ — „najgore prekršeno ograničenje”. Dakle problem (1.40) zapravo rješava

$$\min_x \max_i g_i(x)$$

tj. traži x koji **najmanje krši najgore ograničenje**.

- **Ako je $t^* \leq 0$:** tada je $g_i(x^*) \leq t^* \leq 0$ za sve i , dakle x^* zadovoljava **sva** izvorna ograničenja $\rightarrow x^* \in \mathcal{F}$ i skup nije prazan. Bonus: dobili smo i konkretnu dopuštenu točku.
- **Ako je $t^* > 0$:** ne postoji nijedan x za koji su sva $g_i(x) \leq 0$ (jer bi za takav x vrijednost $t = 0$ bila dopuštena i dala manji cilj od t^*) $\rightarrow \mathcal{F}$ **je prazan**.

Ovaj se postupak zove **faza I** (engl. *phase I*) i standardni je prvi korak svakog ozbiljnog optimizacijskog algoritma: prije nego što tražimo *najbolju* dopuštenu točku, moramo naći *bilo koju*. Uočite i tehniku: **uvodenje pomoćne varijable koja „gura” min--max u obični min** — istu ćemo tehniku sresti kod norma (Vježbe 2, poglavlje 2) i kod robusnog optimiranja (poglavlje 8).

1.13 Sažetak poglavlja

Što morate znati napamet nakon ovog poglavlja:

1. **Standardna forma:** $\min f(x)$ uz $h(x) = 0$, $g(x) \leq 0$; što je x , f , h , g , i što je dozvoljeni skup $\mathcal{F} = \{x \mid h(x) = 0, g(x) \leq 0\}$.
2. **Definicija optimalnog rješenja x^*** (dopustivo i najmanji f).
3. **Nivo krivulja** $\{x \mid f(x) = c\}$ i kako se iz slike nivo krivulja + dozvoljenog skupa očita optimum (odjeljak 1.3).
4. **Prevođenje u standardnu formu:** premještanje konstante na lijevu stranu, okretanje „ $\geq$ ” množenjem s -1 , $\max f \Leftrightarrow \min(-f)$.
5. **Recept klasične analize** (eliminacija ograničenja jednakosti uvrštavanjem $+ F' = 0$ + provjera s F'') — i svijest da on ne funkcionira općenito, zbog čega nam trebaju poglavlja 3 i 4.
6. **Problem dopustivosti** (1.40) i njegova interpretacija.

Terminologija (hrvatski $\leftrightarrow$ engleski):

Hrvatski	Engleski
projektne varijable / varijable odluke	decision variables
funkcija cilja / ciljna funkcija	objective function
ograničenja jednakosti	equality constraints
ograničenja nejednakosti	inequality constraints
dozvoljeni skup / dozvoljeno područje	feasible set
nivo krivulja	level curve / contour
dimenzionalna optimizacija	size optimization
optimiranje oblika	shape optimization
topološka optimizacija	topology optimization

POGLAVLJE 2

Definicije, klasifikacija, konveksnost

Poglavlje je u izradi.

POGLAVLJE 3

Uvjeti optimalnosti

Poglavlje je u izradi.

POGLAVLJE 4

Lagrangeova dualnost

Poglavlje je u izradi.

POGLAVLJE 5

Linearno i kvadratno programiranje

Poglavlje je u izradi.

POGLAVLJE 6

Konicno kvadratno i semidefinitno programiranje

Poglavlje je u izradi.

POGLAVLJE 7

Dinamicki sustavi, Ljapunov, disipativnost

Poglavlje je u izradi.

POGLAVLJE 8

Robusno optimiranje

Poglavlje je u izradi.