

Optimizacijske metode u razvoju i upravljanju sustava

Skripta za učenje

Cjelovita obrada gradiva — od nule do ispita

Skripta je sastavljena **isključivo** iz materijala kolegija: predavanja 01--08 i vježbi 1--5.

Svaka definicija, formula, izvod i postupak rješavanja preuzeti su iz izvornika i raspisani korak po korak. Ništa nije nadopunjeno iz drugih izvora; sva odstupanja od izvornika izričito su označena.

Sveučilište u Zagrebu — Fakultet strojarstva i brodogradnje

Nositelj kolegija: prof. dr. sc. Andrej Jokić

Kako koristiti ovu skriptu

Skripta pretpostavlja **nikakvo** predznanje iz optimizacije. Svaki pojam objašnjen je pri prvom spominjanju: što je, kako se označava i zašto je bitan.

Kako je gradivo posloženo. Poglavlja slijede redoslijed predavanja (01--08). Zadaci s vježbi *nisu* skupljeni na kraju, nego su ugrađeni odmah iza teorije koju koriste. Zadatak koji dodiruje više tema razlomljen je po podzadacima, pa svaki podzadatak stoji uz svoju teoriju.

Tipovi okvira u tekstu:

- **Definicija** — pojam koji morate znati točno onako kako je zapisan.
- **Teorem** — tvrdnja iz predavanja, s objašnjenjem što znači i kako se koristi.
- **Zadatak** — zadatak s vježbi, s potpunim rješenjem raspisanim korak po korak.
- **Napomena** — upozorenje, česta greška ili tipfeler u izvorniku.
- **Kako to nacrtati rukom** — inkrementalne upute za crtanje grafa, korak po korak, do potpune slike.

Oznake stranica. Uz naslove i tvrdnje stoji oznaka poput [str. 15] koja pokazuje stranicu izvornog PDF-a odakle je sadržaj preuzet, da možete provjeriti original.

Napomena o izvorniku. Prezentacije su rađene u Beameru, pa se većina slajdova pojavljuje u više „inkrementalnih” verzija (isti slajd koji se gradi natuknicu po natuknicu). Takvi nizovi ovdje su sažeti u jedan potpuni odjeljak, ali nijedna natuknica nije izostavljena.

Sadržaj

Kako koristiti ovu skriptu	1
1 Uvod	7
1.1 Što je optimizacija?	7
1.2 Optimizacijski problem — standardna forma	8
1.2.1 Zapis s pojedinačnim ograničenjima	8
1.2.2 Objašnjenje svakog simbola od nule	8
1.2.3 Kompaktni („vektorski”) zapis	9
1.2.4 Što je optimalno rješenje	10
1.2.5 Dozvoljeni skup	10
1.3 Uvodni primjer s potpunim grafom	10
1.3.1 Postavka problema	10
1.3.2 Prepoznavanje elemenata standardne forme	11
1.3.3 Rješenje	11
1.3.4 Graf	12
1.4 Gdje i zašto se optimira?	14
1.4.1 Optimiranje rada sustava / procesa („on-line”)	14
1.4.2 U fundamentalnim fizikalnim zakonima / problemima	15
1.4.3 U prirodi	15
1.4.4 Optimalno projektiranje	15
1.5 Sadržaj kolegija i ishodi učenja	15
1.6 Motivacijski primjeri iz prakse	16
1.6.1 Planiranje proizvodnje u elektroenergetskoj mreži	16
1.6.2 Upravljanje tokovima snage i energijom u hibridnom automobilu	16
1.6.3 Prediktivno upravljanje dinamičkim sustavima	17
1.6.4 Optimalno upravljanje — pozicioniranje glave tvrdog diska	17
1.6.5 Ravnotežni položaj sustava u potencijalnom polju	17
1.6.6 Primjeri iz prirode	18
1.6.7 Raspodjela vjetroturbina u vjetroparku	18
1.7 Primjer: problem proizvodnje i distribucije robe	18
1.7.1 Opis problema	19
1.7.2 Projektne varijable	19

1.7.3	Potpuna formulacija	19
1.8	Klasični primjeri optimiranja s potpunim rješenjima	20
1.8.1	Optimalno iskorištavanje materijala — posuda iz limene ploče	20
1.8.2	Minimizacija troškova izgradnje — tlocrt kuće	21
1.8.3	Maksimizacija volumena lijevka I	22
1.8.4	Maksimizacija volumena lijevka II	23
1.8.5	Dimenzioniranje otvora vrata	24
1.8.6	Optimalna ograda	25
1.9	Vrste optimizacije konstrukcija	26
1.9.1	Dimenzionalna optimizacija (<i>size optimization</i>)	26
1.9.2	Optimiranje oblika (<i>shape optimization</i>)	26
1.9.3	Topološka optimizacija (<i>topology optimization</i>)	26
1.10	Postavka problema	27
1.10.1	Jednostavan primjer koji to ilustrira	27
1.10.2	Brojčana usporedba triju oblika, $L = 500$ m	27
1.11	Projektiranje kao proces	28
1.11.1	Slijed projektiranja	29
1.11.2	Strukturalna sinteza	29
1.11.3	Cilj projektiranja?	29
1.11.4	Proces projektiranja	30
1.11.5	Elementi optimizacijskog modela: projektni parametri i varijable	30
1.11.6	Optimizacijski model — pravila izbora parametara	31
1.12	Neki korisni „trikovi”	32
1.12.1	Minimizacija $\Leftrightarrow$ maksimizacija	32
1.12.2	Provjera je li dozvoljeni skup prazan (problem dopustivosti)	32
1.13	Sažetak poglavlja	33
2	Definicije, klasifikacija, konveksnost	35
2.1	Podsjetnik: standardna forma i „trikovi”	35
2.2	Osnovni matematički alat	35
2.2.1	Vektori i matrice	35
2.2.2	Funkcije	36
2.2.3	Linearne funkcije	37
2.2.4	Matrični zapis linearne funkcije	38
2.2.5	Afine funkcije	39
2.3	Nivo krivulje	40

2.4	Skalarni produkt vektora	42
2.5	Klasifikacije optimizacijskih problema	43
2.5.1	Prema postojanju ograničenja	43
2.5.2	Prema karakteru projektnih varijabli / dozvoljenom skupu	44
2.5.3	Prema karakteristikama funkcije cilja i ograničenja	44
2.5.4	Još karakterizacija	45
2.6	Primjeri klasa problema	45
2.6.1	Primjer I — diskretan optimizacijski problem	45
2.6.2	Primjer II — kontinuiran optimizacijski problem	46
2.6.3	Primjer III — cjelobrojno optimiranje: broj stabilnosti grafa	46
2.6.4	Primjer IV — „mixed integer programming”	47
2.7	Rješenje optimizacijskog problema	49
2.7.1	Lokalni i globalni minimizator	49
2.7.2	Infimum i supremum	50
2.8	Derivacija i Jakobijan	51
2.8.1	Linearizacija (aproksimacija prvog reda)	51
2.8.2	Primjer Jakobijana	52
2.9	Gradijent	53
2.9.1	Zašto gradijenti u optimizaciji?	53
2.9.2	Važna svojstva gradijenta	54
2.9.3	Dokaz okomitosti	54
2.9.4	Što nam gradijent govori — formalno	55
2.10	Hessian i Taylorov teorem	55
2.11	Optimiranje bez ograničenja: uvjeti optimalnosti	56
2.12	Pozitivno i negativno definitne matrice	57
2.12.1	Primjer: određivanje definitnosti	58
2.12.2	Primjer: definitnost i minimum	59
2.12.3	Kriterij determinanti (Sylvesterov kriterij)	59
2.13	Konveksno optimiranje: skupovi	60
2.13.1	Afin skup	60
2.13.2	Konveksan skup	61
2.13.3	Konveksna kombinacija i konveksna ljuska	62
2.14	Hiperravnine i poluprostori	63
2.15	Poliedar i politop	66
2.16	Konveksne i konkavne funkcije	69
2.16.1	Primjeri konveksnih i nekonveksnih funkcija	70

2.17	Vektorske norme	71
2.18	Važna svojstva konveksnih funkcija	72
2.18.1	Dva svojstva sa slajda 67	72
2.18.2	Kvazikonveksne funkcije	72
2.18.3	Uvjeti prvog reda	73
2.18.4	Uvjeti drugog reda	74
2.19	Konveksan optimizacijski problem	74
2.20	Norme kao konveksne funkcije i praktične reformulacije	77
2.20.1	Kako izgledaju norme kao funkcije	77
2.20.2	Minimizacija norme kao konveksan optimizacijski problem	77
2.21	Sažetak poglavlja	79
3	Uvjeti optimalnosti	81
3.1	Postavka: problem s ograničenjima	81
3.2	Dozvoljeni smjerovi i smjerovi pada	81
3.3	Primjer: sedlasta funkcija na disku	83
3.3.1	Kandidat 1: $x^* = (0, 1)^\top$ — prolazi test	83
3.3.2	Kandidat 2: $x^* = (1, 0)^\top$ — pada na testu	83
3.4	Problem s jednim ograničenjem jednakosti	85
3.4.1	Postavka	85
3.4.2	Izvod uvjeta	86
3.4.3	Geometrijska slika	86
3.4.4	Uvjet kolinearnosti gradijenata	87
3.4.5	Provjera na primjeru	88
3.5	Lagrangeova funkcija	88
3.6	Više ograničenja jednakosti	89
3.6.1	Regularna točka	89
3.6.2	Lagrangeova funkcija i nužni uvjeti	90
3.6.3	Postupak traženja kandidata za optimum	90
3.6.4	Primjer: paralelepiped najvećeg volumena upisan u kuglu	91
3.7	Problem s jednim ograničenjem nejednakosti	93
3.7.1	Postavka	93
3.7.2	Izvod: dva slučaja	93
3.7.3	Nužni uvjeti za oba slučaja	94
3.7.4	Teorem: uvjeti za jedno ograničenje nejednakosti	95
3.7.5	Zapis preko Lagrangeove funkcije	95

3.7.6	Rješavanje primjera sa slajda 41	96
3.8	Više ograničenja nejednakosti	98
3.8.1	Geometrijska interpretacija	99
3.8.2	Važna iznimka: neregularna točka	99
3.9	KKT uvjeti: općenit slučaj	100
3.10	Fizikalna interpretacija Lagrangeovih množitelja	102
3.11	Ravnotežni položaj preko minimizacije potencijalne energije	103
3.11.1	Primjer 1: uteg na opruzi [str. 64]	103
3.11.2	Primjer 2: klizač na vertikalnoj vodilici [str. 65]	103
3.11.3	Primjeri 3 i 4: nivo krivulje energije s gradijentima [str. 66--67]	103
3.11.4	Primjer 5: uteg na opruzi iznad kose podloge [str. 68]	104
3.12	Sažetak poglavlja	104
4	Lagrangeova dualnost	106
5	Linearno i kvadratno programiranje	107
6	Konicno kvadratno i semidefinitno programiranje	108
7	Dinamicki sustavi, Ljapunov, disipativnost	109
8	Robusno optimiranje	110

POGLAVLJE 1

Uvod

Izvor: 01_Uvod.pdf, stranice 1--79 (obrađeno u cijelosti).

1.1 Što je optimizacija?

[str. 2--7]

Etimologija. Riječ *optimizacija* potječe od latinske riječi „**optimus**”, što znači *najbolji*.

Definicija 1.1: opisna, sa slajda

Optimizacija sadrži skup aktivnosti čiji je cilj pronaći „**najbolje rješenje**”, tzv. **optimum**, uz poštivanje zadanih **ograničenja**.

Uočite da su u toj rečenici već sadržana **tri** ključna sastojka svakog optimizacijskog problema, i vrijedi ih odmah imenovati jer ćemo se na njih vraćati kroz cijeli kolegij:

1. **Nešto se bira** — postoje veličine koje mi možemo mijenjati (npr. dimenzije konstrukcije, količina proizvedene robe, iznosi struja).
2. **Postoji mjerilo „najboljeg”** — moramo imati broj koji svakom izboru pridružuje ocjenu (cijena, masa, potrošnja...), inače riječ „najbolje” nema značenja.
3. **Ne smije se birati što god** — izbori moraju zadovoljiti ograničenja (npr. ne možemo proizvesti više nego što tvornica može, dimenzija ne može biti negativna).

Optimizacija kao matematička disciplina. Sa slajda:

Optimizacija = matematička teorija i algoritmi („matematička mašinerija”) ne samo za donošenje najboljih odluka, već često i ključna za donošenje odluka općenito (izabrati najbolje rješenje od svih mogućih *vs.* da li uopće postoji rješenje).

Ta je zagrada važnija nego što se čini. Kod složenih inženjerskih problema često uopće **nije očit** postoji li **ijedan izbor** koji zadovoljava sva ograničenja. Pitanje „postoji li dopušteno rješenje?” je samo po sebi optimizacijski problem — i to ćemo formalno riješiti već na kraju ovog poglavlja (odjeljak 1.12).

Povijest. Ljudi teže „optimiranju” od davnina, ali korijeni **moderne** optimizacije smještaju se u vrijeme **2. svjetskog rata** — tada nastaju metode *operacijskih istraživanja* (engl. *operations research*).

Terminologija. Pojam „**matematičko programiranje**” (engl. *mathematical programming*) često se koristi kao sinonim za optimiranje. Odatle nam dolaze i imena cijelih klasa problema koje ćemo obrađivati:

- *linear programming* (linearno programiranje, LP) → poglavlje 5,

- *nonlinear programming* (nelinearno programiranje),
- *quadratic programming* (kvadratno programiranje, QP) → poglavlje 5,
- ... i tako dalje.

Napomena: riječ „programiranje”

Riječ „programiranje” ovdje **nema veze s računalnim programiranjem**. Potječe iz vojnog konteksta 1940-ih, gdje je „program” značio *plan* ili *raspored* (npr. program opskrbe). To je uobičajen izvor zabune kod ljudi koji se prvi put susreću s temom.

Jezična opaska sa slajda [str. 7]. Predavač posebno ističe riječ *najoptimalnije* — kao primjer *pogrešne* upotrebe. Razlog: „optimalno” već znači *najbolje*. Ne postoji „optimalnije” ni „najoptimalnije”, kao što ne postoji „najnajbolje”. Ispravno je reći **optimalno**.

1.2 Optimizacijski problem — standardna forma

[str. 8--9]

Ovo je **središnja definicija cijelog kolegija**. Sve što slijedi u poglavljima 2–8 samo je razrada ovog zapisa.

1.2.1 Zapis s pojedinačnim ograničenjima

Definicija 1.2: Optimizacijski problem

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h_i(x) = 0, \quad i = 1, \dots, m \\ & && g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{1.1}$$

1.2.2 Objašnjenje svakog simbola od nule

Vektor projektnih varijabli x .

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- To su **projektne varijable** (engl. *decision variables*, hrv. i *varijable odluke*).
- Ovo su veličine koje **mi biramo** — one su „nepoznanice” problema.
- n je broj tih veličina. Vektor x je dakle stupac od n realnih brojeva; pišemo $x \in \mathbb{R}^n$.
- Notacija $\mathbb{R}$ označava skup realnih brojeva, a $\mathbb{R}^n$ skup svih uređenih n -torki realnih brojeva. Npr. $\mathbb{R}^2$ je obična ravnina.

Funkcija cilja f .

$$f : \mathbb{R}^n \rightarrow \mathbb{R}$$

- Naziva se **funkcija cilja**, **ciljna funkcija** ili **kriterij** (engl. *objective function*, *cost function*).
- Zapis $f : \mathbb{R}^n \rightarrow \mathbb{R}$ čita se: „ f je funkcija koja uzima vektor iz $\mathbb{R}^n$ i vraća **jedan realan broj**”. Baš zato što vraća **jedan** broj, možemo dva različita izbora x međusobno usporediti i reći koji je bolji.
- Konvencija je da **minimiziramo**. Ako želimo maksimizirati, koristimo trik iz odjeljka 1.12.

Ograničenja jednakosti h_i .

$$h_i : \mathbb{R}^n \rightarrow \mathbb{R}, \quad i = 1, \dots, m$$

- Engl. *equality constraints*.
- Uvjet $h_i(x) = 0$ mora biti zadovoljen **točno**, bez ikakvog odstupanja.
- Tipično dolaze iz fizikalnih zakona ili definicijskih veza (npr. „površina mora biti točno A ”, „proizvodnja mora biti jednaka potrošnji”).
- m je broj ograničenja jednakosti.

Ograničenja nejednakosti g_j .

$$g_j : \mathbb{R}^n \rightarrow \mathbb{R}, \quad j = 1, \dots, p$$

- Engl. *inequality constraints*.
- Uvjet $g_j(x) \leq 0$ dopušta „rezervu”: dovoljno je da vrijednost ne prijeđe nulu.
- Tipično dolaze iz tehničkih ili resursnih ograničenja („naprezanje ne smije prijeći dopušteno”, „ne možemo proizvesti više od kapaciteta”).
- p je broj ograničenja nejednakosti.

Projektni prostor. Općenito pišemo $x \in X$, gdje je X **projektni prostor**. U svemu što slijedi u ovom kolegiju bit će $X = \mathbb{R}^n$.

1.2.3 Kompaktni („vektorski”) zapis

[str. 9]

Umjesto da nabrajamo ograničenja jedno po jedno, sve h_i složimo u jedan vektorski zapis, i isto za g_j :

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h(x) = 0 \\ &&& g(x) \leq 0 \end{aligned} \tag{1.2}$$

gdje je sada

$$h : \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad h(x) = \begin{pmatrix} h_1(x) \\ \vdots \\ h_m(x) \end{pmatrix}, \quad g : \mathbb{R}^n \rightarrow \mathbb{R}^p, \quad g(x) = \begin{pmatrix} g_1(x) \\ \vdots \\ g_p(x) \end{pmatrix}$$

Napomena: kako čitati $g(x) \leq 0$ kad je $g(x)$ vektor

Nejednakost između vektora ovdje se čita **po komponentama**: $g(x) \leq 0$ znači $g_1(x) \leq 0$ i $g_2(x) \leq 0$ i ... i $g_p(x) \leq 0$. Sve nejednakosti moraju vrijediti istovremeno. Nula na desnoj strani je nul-vektor odgovarajuće dimenzije.

1.2.4 Što je optimalno rješenje

[str. 9]

Definicija 1.3: Optimalno rješenje

Optimalno rješenje x^* je vektor projektnih varijabli koji, od svih vektora iz projektnog prostora koji zadovoljavaju ograničenja, ima **najmanju** vrijednost funkcije cilja f .

Uočite da definicija ima dva dijela i oba su nužna:

1. x^* mora **sam zadovoljavati ograničenja** (inače nije kandidat),
2. među svim takvim kandidatima ima **najmanji** f .

Zvjezdica $*$ je standardna oznaka za optimalnu vrijednost; koristit ćemo je kroz cijelu skriptu (x^* , $f(x^*)$, kasnije p^* , λ^* , ...).

1.2.5 Dozvoljeni skup

[str. 78]

Skup svih x koji zadovoljavaju **sva** ograničenja zove se **dozvoljeni skup** (ili *dozvoljeno područje*, *dozvoljeni projektni prostor*; engl. *feasible set*):

Definicija 1.4: Dozvoljeni skup

$$\mathcal{F} = \{ x \mid h(x) = 0, g(x) \leq 0 \} \quad (1.3)$$

Notacija $\{ x \mid \text{uvjet} \}$ čita se: „skup svih x **takvih da** vrijedi uvjet”. Uspravna crta $|$ znači „takvih da”.

Uz tu oznaku problem se piše najkraće:

$$\min_{x \in \mathcal{F}} f(x)$$

1.3 Uvodni primjer s potpunim grafom

[str. 10--15]

Ovo je prvi konkretan problem u kolegiju i vrijedi ga proći vrlo pažljivo, jer se na njemu vidi *sve* iz prethodnog odjeljka odjednom.

1.3.1 Postavka problema

[str. 10]

$$\begin{aligned} \min_x \quad & (x_1 - 2)^2 + (x_2 - 1)^2 \\ \text{uz ograničenja} \quad & \begin{cases} x_1^2 - x_2 \leq 0 \\ x_1 + x_2 \leq 2 \end{cases} \end{aligned} \quad (1.4)$$

Projektni prostor [str. 10]: $X = \mathbb{R}^n$ s varijablama $x = (x_1, x_2)$, dakle $n = 2$.

1.3.2 Prepoznavanje elemenata standardne forme

[str. 11--12]

Dozvoljeni skup [str. 11]:

$$\mathcal{F} = \{x \mid g(x) \leq 0\}, \quad g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \end{pmatrix} = \begin{pmatrix} x_1^2 - x_2 \\ x_1 + x_2 - 2 \end{pmatrix} \leq 0$$

Obratite pažnju na **prebacivanje na standardnu formu**: ograničenje je zadano kao $x_1 + x_2 \leq 2$, a standardna forma traži oblik $g_j(x) \leq 0$. Zato **oduzmemo 2 s obje strane**:

$$x_1 + x_2 \leq 2 \iff x_1 + x_2 - 2 \leq 0 \implies g_2(x) = x_1 + x_2 - 2$$

Prvo ograničenje već je u pravom obliku: $g_1(x) = x_1^2 - x_2$.

Funkcija cilja [str. 12]:

$$f(x) = (x_1 - 2)^2 + (x_2 - 1)^2$$

Geometrijsko značenje funkcije cilja. $f(x)$ je **kvadrat udaljenosti** točke $x = (x_1, x_2)$ od točke $(2, 1)$. (Po Pitagorinu poučku, udaljenost je $\sqrt{(x_1 - 2)^2 + (x_2 - 1)^2}$, a f je taj izraz na kvadrat.) Dakle problem glasi: „**nađi točku dozvoljenog skupa koja je najbliža točki $(2, 1)$** ”. Bez ograničenja rješenje bi trivijalno bilo $x = (2, 1)$ s $f = 0$; ograničenja to zabranjuju i zato problem nije trivijalan.

1.3.3 Rješenje

[str. 15]

$$x^* = \begin{pmatrix} x_1^* \\ x_2^* \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad f(x^*) = 1$$

Provjera da je x^* doista dozvoljena točka (uvrštavanje korak po korak):

$$g_1(x^*) = (x_1^*)^2 - x_2^* = 1^2 - 1 = 1 - 1 = 0 \leq 0 \quad \checkmark \quad (1.5)$$

$$g_2(x^*) = x_1^* + x_2^* - 2 = 1 + 1 - 2 = 2 - 2 = 0 \leq 0 \quad \checkmark \quad (1.6)$$

Oba ograničenja su zadovoljena s **jednakošću** — kažemo da su **aktivna** u x^* (taj ćemo pojam formalno uvesti u poglavlju 3).

Provjera vrijednosti funkcije cilja:

$$f(x^*) = (1 - 2)^2 + (1 - 1)^2 = (-1)^2 + 0^2 = 1 + 0 = 1 \quad \checkmark$$

1.3.4 Graf

Slajdovi 13, 14 i 15 grade upravo ovaj crtež u tri koraka: prvo ograničenje g_1 , zatim ograničenje g_2 , pa oba zajedno s nivo krivuljama.

Kako to nacrtati rukom: dozvoljeni skup i nivo krivulje

Korak 1 — prazan koordinatni sustav. Nacrtajte vodoravnu os i označite je x_1 , te okomitu os i označite je x_2 . Raspon kao na slajdu: x_1 od -2 do 3 , x_2 od -2 do 4 . Označite jedinice na obje osi (cijeli brojevi). Koristite **jednako mjerilo** na obje osi — inače će kružnice iz koraka 5 izgledati kao elipse i izgubit će se geometrijsko značenje.

Korak 2 — prvo ograničenje g_1 (odgovara slajdu 13). Granica ograničenja g_1 je krivulja gdje vrijedi jednakost:

$$g_1(x) = 0 \iff x_1^2 - x_2 = 0 \iff x_2 = x_1^2$$

To je **obična parabola** s tjemenom u ishodištu $(0, 0)$, otvorena prema gore. Nacrtajte je kroz nekoliko točaka koje lako izračunate:

x_1	-2	-1	0	1	2
$x_2 = x_1^2$	4	1	0	1	4

Koju stranu sjenčati? Ograničenje traži $x_1^2 - x_2 \leq 0$, tj. $x_2 \geq x_1^2$. Dakle dopušteno je ono što je **iznad** parabole. Provjera testnom točkom: uzmimo $(0, 1)$ — tada je $g_1 = 0^2 - 1 = -1 \leq 0$ ✓, a točka $(0, 1)$ leži iznad parabole. Dakle: **osjenčajte (kao nedopušteno) područje ispod parabole**, a zadržite područje iznad nje.

Korak 3 — drugo ograničenje g_2 (odgovara slajdu 14). Granica je pravac:

$$g_2(x) = 0 \iff x_1 + x_2 - 2 = 0 \iff x_2 = 2 - x_1$$

Pravac s nagibom -1 . Najlakše ga je nacrtati kroz dvije točke — sjecišta s osima:

- za $x_1 = 0$: $x_2 = 2 \rightarrow$ točka $(0, 2)$,
- za $x_2 = 0$: $x_1 = 2 \rightarrow$ točka $(2, 0)$.

Povucite pravac kroz te dvije točke.

Koju stranu sjenčati? Ograničenje traži $x_1 + x_2 - 2 \leq 0$, tj. $x_2 \leq 2 - x_1$, dakle dopušteno je **ispod** pravca. Provjera testnom točkom: ishodište $(0, 0)$ daje $g_2 = 0 + 0 - 2 = -2 \leq 0$ ✓, a ishodište je ispod pravca. Dakle: **osjenčajte (kao nedopušteno) područje iznad pravca**.

Korak 4 — odnos dviju krivulja i dozvoljeni skup. Parabola i pravac se sijeku ondje gdje vrijedi i $x_2 = x_1^2$ i $x_2 = 2 - x_1$:

$$x_1^2 = 2 - x_1 \implies x_1^2 + x_1 - 2 = 0 \implies (x_1 + 2)(x_1 - 1) = 0 \implies x_1 = -2 \text{ ili } x_1 = 1$$

Pripadni x_2 :

- za $x_1 = -2$: $x_2 = 2 - (-2) = 4 \rightarrow$ sjecište $(-2, 4)$,
- za $x_1 = 1$: $x_2 = 2 - 1 = 1 \rightarrow$ sjecište $(1, 1)$.

Dozvoljeni skup je presjek dvaju područja: **iznad parabole i ispod pravca**. To je oblik „leće” (na slajdu bijelo područje) omeđen odozdo parabolom, a odozgo pravcem, s vrhovima točno u dvjema sjecišnim točkama $(-2, 4)$ i $(1, 1)$. Sve ostalo na crtežu je nedopušteno (na slajdu obojeno crveno).

Korak 5 — nivo krivulje funkcije cilja (odgovara slajdu 15). **Nivo krivulja** (engl. *level curve, contour*) funkcije f za razinu c je skup svih točaka u kojima f ima istu vrijednost c : $\{x \mid f(x) = c\}$. (Pojam se detaljnije obrađuje u poglavlju 2.) Ovdje:

$$(x_1 - 2)^2 + (x_2 - 1)^2 = c$$


To je **kružnica sa središtem u $(2, 1)$ i polumjerom $\sqrt{c}$** . Nacrtajte nekoliko koncentričnih kružnica oko točke $(2, 1)$, npr. za

$$c = 0,25 \ (r = 0,5), \quad c = 1 \ (r = 1), \quad c = 2 \ (r \approx 1,41), \quad c = 4 \ (r = 2), \quad c = 9 \ (r = 3)$$

Što je kružnica manja, to je vrijednost funkcije cilja manja — jer je f kvadrat udaljenosti od središta.

Korak 6 — očitavanje optimuma. Označite točku $(2, 1)$ (križić) — to bi bio minimum *da nema ograničenja*, ali ona leži u crvenom (nedopuštenom) području: provjerimo, $g_1(2, 1) = 2^2 - 1 = 3 > 0$, dakle nedopustiva. Sada „napuhajte” kružnice od polumjera 0 prema van i gledajte **koja prva dotakne bijelu leću**. Ta prva dodirna točka je optimum. To je točno kružnica $c = 1$, a dodiruje leću u vrhu $(1, 1)$ — dakle $x^* = (1, 1)$, $f(x^*) = 1$.

Korak 7 — što graf znači. Optimum leži u **vrhu** dozvoljenog skupa, ondje gdje se sijeku obje granice, dakle **oba ograničenja su aktivna**. Optimalna vrijednost $f(x^*) = 1$ strogo je veća od nule (vrijednosti neograničenog minimuma) — to je „cijena” koju plaćamo zato što nas ograničenja tjeraju dalje od željene točke $(2, 1)$. U poglavlju 3 naučit ćemo algebarski uvjet (KKT uvjete) koji formalno opisuje upravo ovakvu situaciju.



Slika 1.1: Dozvoljeni skup (bijela „leća”), nivo krivulje funkcije cilja (koncentrične kružnice oko $(2, 1)$) i optimum $x^* = (1, 1)$. Nedopušteno područje je crveno.

Napomena: tiskarska pogreška na slajdu 15

Na slajdu 15 prvo ograničenje je otipkano kao $g_1(x) = x_1^2 - x^2 \leq 0$, dok na slajdovima 10--14 svugdje piše $g_1(x) = x_1^2 - x_2 \leq 0$. Ispravno je $x_1^2 - x_2$ — to potvrđuje i sam crtež na slajdu (parabola $x_2 = x_1^2$) i rješenje $x^* = (1, 1)$.

1.4 Gdje i zašto se optimira?

[str. 16--17]

1.4.1 Optimiranje rada sustava / procesa („on-line”)

- Planiranje proizvodnje u elektroenergetskoj mreži
- Upravljanje motorom automobila
- Upravljanje tokovima snage i energijom u hibridnom automobilu
- Traženje najkraćeg puta (npr. GPS u autu, „preračunavam”)
- Gibanje robota prilikom obavljanja zadatka
- Plan bušenja rupa na ploči za elektroniku

- Web tražilica
- Optimalno upravljanje dinamičkim sustavima (bogata inženjerska / znanstvena grana za sebe)
- ...

1.4.2 U fundamentalnim fizikalnim zakonima / problemima

- Traženje **ravnotežnog položaja** minimizacijom potencijalne energije
- **Stabilnost dinamičkih sustava** — traženje Ljapunovljeve funkcije

Ove dvije stavke nisu samo ilustracija: prva se detaljno rješava u poglavlju 3, a druga je tema cijelog poglavlja 7.

1.4.3 U prirodi

- Oblik stabla (optimiranje oblika obzirom na vlastitu težinu i vanjska opterećenja)
- Struktura kosti
- Trajektorija šišmiša u lovu na plijen
- Oblik jabuke
- Prilagodba vrste na uvjete života u zadanoj okolini
- ...

1.4.4 Optimalno projektiranje

- Optimalna raspodjela vjetroturbina u vjetroparku
- Optimiranje topologije, oblika, dimenzija mehanizama i nosivih konstrukcija — **u ovom kolegiju**
- ...

... i još puno, puno toga.

1.5 Sadržaj kolegija i ishodi učenja

[str. 18--32]

Kompletna popis tema sa slajdova (gradi se inkrementalno kroz 15 slajdova):

1. **Uvod:** Ciljevi kolegija i ishodi učenja.
2. **Optimizacijski problem:** definicije i klasifikacija. Konveksni opt. problemi.
3. **Uvjeti optimalnosti.** Geometrijska interpretacija i primjene.
4. **Lagrangeova dualnost,** alternative i analiza osjetljivosti.
5. **Linearno programiranje.** pristupi rješavanju i primjeri.
6. **Kvadratno programiranje** s primjenama. Formulacija i značajke.
7. **Linearne matrične nejednadžbe i semidefinitno programiranje.**
8. **Numerički algoritmi** za rješavanje opt. problema (pregled).

9. **Optimiranje mehatroničkih sustava** — od linearnog do semidefinitnog programiranja: primjeri iz prakse.
10. **Formulacija stabilnosti i disipativnost dinamičkih sustava** kao opt. problema.
11. Formulacije kriterija i analiza učinkovitosti dinamičkih sustava.
12. Formulacije **optimalnog upravljanja** i pristupi rješavanju.
13. **Robusno optimiranje 1**
14. **Robusno optimiranje 2**
15. **Višeciljna optimizacija** i višeciljno upravljanje

Kako se to preslikava na ovu skriptu: teme 1--2 → poglavlja 1--2; tema 3 → poglavlje 3; tema 4 → poglavlje 4; teme 5--6 → poglavlje 5; teme 7 i 9 → poglavlje 6; teme 10--12 → poglavlje 7; teme 13--14 → poglavlje 8.

1.6 Motivacijski primjeri iz prakse

[str. 33--43]

1.6.1 Planiranje proizvodnje u elektroenergetskoj mreži

[str. 33--34]

Problem: planiranje rada električnih generatora.

Sa slajda, sa svrstavanjem svake stavke u element standardne forme:

Sa slajda	Element opt. problema
tipično noć prije dana proizvodnje	(vremenski okvir odluke)
proizvodnja = predviđenoj potrošnji	ograničenje jednakosti $h(x) = 0$
minimiziranje troškova proizvodnje	funkcija cilja $f(x)$
ograničenja na tok snage u dalekovodima	ograničenja nejednakosti $g(x) \leq 0$
planovi u slučaju kvara	robustnost (poglavlje 8)

Dodatno [str. 34]:

- Optimiranje (optimalno upravljanje) je „**skrivena tehnologija**” za razvoj naprednih mreža u budućnosti.
- Matematička formulacija tržišta i kreiranja tržišnih cijena: **Lagrangeova dualnost**.

Zadnja rečenica je najava Vježbi 3, gdje se cijeli „Primjer 1: Tržište i formiranje cijena” rješava upravo preko dualnosti — vidi poglavlje 4.

1.6.2 Upravljanje tokovima snage i energijom u hibridnom automobilu

[str. 35]

- Nije dobro imati napunjenu bateriju: želimo je (polu)praznu da bismo je mogli puniti prilikom kočenja (rekuperacija).

- **dobro** $\rightarrow$ **optimalno**
- Optimiranje je „skrivena tehnologija” koja daje „inteligenciju” procesu: pojmovi *dobro--loše* moraju biti vezani uz neki kriterij $\rightarrow$ **formalizacija funkcije cilja**.

1.6.3 Prediktivno upravljanje dinamičkim sustavima

[str. 36--37]

Slajdovi su ilustracija koncepta MPC-a (engl. *Model Predictive Control*): u svakom koraku se, na temelju modela, riješi optimizacijski problem na konačnom horizontu predikcije, primijeni se prvi upravljački potez, pa se postupak ponovi.

1.6.4 Optimalno upravljanje — pozicioniranje glave tvrdog diska

[str. 38]

Slajd prikazuje mehanizam tvrdog diska (ruka s glavom, *pivot, voice coil motor* VCM) i regulacijsku petlju: regulator K prima signal pogreške e i daje upravljanje u ; y_r je referenca, y izlaz, d poremećaj.

Podaci sa slajda: $>15\,000$ o/min, $12\,000$ traka na 1 cm.

Formulacija problema (sa slajda):

$$\min_K \max_{\|d\| \neq 0} \frac{\|e\|}{\|d\|}, \quad K \in \{ \text{stabilizirajući regulatori} \} \quad (1.7)$$

Kako to čitati. $\|\cdot\|$ je **norma** — mjera „veličine” signala (formalno u poglavlju 2). Omjer $\|e\|/\|d\|$ je „koliko se poremećaj d pojača u pogrešku e ”. Unutarnji $\max$ uzima **najgori mogući** poremećaj, a vanjski $\min$ bira regulator koji taj najgori slučaj čini što manjim. Ovakav **min--max** zapis je tipičan za robusno projektiranje i vratit ćemo mu se u poglavljima 7 i 8.

1.6.5 Ravnotežni položaj sustava u potencijalnom polju

[str. 39--40]

Postavka [str. 39]. Točka mase m obješena je u vertikalnoj ravnini o dvije elastične opruge zanemarive mase s konstantama k_1, k_2 i duljinama l_1, l_2 , dok je razmak objesišta jednak d .

Geometrija sa slajda: koordinatni sustav (x, y) ; lijevo objesište je u ishodištu $(0, 0)$, desno objesište je na osi x na udaljenosti d , tj. u $(d, 0)$; masa m visi ispod, u točki (x, y) (s $y < 0$). Lijeva opruga ima parametre k_1, l_1 , desna k_2, l_2 .

Zadatak: izračunati ravnotežni položaj mase.

Rješenje [str. 40]. Potencijalna energija mase m u položaju (x, y) je

$$V(x, y) = mgy + \frac{k_1}{2} \left(l_1 - \sqrt{x^2 + y^2} \right)^2 + \frac{k_2}{2} \left(l_2 - \sqrt{(d-x)^2 + y^2} \right)^2 \quad (1.8)$$

Rastav izraza član po član (svaki je član oblika „energija”):

- mgy — **gravitacijska potencijalna energija** mase u polju sile teže (g = ubrzanje sile teže). Budući da masa visi ispod osi x, y je negativan pa je taj član negativan — spuštanjem mase energija pada.

- $\sqrt{x^2 + y^2}$ — trenutna **duljina lijeve opruge**, tj. udaljenost od objesišta $(0, 0)$ do mase (x, y) (Pitagorin poučak).
- $l_1 - \sqrt{x^2 + y^2}$ — **deformacija** lijeve opruge (razlika nedeformirane duljine l_1 i trenutne duljine).
- $\frac{k_1}{2}(\cdot)^2$ — **elastična energija** lijeve opruge; standardna formula $E = \frac{1}{2}k \Delta l^2$.
- Analogno za desnu oprugu, samo je njezino objesište u $(d, 0)$, pa je udaljenost do mase $\sqrt{(d-x)^2 + y^2}$.

Ravnotežna točka (x^*, y^*) je ona koja **minimizira** potencijalnu energiju:

$$(x^*, y^*) = \arg \min_{x, y} V(x, y) \quad (1.9)$$

Napomena: notacija $\arg \min$

$\min_x V(x)$ je **najmanja vrijednost** koju V poprima (broj), dok je $\arg \min_x V(x)$ **argument** u kojem se taj minimum postiže (točka). Za nas je obično zanimljiv $\arg \min$ — želimo znati *gdje* je optimum, a ne samo *koliko* iznosi.

Ovo je važan konceptualni primjer: **fizikalni zakon (ravnoteža) izražen je kao optimizacijski problem bez ograničenja**. Isti primjer se u poglavlju 3 proširuje na slučaj s ograničenjima i rješava preko uvjeta optimalnosti.

1.6.6 Primjeri iz prirode

[str. 41]

Slajd je fotografska ilustracija tvrdnji iz odjeljka o prirodi (oblici koje priroda „optimira”). Nema dodatnih formula.

1.6.7 Raspodjela vjetroturbina u vjetroparku

[str. 42--43]

Slajd 43 prikazuje dva 3D grafa (površina prinosa nad tlocrtom parka, s ucrtanim pozicijama turbina kao točkama i označenim smjerom sjevera **N**):

- lijevo: **optimalni položaji sa zanemarenim interakcijama preko vrtloga**,
- desno: **optimalni položaji s uračunatim interakcijama preko vrtloga**.

Poanta: ista funkcija cilja (ukupna proizvedena energija), ali bogatiji model (uzimanje u obzir da turbina u vjetrenoj sjeni druge turbine daje manje) daje **bitno drukčiji optimalni raspored**. Model ulazi u optimizaciju kroz ograničenja i funkciju cilja — kvaliteta modela izravno određuje kvalitetu optimuma.

1.7 Primjer: problem proizvodnje i distribucije robe

[str. 44--45]

Ovo je prvi potpuno formuliran „inženjersko-poslovni” problem u kolegiju i ujedno prvi primjer **linearnog programa** (LP), koji ćemo formalno obraditi u poglavlju 5.

1.7.1 Opis problema

[str. 44]

- Tvrtka ima **2 tvornice** i **7 trgovina**.
- U jednom proizvodnom vremenskom intervalu tvornica i može proizvesti do a_i tona.
- Svaka trgovina j redovito ima potražnju od b_j tona.
- Troškovi transporta od tvornice i do trgovine j su c_{ij} kuna/toni.
- **Kako optimalno voditi tvrtku (minimizirati trošak)?**

1.7.2 Projektne varijable

[str. 45]

$x_{ij} \in \mathbb{R}$: koliko tvornica i dobavlja robe trgovini j , $x_{ij} \geq 0$

Budući da imamo 2 tvornice i 7 trgovina, ukupno je $2 \times 7 = 14$ varijabli. Uvjet $x_{ij} \geq 0$ je fizikalne prirode: ne može se isporučiti negativna količina.

1.7.3 Potpuna formulacija

[str. 45]

$$\begin{aligned}
 & \min \quad \sum_{i=1}^2 \sum_{j=1}^7 c_{ij} x_{ij} \\
 & \text{uz ograničenja} \quad \sum_{j=1}^7 x_{ij} \leq a_i, \quad i = 1, 2 \\
 & \quad \sum_{i=1}^2 x_{ij} \geq b_j, \quad j = 1, \dots, 7 \\
 & \quad x_{ij} \geq 0
 \end{aligned} \tag{1.10}$$

Čitanje svakog retka:

- **Funkcija cilja** $\sum_i \sum_j c_{ij} x_{ij}$: za svaku moguću relaciju tvornica $\rightarrow$ trgovina pomnožimo prevezenu količinu x_{ij} [t] s jediničnim troškom c_{ij} [kn/t] i sve zbrojimo. Rezultat je **ukupan trošak transporta** u kunama. (Simbol $\sum$ znači „zbroji po svim vrijednostima indeksa”; dvostruka suma znači da prolazimo po svim parovima (i, j) , dakle po svih 14 relacija.)
- **Kapacitet tvornice** $\sum_j x_{ij} \leq a_i$: sve što tvornica i pošalje (zbroj po svim trgovinama) ne smije prijeći njezin kapacitet a_i . Dva takva ograničenja (po jedno za svaku tvornicu).
- **Potražnja trgovine** $\sum_i x_{ij} \geq b_j$: sve što trgovina j primi (zbroj po objema tvornicama) mora biti barem b_j . Sedam takvih ograničenja.
- **Nenegativnost** $x_{ij} \geq 0$: 14 ograničenja.

Napomena: prevođenje u standardnu formu

Standardna forma traži $g_j(x) \leq 0$, pa nejednakost „ $\geq$ ” pomnožimo s -1 (što okreće smjer):
 $\sum_i x_{ij} \geq b_j \Leftrightarrow b_j - \sum_i x_{ij} \leq 0$, i $x_{ij} \geq 0 \Leftrightarrow -x_{ij} \leq 0$. Kapacitet je već u pravom obliku
 nakon premještanja: $\sum_j x_{ij} - a_i \leq 0$.

Uočite: i funkcija cilja i sva ograničenja su **linearne** funkcije varijabli x_{ij} . To je definicija linearnog programa (poglavlje 5).

1.8 Klasični primjeri optimiranja s potpunim rješenjima

[str. 46--52]

Slajdovi 46--52 rješavaju šest školskih ekstremalnih problema. Svi se rješavaju istim receptom, pa ga vrijedi jednom izreći:

Definicija 1.5: Recept klasične analize — ekstrem funkcije jedne varijable

1. Uvedi varijablu i izrazi **funkciju cilja** preko nje.
2. Ako postoji ograničenje jednakosti, iz njega **izrazi jednu varijablu** i **uvrsti** u funkciju cilja (eliminacija) — tako problem s ograničenjem postaje problem bez ograničenja.
3. Deriviraj i izjednači s nulom: $\frac{dF}{dx} = 0 \rightarrow$ **stacionarne točke**.
4. Provjeri drugom derivacijom: $F'' > 0 \rightarrow$ **minimum**, $F'' < 0 \rightarrow$ **maksimum**.
5. Izračunaj vrijednost cilja u nađenoj točki.

Ovaj recept vrijedi za jednostavne, glatke probleme jedne varijable. U poglavlju 3 generalizirat ćemo ga na više varijabli i na probleme gdje se ograničenja *ne mogu* tako lako eliminirati — tada nastupaju Lagrangeovi multiplikatori i KKT uvjeti.

1.8.1 Optimalno iskorištavanje materijala — posuda iz limene ploče

[str. 46--47]

Problem. Iz kvadratne limene ploče stranice a potrebno je izrezati uglove tako da se iz preostalog dijela načini posuda što većeg volumena. Izrezuju se četiri kvadratića stranice x u uglovima; preostali „križ” se savine prema gore.

Ciljna funkcija je volumen:

$$V = (a - 2x)^2 \cdot x$$

Odakle to: nakon izrezivanja uglova stranice x i savijanja, baza posude je kvadrat stranice $a - 2x$ (s obje strane oduzimamo po x), a visina posude je x .

Derivacija:

$$\frac{dV}{dx} = 12x^2 - 8ax + a^2$$

Provjera računa (raspis međukoraka koji na slajdu nije napisan):

$$V = x(a - 2x)^2 = x(a^2 - 4ax + 4x^2) = a^2x - 4ax^2 + 4x^3 \quad (1.11)$$

$$\frac{dV}{dx} = a^2 - 8ax + 12x^2 \quad \checkmark \quad (1.12)$$

Izjednačavanje s nulom daje kvadratnu jednadžbu $12x^2 - 8ax + a^2 = 0$, čija su rješenja (sa slajda):

$$x_{1,2} = \frac{a}{3} \pm \frac{a}{6}; \quad x_1 = a/2, \quad x_2 = a/6$$

Provjera preko formule za kvadratnu jednadžbu:

$$x_{1,2} = \frac{8a \pm \sqrt{(8a)^2 - 4 \cdot 12 \cdot a^2}}{2 \cdot 12} = \frac{8a \pm \sqrt{64a^2 - 48a^2}}{24} = \frac{8a \pm \sqrt{16a^2}}{24} = \frac{8a \pm 4a}{24} \quad (1.13)$$

$$x_1 = \frac{12a}{24} = \frac{a}{2}, \quad x_2 = \frac{4a}{24} = \frac{a}{6} \quad \checkmark \quad (1.14)$$

Provjera drugom derivacijom:

$$V'' = \frac{d^2V}{dx^2} = 24x - 8a$$

$$V''\left(\frac{a}{2}\right) = 24 \cdot \frac{a}{2} - 8a = 12a - 8a = 4a > 0 \rightarrow \mathbf{min.} \quad (1.15)$$

$$V''\left(\frac{a}{6}\right) = 24 \cdot \frac{a}{6} - 8a = 4a - 8a = -4a < 0 \rightarrow \mathbf{max.} \quad (1.16)$$

Vrijednosti:

$$V_{\max} = \left(a - \frac{a}{3}\right)^2 \cdot \frac{a}{6} = \frac{2}{27}a^3; \quad V_{\min} = 0$$

Provjera: za $x = a/6$ je $a - 2x = a - a/3 = \frac{2a}{3}$, pa je $V = \left(\frac{2a}{3}\right)^2 \cdot \frac{a}{6} = \frac{4a^2}{9} \cdot \frac{a}{6} = \frac{4a^3}{54} = \frac{2a^3}{27} \checkmark$.
Za $x = a/2$ je $a - 2x = 0$, pa je $V = 0$ — geometrijski jasno: izrezali smo cijelu ploču, baza je nestala.

1.8.2 Minimizacija troškova izgradnje — tlocrt kuće

[str. 48]

Problem. Kuća ima 3 prostorije površine A [m²]. Troškovi izgradnje vanjskih zidova iznose C [EUR/m], a troškovi za unutrašnje zidove iznose $2/3$ tih troškova. Odrediti mjere tlocrta tako da troškovi izgradnje zidova budu minimalni.

Geometrija sa slajda: pravokutnik širine x i visine y ; unutar njega jedan okomiti zid (duljine y) koji odvaja desni dio, te u lijevom dijelu vodoravni zid duljine $2x/5$ — tako se dobiju 3 prostorije.

Ograničenje jednakosti:

$$A = x y \text{ [m}^2\text{]} \rightarrow y = A/x$$

Ciljna funkcija $\rightarrow$ minimalni troškovi:

$$F(x) = C \left(2x + 2\frac{A}{x} \right) + \frac{2}{3}C \left(\frac{2}{5}x + \frac{A}{x} \right)$$

Rastav: prvi član su vanjski zidovi — opseg pravokutnika je $2x + 2y = 2x + 2A/x$, uz cijenu C . Drugi član su unutarnji zidovi — vodoravni duljine $\frac{2}{5}x$ i okomiti duljine $y = A/x$, uz cijenu $\frac{2}{3}C$.

Sređivanje (sa slajda):

$$F(x) = \frac{2}{3}C \left(\frac{17}{5}x + 4\frac{A}{x} \right)$$

Raspis međukoraka koji na slajdu nije prikazan:

$$F(x) = 2Cx + \frac{2CA}{x} + \frac{2}{3}C \cdot \frac{2}{5}x + \frac{2}{3}C \frac{A}{x} \quad (1.17)$$

$$= C \underbrace{\left(2 + \frac{4}{15}\right)}_{=\frac{30+4}{15}=\frac{34}{15}} x + C \underbrace{\left(2 + \frac{2}{3}\right)}_{=\frac{6+2}{3}=\frac{8}{3}} \frac{A}{x} = \frac{34}{15}Cx + \frac{8}{3}C \frac{A}{x} \quad (1.18)$$

a s druge strane

$$\frac{2}{3}C \left(\frac{17}{5}x + \frac{4A}{x} \right) = \frac{2 \cdot 17}{3 \cdot 5}Cx + \frac{2 \cdot 4}{3}C \frac{A}{x} = \frac{34}{15}Cx + \frac{8}{3}C \frac{A}{x} \quad \checkmark$$

Konstante prebacimo na lijevu stranu (jer konstantni pozitivni faktor ne mijenja položaj minimuma — ovo je važan i često korišten trik):

$$F_0 = \frac{3F(x)}{2C} = \left(\frac{17}{5}x + 4\frac{A}{x} \right)$$

Derivacija i izjednačavanje s nulom:

$$\frac{dF_0}{dx} = \frac{17}{5} - \frac{4A}{x^2} = 0 \quad \rightarrow \quad x^2 = \frac{20}{17}A = \frac{20}{17}xy$$

Međukorak: iz $\frac{17}{5} = \frac{4A}{x^2}$ slijedi $x^2 = \frac{4A \cdot 5}{17} = \frac{20A}{17}$; zatim se uvrsti $A = xy$.

Odakle treba biti:

$$\frac{x}{y} = \frac{20}{17}$$

Međukorak: iz $x^2 = \frac{20}{17}xy$ podijelimo obje strane s x (dopušteno jer $x > 0$) i dobijemo $x = \frac{20}{17}y$, tj. $x/y = 20/17$.

1.8.3 Maksimizacija volumena lijevka I

[str. 49]

Problem. Neka se iz okrugle ploče izreže isječak tako da se iz ostatka načini lijevak (stožac) što većeg volumena.

Geometrija: iz kruga polumjera r izreže se kružni isječak, a preostali dio (središnjeg kuta φ) se smota u plašt stošca. Nastali stožac ima polumjer baze R , izvodnicu r (jer je to polumjer polazne ploče) i visinu h .

Polumjer baze (1): duljina luka preostalog dijela postaje opseg baze:

$$2R\pi = r\varphi \quad \rightarrow \quad R = \frac{r\varphi}{2\pi} \quad (1.19)$$

Visina stošca (2): iz pravokutnog trokuta (izvodnica, polumjer baze, visina):

$$h = \sqrt{r^2 - R^2} \quad (1.20)$$

Ciljna funkcija (3): volumen stošca

$$V = \frac{\pi R^2 h}{3} \quad (1.21)$$

Uvrštenjem (1) i (2) u (3):

$$V = \frac{r^3}{12\pi} \varphi^2 \sqrt{1 - \frac{\varphi^2}{4\pi^2}}$$

Raspis međukoraka:

$$R^2 = \frac{r^2 \varphi^2}{4\pi^2}, \quad h = \sqrt{r^2 - \frac{r^2 \varphi^2}{4\pi^2}} = r \sqrt{1 - \frac{\varphi^2}{4\pi^2}} \quad (1.22)$$

$$V = \frac{\pi}{3} \cdot \frac{r^2 \varphi^2}{4\pi^2} \cdot r \sqrt{1 - \frac{\varphi^2}{4\pi^2}} = \frac{r^3 \varphi^2}{12\pi} \sqrt{1 - \frac{\varphi^2}{4\pi^2}} \quad \checkmark \quad (1.23)$$

Prebacivanjem konstanti na lijevu stranu i kvadriranjem, uređena ciljna funkcija je:

$$F(\varphi) = \left(\frac{12\pi V}{r^3} \right)^2 = \varphi^4 \left(1 - \frac{\varphi^2}{4\pi^2} \right)$$

Napomena: zašto smijemo kvadrirati

Funkcija $t \mapsto t^2$ je **strogo rastuća** za $t \geq 0$, a $V \geq 0$. Strogo rastuća transformacija ne mijenja *položaj* maksimuma, samo njegovu vrijednost. Isto vrijedi za množenje pozitivnom konstantom. Ovaj postupak (uklanjanje korijena kvadriranjem) koristit ćemo često — vidi i Vježbe 2, gdje se isto radi s normama.

Derivacija:

$$\frac{dF}{d\varphi} = 4\varphi^3 - \frac{3}{2\pi^2} \varphi^5 = 0$$

Provjera: $F(\varphi) = \varphi^4 - \frac{\varphi^6}{4\pi^2}$, pa je $F' = 4\varphi^3 - \frac{6\varphi^5}{4\pi^2} = 4\varphi^3 - \frac{3\varphi^5}{2\pi^2} \quad \checkmark$

Iz toga slijedi:

$$\varphi^2 = \frac{8}{3}\pi^2 \quad \rightarrow \quad \varphi = \sqrt{\frac{2}{3}} \cdot 2\pi \text{ rad} = 293,939^\circ$$

Međukoraci: podijelimo jednadžbu s φ^3 (za $\varphi \neq 0$): $4 = \frac{3}{2\pi^2} \varphi^2$, dakle $\varphi^2 = \frac{8\pi^2}{3}$. Zatim $\varphi = \sqrt{\frac{8\pi^2}{3}} = 2\pi \sqrt{\frac{2}{3}}$. Brojčano: $\sqrt{2/3} = 0,8165$, pa $\varphi = 0,8165 \cdot 6,2832 = 5,1302$ rad; u stupnjevima $5,1302 \cdot \frac{180}{\pi} = 293,94^\circ \quad \checkmark$

1.8.4 Maksimizacija volumena lijevka II

[str. 50]

Problem. Kakav oblik treba imati lijevak (stožac) da kod **zadane površine plašta** ima što veći volumen?

Površina plašta:

$$A = 2\pi r \cdot R/2 = \pi Rr \quad \rightarrow \quad r = \frac{A}{\pi R}$$

(Ovdje je r izvodnica stošca, R polumjer baze.)

Volumen:

$$V = \frac{\pi R^2}{3} \sqrt{r^2 - R^2} = \frac{\pi R^2}{3} \sqrt{\frac{A^2}{\pi^2 R^2} - R^2}, \quad V = \frac{R}{3} \sqrt{A^2 - \pi^2 R^4}$$

Raspis zadnjeg koraka: izlučimo $\frac{1}{\pi^2 R^2}$ iz korijena:

$$\sqrt{\frac{A^2}{\pi^2 R^2} - R^2} = \frac{1}{\pi R} \sqrt{A^2 - \pi^2 R^4} \quad (1.24)$$

$$V = \frac{\pi R^2}{3} \cdot \frac{1}{\pi R} \sqrt{A^2 - \pi^2 R^4} = \frac{R}{3} \sqrt{A^2 - \pi^2 R^4} \quad \checkmark \quad (1.25)$$

Volumen V bit će maksimalan kad i $(3V)^2$, pa je (isti trik kao prije):

$$F(R) = (3V)^2 = A^2 R^2 - \pi^2 R^6$$

Derivacija:

$$\frac{dF}{dR} = 2A^2 R - 6\pi^2 R^5 = 0 \quad \rightarrow \quad A = \sqrt{3\pi^2 R^4} = \pi\sqrt{3} R^2$$

Međukorak: podijelimo s $2R$ ($R \neq 0$): $A^2 = 3\pi^2 R^4$, pa korjenovanjem $A = \pi R^2 \sqrt{3}$.

Iz $R^2 = \frac{A}{\pi\sqrt{3}}$ i $h^2 = r^2 - R^2 = \frac{A^2}{\pi^2 R^2} - R^2$, slijedi:

$$\frac{h^2}{R^2} = 2 \quad \rightarrow \quad \frac{h}{R} = \sqrt{2}$$

Raspis:

$$\frac{h^2}{R^2} = \frac{1}{R^2} \left(\frac{A^2}{\pi^2 R^2} - R^2 \right) = \frac{A^2}{\pi^2 R^4} - 1 \stackrel{A^2=3\pi^2 R^4}{=} \frac{3\pi^2 R^4}{\pi^2 R^4} - 1 = 3 - 1 = 2 \quad \checkmark$$

Zaključak: optimalan lijevak ima omjer visine i polumjera baze $h/R = \sqrt{2}$.

1.8.5 Dimenzioniranje otvora vrata

[str. 51]

Problem. Kako visoka moraju biti vrata tornja (h) da se ljestve duljine L mogu uvući u toranj?

Geometrija sa slajda: zid tornja je okomit; ljestve $\overline{AB} = L$ naslonjene su tako da im donji kraj B klizi po podu na udaljenosti x od zida, a gornji kraj A je uz vanjski zid; a je vodoravni odmak zida, y je visina na kojoj ljestve prelaze preko brida vrata, a h je tražena visina vrata.

Rješenje: traži se **maksimalna visina y za vrijeme uvlačenja** ljestvi u toranj.

Iz sličnosti trokuta (1):

$$\frac{y}{x-a} = \frac{\sqrt{L^2 - x^2}}{x} \quad \rightarrow \quad y = \frac{x-a}{x} \sqrt{L^2 - x^2} \quad (1.26)$$

(Ovdje je $\sqrt{L^2 - x^2}$ visina gornjeg kraja ljestvi A nad podom — Pitagorin poučak na trokutu s hipotenuzom L i vodoravnom katetom x .)

Derivacija i stacionarna točka (2):

$$\frac{dy}{dx} = \frac{aL^2 - x^3}{x^2 \sqrt{L^2 - x^2}} = 0 \quad \rightarrow \quad x_m = \sqrt[3]{aL^2} \quad (1.27)$$

Međukorak: razlomak je nula kad je brojnik nula: $aL^2 - x^3 = 0 \Rightarrow x^3 = aL^2 \Rightarrow x = \sqrt[3]{aL^2}$.

Uvrštenjem (2) u (1):

$$h \geq y_m = \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{3/2} \cdot L$$

Raspis uvrštavanja (na slajdu nije prikazan): uz $x_m = a^{1/3}L^{2/3}$,

$$\frac{a}{x_m} = \frac{a}{a^{1/3}L^{2/3}} = \frac{a^{2/3}}{L^{2/3}} = \left(\frac{a}{L} \right)^{2/3} \quad (1.28)$$

$$\sqrt{L^2 - x_m^2} = \sqrt{L^2 - a^{2/3}L^{4/3}} = L\sqrt{1 - \left(\frac{a}{L} \right)^{2/3}} \quad (1.29)$$

$$y_m = \left(1 - \frac{a}{x_m} \right) \sqrt{L^2 - x_m^2} = \left[1 - \left(\frac{a}{L} \right)^{2/3} \right] \cdot L \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{1/2} = L \left[1 - \left(\frac{a}{L} \right)^{2/3} \right]^{3/2} \quad \checkmark \quad (1.30)$$

Brojčani primjer sa slajda:

$$a = 2,7 \text{ m}; \quad L = 12,5 \text{ m} \rightarrow y_m = 6,4 \text{ m}; \quad x_m = 7,5 \text{ m}$$

Provjera računa:

$$\frac{a}{L} = \frac{2,7}{12,5} = 0,216 = 0,6^3 \Rightarrow \left(\frac{a}{L} \right)^{2/3} = 0,6^2 = 0,36 \quad (1.31)$$

$$y_m = 12,5 (1 - 0,36)^{3/2} = 12,5 \cdot 0,64^{3/2} = 12,5 \cdot 0,8^3 = 12,5 \cdot 0,512 = 6,4 \text{ m} \quad \checkmark \quad (1.32)$$

$$x_m = \sqrt[3]{2,7 \cdot 12,5^2} = \sqrt[3]{2,7 \cdot 156,25} = \sqrt[3]{421,875} = 7,5 \text{ m} \quad \checkmark \quad (1.33)$$

Slajd uz to prikazuje graf $y(x)$ za te brojke: krivulja kreće od nule pri $x = a = 2,7$, raste do vrha $y \approx 6,4$ pri $x = 7,5$, i pada natrag na nulu pri $x = L = 12,5$ (tada su ljestve okomite uz zid).

1.8.6 Optimalna ograda

[str. 52]

Problem. Površinu od 1 ha treba ograditi na način prema skici (pravokutnik $x \times y$ s jednim unutarnjim pregradnim zidom duljine y). Troškovi postavljanja ograde proporcionalni su duljini ograde. Odrediti dimenzije x i y tako da troškovi budu minimalni.

Ciljna funkcija je duljina ograde:

$$L = 2x + 3y \quad (1.34)$$

Odakle: vanjski opseg je $2x + 2y$, a unutarnja pregrada je još jedan komad duljine y ; ukupno $2x + 3y$.

Ograničenje je površina:

$$A = xy = 10\,000 \text{ m}^2 \rightarrow h = xy - 10\,000 = 0 \quad (1.35)$$

(1 ha = 10 000 m². Zapis $h = xy - 10\,000 = 0$ je upravo standardna forma ograničenja jednakosti iz odjeljka 1.2.)

Uvrštenjem (2) u (1), tj. $y = 10\,000/x$, ciljna funkcija postaje:

$$L = 2x + \frac{3 \cdot 10\,000}{x} \quad \rightarrow \quad \frac{dL}{dx} = 2 - \frac{30\,000}{x^2} = 0$$

pa je:

$$x_{\text{opt}} = 100\sqrt{\frac{3}{2}}, \quad y_{\text{opt}} = 100\sqrt{\frac{2}{3}}, \quad \left(\frac{x}{y}\right)_{\text{opt}} = \frac{3}{2}$$

Raspis:

$$2 = \frac{30\,000}{x^2} \Rightarrow x^2 = 15\,000 \Rightarrow x = \sqrt{15\,000} = \sqrt{10\,000 \cdot 1,5} = 100\sqrt{\frac{3}{2}} \approx 122,47 \text{ m} \quad (1.36)$$

$$y = \frac{10\,000}{x} = \frac{10\,000}{100\sqrt{3/2}} = \frac{100}{\sqrt{3/2}} = 100\sqrt{\frac{2}{3}} \approx 81,65 \text{ m} \quad (1.37)$$

$$\frac{x}{y} = \frac{100\sqrt{3/2}}{100\sqrt{2/3}} = \sqrt{\frac{3/2}{2/3}} = \sqrt{\frac{9}{4}} = \frac{3}{2} \quad \checkmark \quad (1.38)$$

Interpretacija: omjer stranica nije 1:1 (kao kod običnog pravokutnika bez pregrade) nego 3:2 — jer pregradni zid „poskupljuje” smjer y , pa se isplati taj smjer skratiti.

1.9 Vrste optimizacije konstrukcija

[str. 53--56]

1.9.1 Dimenzionalna optimizacija (*size optimization*)

[str. 53]

Optimiranje **dimenzija** objekata **poznate strukture i oblika**.

Primjeri:

- dimenzije elemenata nosivih konstrukcija (presjeci štapova, debljine limova, ...)
- dimenzije članova mehanizama

1.9.2 Optimiranje oblika (*shape optimization*)

[str. 54]

Osnovni **oblik** objekta mijenja se postupkom optimizacije ovisno o zadanim parametrima problema (alat je često **FEM** analiza — metoda konačnih elemenata).

1.9.3 Topološka optimizacija (*topology optimization*)

[str. 55--56]

Traži se optimalna **topologija (struktura)** konstrukcije u zadanoj domeni.

Napomena

Na slajdovima 55 i 56 topološka optimizacija je numerirana kao „2.” (očito tipfeler u prezentaciji — dvije uzastopne stavke nose broj 2). Sadržajno je to **treća** vrsta.

Razlika u tri riječi: *dimenzionalna* mijenja **brojeve** (koliko je štap deo), *oblikovna* mijenja **konture** (kako je rub zaobljen), *topološka* mijenja **raspored materijala** (gdje uopće ima materijala, a gdje su rupe). Topološka je najslobodnija i najteža.

1.10 Postavka problema

[str. 57--58]

Teorem 1.1: Ključna poruka slajda 57

Pravilna definicija, formulacija i točna matematička postavka optimizacijskog problema je često **najveći korak** prilikom rješavanja problema.

Iz formulacije problema treba raspoznati o **kojoj se vrsti optimizacije radi**.

1.10.1 Jednostavan primjer koji to ilustrira

[str. 57--58]

Problem. Površinu uz postojeću prirodnu ogradu (zid, stijena i sl.) treba ograditi s raspoloživom duljinom žičane ograde L tako da ogradena površina bude **maksimalna**.

Na slajdu su prikazana **tri oblika**:

- **a)** pravokutnik naslonjen na zid (jedna stranica x uz zid, dvije stranice y),
- **b)** polukrug polumjera r naslonjen na zid,
- **c)** pola pravilnog mnogokuta (n -terokut, konkretno $n = 8$) naslonjenog na zid.

Poanta (sa slajda):

Iz gornje formulacije nije jasno da li se oblik ograde može odabrati po volji ili se postavlja i neki drugi zahtjevi. Svaki od pokazanih oblika daje za istu duljinu ograde svoje rješenje, pri čemu se oblikom b) ograđuje **najveća** površina, a oblikom a) **najmanja**. Međutim, ako se radi o ogradi pašnjaka koju treba seliti duž zida, tada je oblik a) u „tehnološkoj” prednosti, jer se iskoristi sva raspoloživa površina.

Zaključak: ista rečenica („ogradi maksimalnu površinu”) daje **tri različita optimizacijska problema**, ovisno o tome što smo prešutno pretpostavili. Zato je formulacija najvažniji korak.

1.10.2 Brojčana usporedba triju oblika, $L = 500$ m

[str. 58]

Oblik b) — polukrug

$$L = r\pi \rightarrow A = \frac{\pi r^2}{2} = \frac{L^2}{2\pi} = \frac{500^2}{2\pi} = 39\,788,7 \text{ m}^2$$

Raspis: iz $L = r\pi$ slijedi $r = L/\pi$, pa je $A = \frac{\pi}{2} \cdot \frac{L^2}{\pi^2} = \frac{L^2}{2\pi} = \frac{250\,000}{6,2832} = 39\,788,7 \text{ m}^2 \checkmark$

Oblik c) — polovica pravilnog n -terokuta, $n = 8$ (osmerokut)

$$L = \frac{n}{2}a \rightarrow \varphi = \frac{2\pi}{n}; \quad a = 2r \sin \frac{\varphi}{2} = 2r \sin \frac{\pi}{n}$$

(a je duljina jedne stranice, φ središnji kut nad jednom stranicom, r polumjer opisane kružnice. Uz zid je polovica mnogokuta, pa ograda ima $n/2$ stranica.)

$$r = \frac{L}{n \cdot \sin \frac{\pi}{n}}$$

Raspis: iz $L = \frac{n}{2}a = \frac{n}{2} \cdot 2r \sin \frac{\pi}{n} = n r \sin \frac{\pi}{n}$ slijedi $r = \frac{L}{n \sin(\pi/n)}$ $\checkmark$

$$A = \frac{1}{2} a r \cos \frac{\varphi}{2} \cdot \frac{n}{2} = \frac{n}{4} \cdot 2 \frac{L}{n} \cdot \frac{L}{n \cdot \sin \frac{\pi}{n}} \cos \frac{\pi}{n} = \frac{L^2}{2n \cdot \tan \frac{\pi}{n}}$$

$$A = \frac{500^2}{2 \cdot 8 \cdot \tan \frac{\pi}{8}} = 37\,722,1 \text{ m}^2 \quad \left(\text{za } n \rightarrow \infty, \lim_{n \rightarrow \infty} \left(n \cdot \tan \frac{\pi}{n} \right) = \pi \right)$$

Provjera brojki: $\tan(\pi/8) = \tan 22,5^\circ = 0,41421$, pa je $2 \cdot 8 \cdot 0,41421 = 6,6274$ i $A = 250\,000/6,6274 = 37\,722 \text{ m}^2 \checkmark$

Značenje granice: kad $n \rightarrow \infty$, $n \tan(\pi/n) \rightarrow \pi$, pa formula za mnogokut prelazi u $A \rightarrow L^2/(2\pi)$ — točno rezultat polukruga b). Mnogokut s mnogo stranica je praktički polukrug, što potvrđuje da je b) najbolji oblik.

Oblik a) — pravokutnik

$$L = x + 2y \rightarrow x = L - 2y \quad (\text{ograničenje jednakosti})$$

$$A = xy = (L - 2y)y; \quad \frac{dA}{dy} = L - 4y = 0 \rightarrow y = \frac{L}{4} = 125 \text{ m}; \quad x = \frac{L}{2} = 250 \text{ m}$$

Raspis derivacije: $A = Ly - 2y^2$, pa je $\frac{dA}{dy} = L - 4y \checkmark$

$$A = xy = 250 \cdot 125 = 31\,250 \text{ m}^2 \quad (x : y = 2 : 1)$$

Rangiranje: b) $39\,788,7 >$ c) $37\,722,1 >$ a) $31\,250 \text{ m}^2$. Razlika između najboljeg i najlošijeg oblika je oko **27 %** — a sve uz istu duljinu ograde. Odabir *strukture* (oblika) donosi veći dobitak nego optimiranje *dimenzija* unutar zadane strukture. To je uvod u sljedeći odjeljak.

1.11 Projektiranje kao proces

1.11.1 Slijed projektiranja

[str. 59]

Projektiranje tehničkog sustava ostvaruje se u **dva koraka**:

1. **izbor strukture** sustava, odnosno **strukturalne sinteze**;
2. **izbor brojčanih vrijednosti parametara** odabrane strukture (sinteza parametara ili **dimenzionalna sinteza**).

Strukturalna sinteza jest (glavni) zadatak **stvaralačkog djelovanja inženjera** koji je općenito teško ili nemoguće automatizirati (algoritmizirati).

To se izravno poklapa s primjerom ograde: odabir između oblika a), b), c) je strukturalna sinteza (kreativni čin), a računanje $x = 250$, $y = 125$ je dimenzionalna sinteza (algoritamski dio) — i baš je taj drugi dio ono što ovaj kolegij formalizira.

1.11.2 Strukturalna sinteza

[str. 60]

Struktura projektiranog tehničkog sustava ili objekta (**topologija konstrukcije**) određena je poznatim **skupom elemenata strukture** i **vezama među njima**.

Poteškoće koje se pojavljuju u formalizaciji problema strukturalne sinteze:

- nemjerljive karakteristike elemenata strukture;
- formalno nedefinirane veze između pojedinih elemenata i zahtjeva;
- kvalitativni kriteriji;
- neformalan opis funkcioniranja projektiranog objekta;
- zahtjevi koji se odnose na funkcioniranje objekta.

Temelj sinteze tehničkih sustava jest: skup znanja i iskustva projektanata, intuicija, kreativnost, literatura, izvedeni projekti, sheme mogućih rješenja, metode projektiranja, računalna i programska podrška.

Opis elemenata strukture, opis veza među njima kao i formiranje matematičkog modela strukture definira se pomoću prikladnog (konačnog) skupa veličina: to su **projektni parametri**.

1.11.3 Cilj projektiranja?

[str. 61--67]

1. Gradnja sustava s besprijekornim funkcioniranjem se **danas podrazumijeva**.
2. U uvjetima konkurencije od presudne je važnosti projektirati **najbolji ili što bolji** sustav (objekt ili proizvod).
3. Kriteriji po kojima je neki sustav najbolji su različiti, primjerice: **cijena, težina, efikasnost, oblik, praktičnost, kompleksnost, originalnost, pouzdanost, trajnost** i sl.
4. **Izbor dominantnog kriterija** predstavlja **stratešku odluku** na početku samog procesa projektiranja. Kvaliteta rješenja ocjenjuje se **kvantitativnom** usporedbom odabranih kriterija, koji stoga moraju biti **funkcijom projektnih parametara**.

5. Izbor projektnih parametara najčešće **nije slobodan**, već njihove veličine moraju zadovoljiti neke unaprijed zadane uvjete ili **ograničenja**. Također trebaju biti ispunjeni uvjeti **međusobne ovisnosti** parametara koji slijede iz strukture projektiranog sustava.
6. Projektiranje je stoga **iterativni proces** određivanja strukture i projektnih parametara projektiranog sustava, konstrukcije ili proizvoda.
7. Konačnim projektnim rješenjem trebaju se ispuniti **svi** kriteriji i tehnički zahtjevi projekta.

Točka 4 je zapravo definicija **funkcije cilja** rečena inženjerskim jezikom („kriterij mora biti funkcija projektnih parametara”), a točka 5 definicija **ograničenja**. Time se zatvara krug s odjeljkom 1.2.

1.11.4 Proces projektiranja

[str. 68]

Prema primijenjenim metodama i projektnim zahtjevima proces projektiranja može biti:

- a) **Proces konvencionalnog projektiranja.** Osnovni cilj: besprijeckorno funkcioniranje sustava ili proizvoda u okviru uvjeta postavljenih projektnim zadatkom (*funkcionalno projektiranje*). Ovaj proces baziran je na **iskustvu i intuiciji**.
- b) **Proces optimalnog projektiranja.** Pored besprijeckornog funkcioniranja sustava ili proizvoda, **jedan ili više projektnih kriterija treba biti ispunjen na optimalan način**. Postupak optimalnog projektiranja zahtijeva **strogu matematičku formulaciju problema** — postavku matematičkog modela ili optimizacijskog problema.

1.11.5 Elementi optimizacijskog modela: projektni parametri i varijable

[str. 69--70]

Definicija 1.6: Projektni parametri

Projektni parametri su veličine pomoću kojih se **jednoznačno definiraju dimenzije i svojstva** konstrukcije ili projektiranog sistema.

Projektni parametri dijele se na **konstantne projektne parametre** i **projektne varijable**.

Konstantni projektni parametri se u postupku optimizacije **ne mijenjaju**, a mogu se podijeliti na dvije vrste:

- **taktički projektni parametri** (z) — zadani su **projektnim zadatkom** i ne mogu se mijenjati u cijelom procesu projektiranja. Oni su konstante strukturalne i dimenzionalne sinteze konstrukcije, tj. predstavljaju **taktičke performanse** projektiranog sustava.
- **tehnički projektni parametri** (y) — projektne su konstante **po zamisli projektanta**, i to prvenstveno iz **konstrukcijskih ili tehnoloških** razloga.

Hijerarhija sa slajda 70:

PROJEKTNİ PARAMETRI	
PROJEKTNE VARIJABLE	PROJEKTNE KONSTANTE
x	y, z
	TEHNIČKI y TAKTIČKI z
	(odabrani od pro- (zadani projekt- jektanta) nim zadatkom)

Dodatne tvrdnje sa slajda 70:

- Tehnički parametri su konstante **samo kod dimenzionalne sinteze već poznate strukture (topologije)** objekta.
- Projektant može mijenjati broj tehničkih parametara njihovim **prebacivanjem u projektne varijable i obrnuto**.
- Projektni parametri koji se **mijenjaju** u postupku sinteze nazivaju se **projektnim varijablama** (x).
- **Suma broja projektnih varijabli i tehničkih parametara** u postupku optimizacije iste strukture sistema je **konstantna**.
- Ispravan izbor projektnih parametara i odgovarajuća matematička formulacija problema glavne su poteškoće i preduvjeti uspješnog postupka optimalnog projektiranja.

Napomena: veza sa standardnom formom

Vektor x iz standardne forme = projektne varijable. Parametri y i z ne pojavljuju se kao nepoznanice, nego kao **brojevi** u izrazima za f , h i g . U primjeru ograde: x i y (dimenzije) su projektne varijable, a 10 000 m² je taktički parametar (zadan zadatkom).

1.11.6 Optimizacijski model — pravila izbora parametara

[str. 71--77]

Kod izbora projektnih parametara važno je sljedeće:

1. Projektant treba dobro **proučiti problem** i matematički ga opisati pomoću projektnih varijabli;
2. Projektni parametri trebaju biti **nezavisni**;
3. Problem treba opisati sa **što manje** projektnih parametara;
4. Matematičku formulaciju problema treba u **početnoj fazi** provesti sa **što manjim brojem tehničkih parametara**; to je važno radi fleksibilnosti algoritma i otklanjanja eventualnih pogrešnih procjena o utjecaju nekih tehničkih parametara na rezultat. U **kasnijoj fazi** mogu se neke od varijabli odabrati kao konstante, i to:
 - iz **konstrukcijskih ili tehnoloških** razloga;
 - jer je utvrđeno da **ne utječu bitno** na konačni rezultat optimizacije;
 - jer je utvrđeno da optimalno rješenje odgovara **uvijek vrijednosti neke varijable na rubu ograničenja**.

Napomena

Zašto pravilo 2 (nezavisnost)? Ako su dvije varijable povezane (npr. uvedemo i polumjer r i promjer $d = 2r$), ograničenje $d = 2r$ postaje suvišna jednadžba, a problem numerički degenerira (rješenje nije jedinstveno u parametrima). Bolje je odabrati samo jednu od njih.

Zašto pravilo 3 (što manje parametara)? Broj varijabli n izravno određuje dimenziju prostora u kojem tražimo optimum i time složenost rješavanja.

Zadnja alineja pravila 4 najavljuje pojam **aktivnog ograničenja** iz poglavlja 3: ako znamo da optimum uvijek leži na rubu, možemo tu nejednakost zamijeniti jednakošću i eliminirati varijablu.

1.12 Neki korisni „trikovi“

[str. 79]

Ovaj slajd zatvara predavanje 1 i ponavlja se na početku predavanja 2.

1.12.1 Minimizacija $\Leftrightarrow$ maksimizacija

$$\begin{array}{ccc} \max_x f(x) & \Longleftrightarrow & \min_x -f(x) \\ \text{uz ogr. } x \in \mathcal{F} & & \text{uz ogr. } x \in \mathcal{F} \end{array} \quad (1.39)$$

Zašto to vrijedi. Ako f postiže svoju **najveću** vrijednost u točki x^* , onda $-f$ u istoj toj točki postiže svoju **najmanju** vrijednost (jer množenje s -1 „okreće“ os vrijednosti). Dakle:

- **argument** je isti: $\arg \max f = \arg \min(-f)$,
- **vrijednosti** su suprotne: $\max f = -\min(-f)$ — na to treba paziti kad izvještavate optimalnu vrijednost!

Zbog ovog trika **cijela teorija se može razviti samo za minimizaciju**, što i činimo u standardnoj formi iz odjeljka 1.2.

1.12.2 Provjera je li dozvoljeni skup prazan (problem dopustivosti)

Pitanje: Je li skup $\mathcal{F} = \{x \mid g_i(x) \leq 0, i = 1, \dots, p\}$ prazan? Ako nije, kako naći neki $x \in \mathcal{F}$?

Rješenje: riješi optimizacijski problem

$$\begin{array}{ccc} \min_{x,t} & t & \\ \text{uz ograničenja} & g_i(x) \leq t, & i = 1, \dots, p \end{array} \quad (1.40)$$

Neka je t^*, x^* rješenje. **Ako je $t^* \leq 0$, tada $\mathcal{F}$ nije prazan skup i $x^* \in \mathcal{F}$.**

Detaljno objašnjenje (jer je ideja lukavija nego što izgleda):

- Uvodimo **novu, pomoćnu varijablu** $t \in \mathbb{R}$. Sada minimiziramo po paru (x, t) , dakle problem ima $n + 1$ varijablu umjesto n .

- Za *bilo koji* x uvijek možemo naći dovoljno velik t da svi uvjeti $g_i(x) \leq t$ budu zadovoljeni (npr. $t = \max_i g_i(x)$). Zato **novi problem nikad nije nedopustiv** — uvijek ima rješenje, za razliku od polaznog.
- Funkcija cilja je samo t : guramo t što niže. Za fiksni x najmanji dopušteni t je točno $\max_i g_i(x)$ — „najgore prekršeno ograničenje”. Dakle problem (1.40) zapravo rješava

$$\min_x \max_i g_i(x)$$

tj. traži x koji **najmanje krši najgore ograničenje**.

- **Ako je $t^* \leq 0$:** tada je $g_i(x^*) \leq t^* \leq 0$ za sve i , dakle x^* zadovoljava **sva** izvorna ograničenja $\rightarrow x^* \in \mathcal{F}$ i skup nije prazan. Bonus: dobili smo i konkretnu dopuštenu točku.
- **Ako je $t^* > 0$:** ne postoji nijedan x za koji su sva $g_i(x) \leq 0$ (jer bi za takav x vrijednost $t = 0$ bila dopuštena i dala manji cilj od t^*) $\rightarrow \mathcal{F}$ **je prazan**.

Napomena: faza I

Ovaj se postupak zove **faza I** (engl. *phase I*) i standardni je prvi korak svakog ozbiljnog optimizacijskog algoritma: prije nego što tražimo *najbolju* dopuštenu točku, moramo naći *bilo koju*. Uočite i tehniku: **uvodenje pomoćne varijable koja „gura” min--max u obični min** — istu ćemo tehniku sresti kod norma (Vježbe 2, poglavlje 2) i kod robusnog optimiranja (poglavlje 8).

1.13 Sažetak poglavlja

Što morate znati napamet nakon ovog poglavlja:

1. **Standardna forma:** $\min f(x)$ uz $h(x) = 0$, $g(x) \leq 0$; što je x , f , h , g , i što je dozvoljeni skup $\mathcal{F} = \{x \mid h(x) = 0, g(x) \leq 0\}$.
2. **Definicija optimalnog rješenja x^*** (dopustivo i najmanji f).
3. **Nivo krivulja** $\{x \mid f(x) = c\}$ i kako se iz slike nivo krivulja + dozvoljenog skupa očita optimum (odjeljak 1.3).
4. **Prevođenje u standardnu formu:** premještanje konstante na lijevu stranu, okretanje „ $\geq$ ” množenjem s -1 , $\max f \Leftrightarrow \min(-f)$.
5. **Recept klasične analize** (eliminacija ograničenja jednakosti uvrštavanjem $+ F' = 0$ + provjera s F'') — i svijest da on ne funkcionira općenito, zbog čega nam trebaju poglavlja 3 i 4.
6. **Problem dopustivosti** (1.40) i njegova interpretacija.

Terminologija (hrvatski $\leftrightarrow$ engleski):

Hrvatski	Engleski
projektne varijable / varijable odluke	decision variables
funkcija cilja / ciljna funkcija	objective function
ograničenja jednakosti	equality constraints
ograničenja nejednakosti	inequality constraints
dozvoljeni skup / dozvoljeno područje	feasible set
nivo krivulja	level curve / contour
dimenzionalna optimizacija	size optimization
optimiranje oblika	shape optimization
topološka optimizacija	topology optimization

POGLAVLJE 2

Definicije, klasifikacija, konveksnost

Izvori: 02_Definicije_klasifikacija_konveksnost.pdf (str. 1--72), Vjezbe_1.pdf (str. 1--34) i Vjezbe_2.pdf (str. 1--11) — sve obrađeno u cijelosti.

Zadaci iz Vježbi 1 i 2 umetnuti su **odmah iza teorije koju koriste**, a ne na kraju poglavlja. Oznaka [str. V1:20] znači „Vježbe 1, stranica 20”.

Napomena: zadaci rješavani na ploči

Kod Zadataka 1--4 iz Vježbi 1 na slajdu piše samo „*Rješenje na ploči (Bilježiti!)*” — **u izvorniku nema zapisanog rješenja**, jer je ono izvedeno na ploči. U ovoj skripti ti su zadaci riješeni korištenjem **isključivo definicija i tvrdnji s istih tih vježbi**, i to je na svakom mjestu izričito označeno. Kod Zadataka 3 i 4 izvornik uz to nema ni sliku na koju se poziva, pa je ovdje uzet konkretan primjer istog tipa.

2.1 Podsjetnik: standardna forma i „trikovi”

[str. 3--5]

Predavanje 2 počinje ponavljanjem standardne forme iz odjeljka 1.2:

$$\begin{array}{ll} \text{minimiziraj} & f(x) \\ \text{uz ograničenja} & h(x) = 0, \quad g(x) \leq 0 \end{array} \quad \mathcal{F} = \{x \mid h(x) = 0, g(x) \leq 0\} \quad (2.1)$$

te oba „trika” iz odjeljka 1.12: pretvorbu $\max f \Leftrightarrow \min(-f)$ i problem dopustivosti (1.40). Ako vam ta dva mjesta nisu potpuno jasna, vratite se na njih prije nastavka — koristit ćemo ih stalno.

2.2 Osnovni matematički alat

Ovaj odjeljak pokriva Vježbe 1, str. 2--19. To je jezik kojim je pisano sve ostalo u kolegiju.

2.2.1 Vektori i matrice

[str. V1:2--3]

Definicija 2.1: Vektor i matrica

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \quad A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & a_{22} & \dots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nm} \end{pmatrix} \in \mathbb{R}^{n \times m}$$

Čitanje oznaka od nule:

- $x \in \mathbb{R}^n$: x je **stupčani vektor** s n redaka. Broj x_i je i -ta **komponenta**.
- $A \in \mathbb{R}^{n \times m}$: matrica s n **redaka** i m **stupaca**. Element a_{ij} nalazi se u i -tom retku i j -tom stupcu. *Prvi indeks je uvijek redak, drugi stupac* — to je konvencija koju treba zapamtiti odmah.

Primjeri sa slajda:

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \in \mathbb{R}^3, \quad M = \begin{pmatrix} m_{11} & m_{12} & m_{13} \\ m_{21} & m_{22} & m_{23} \end{pmatrix} \in \mathbb{R}^{2 \times 3}$$

Transponiranje (primjeri sa slajda):

$$x^\top = (x_1 \ x_2 \ x_3) \in \mathbb{R}^{1 \times 3}, \quad M^\top = \begin{pmatrix} m_{11} & m_{21} \\ m_{12} & m_{22} \\ m_{13} & m_{23} \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

Što transponiranje radi: zamjenjuje retke i stupce. Element koji je bio na mjestu (i, j) prelazi na mjesto (j, i) . Stupčani vektor postaje retčani. Dimenzije se obrnu: $n \times m$ postaje $m \times n$.

Napomena: zašto nam treba transponiranje

Množenje matrica traži da se dimenzije „poklope”: $A B$ ima smisla samo ako A ima onoliko stupaca koliko B ima redaka. Ako su $x, y \in \mathbb{R}^n$ oba stupčani, $x y$ nema smisla ($n \times 1$ puta $n \times 1$), ali $x^\top y$ ima ($1 \times n$ puta $n \times 1 = 1 \times 1$, dakle broj). Zato ćemo skalarni produkt uvijek pisati kao $x^\top y$.

2.2.2 Funkcije

[str. V1:4--6]

Definicija 2.2: Skalarna funkcija više varijabli

Notacija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ označava f kao funkciju koja mapira vektor iz $\mathbb{R}^n$ u **realan broj (skalar)**.

Primjeri sa slajda [str. V1:4]:

- $f : \mathbb{R}^4 \rightarrow \mathbb{R}$ definirana s $f(x) = x_1 - x_3^2 + x_1 x_4$
- $f : \mathbb{R} \rightarrow \mathbb{R}$ definirana s $f(x) = \sin(x) + \cos(x)$

- $f : \mathbb{R}^4 \rightarrow \mathbb{R}$ definirana s $f(x) = 5x_1 + 2x_2 - 7x_3 + 10x_4 + 6$
- $f : \mathbb{R}^4 \rightarrow \mathbb{R}$ definirana s $f(x) = x_1 - 2x_2 + 5x_3 - x_4$

Definicija 2.3: Vektorska funkcija

Funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ mapira vektore iz $\mathbb{R}^n$ u vektore iz $\mathbb{R}^m$:

$$f(x) = \begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_m(x) \end{pmatrix}$$

gdje su $f_i(x)$ **skalarne** funkcije ($f_i : \mathbb{R}^n \rightarrow \mathbb{R}$).

Dakle: vektorska funkcija je samo „hrpa” skalarnih funkcija složenih jedna ispod druge. Svaka od njih uzima *isti* ulazni vektor x .

Primjeri sa slajda [str. V1:6]:

$$f : \mathbb{R}^4 \rightarrow \mathbb{R}^2, \quad f(x) = \begin{pmatrix} x_1 - x_3^2 + x_1x_4 \\ x_2 \end{pmatrix}; \quad f : \mathbb{R} \rightarrow \mathbb{R}^2, \quad f(x) = \begin{pmatrix} \sin(x) + \cos(x) \\ x^2 - 5 \end{pmatrix}$$

2.2.3 Linearne funkcije

[str. V1:7--9]

Definicija 2.4: Linearnost

Neka su U, V linearni prostori. Preslikavanje $f : U \rightarrow V$ je **linearno** ako ima sljedeća svojstva:

- **Aditivnost:** $f(x + y) = f(x) + f(y)$, za sve $x, y \in U$
- **Homogenost:** $f(\alpha x) = \alpha f(x)$, za sve skalare α i za sve $x \in U$

Što ta dva svojstva praktično znače. Ako znate odgovor za dva ulaza, znate ga i za njihov zbroj; ako znate odgovor za jedan ulaz, znate ga i za bilo koje njegovo skaliranje. Zajedno se to zove **princip superpozicije** — i on je razlog zašto su linearni modeli u inženjerstvu toliko moćni.

Pitanje sa slajda [str. V1:8]: koje od navedenih funkcija su linearne?

Funkcija	Linearna?
$f(x) = x_1 - x_3^2 + x_1x_4$	ne — ima kvadrat i umnožak varijabli
$f(x) = \sin(x) + \cos(x)$	ne — npr. $\cos(0) = 1 \neq 0$
$f(x) = 5x_1 + 2x_2 - 7x_3 + 10x_4 + 6$	ne — slobodni član 6; ovo je <i>afina</i>
$f(x) = x_1 - 2x_2 + 5x_3 - x_4$	da

Kako se to brzo provjeri: linearna funkcija nužno mora dati $f(0) = 0$ (jer iz homogenosti $f(0) = f(0 \cdot 0) = 0 \cdot f(0) = 0$). Ako uvrštavanje nule ne da nulu, funkcija sigurno *nije* linearna

— to odmah izbacuje treću funkciju (daje 6) i drugu (daje 1). Prva funkcija daje nulu u nuli, ali pada na aditivnosti: npr. za članove x_3^2 vrijedi $(a+b)^2 \neq a^2 + b^2$.

Drugi popis sa slajda [str. V1:9]:

$$f: \mathbb{R}^4 \rightarrow \mathbb{R}^2, f(x) = \begin{pmatrix} x_1 - x_3 + x_1x_4 \\ x_2 \end{pmatrix}; \quad f: \mathbb{R} \rightarrow \mathbb{R}^2, f(x) = \begin{pmatrix} 3x \\ x - 5 \end{pmatrix};$$

$$f: \mathbb{R}^3 \rightarrow \mathbb{R}^3, f(x) = \begin{pmatrix} -x_1 + x_2 \\ 3x_2 + 4x_3 \\ x_1 - 3x_2 + 2x_3 \end{pmatrix}$$

Funkcija	Linearna?
prva	ne — član x_1x_4
druga	ne — druga komponenta ima -5 ; <i>afina</i>
treća	da

2.2.4 Matrični zapis linearne funkcije

[str. V1:10--17]

Teorem 2.1: Matrični prikaz

Ako je $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ **linearna** funkcija onda postoji matrica $A \in \mathbb{R}^{m \times n}$ takva da je

$$f(x) = Ax$$

Ako je $f: \mathbb{R}^n \rightarrow \mathbb{R}$ **skalarna linearna** funkcija onda postoji vektor $a \in \mathbb{R}^n$ takav da je

$$f(x) = a^\top x$$

Ovo je vrlo jaka tvrdnja: *svaka* linearna funkcija je množenje matricom, i obrnuto. Zato u optimizaciji linearne funkcije nikad ne pišemo raspisano, nego uvijek kao Ax ili $a^\top x$.

Zadatak sa slajda [str. V1:11]: zapišite linearne funkcije s prethodnih slajdova u ovom obliku. Slajdovi 12--17 daju rješenje.

Skalarni slučaj [str. V1:14]:

$$f(x) = x_1 - 2x_2 + 5x_3 - x_4 = \begin{pmatrix} 1 & -2 & 5 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = a^\top x$$

Kako se čita: koeficijent uz x_i postaje i -ta komponenta vektora a . Ovdje $a = (1, -2, 5, -1)^\top$.

Vektorski slučaj [str. V1:16]:

$$f(x) = \begin{pmatrix} -x_1 + x_2 \\ 3x_2 + 4x_3 \\ x_1 - 3x_2 + 2x_3 \end{pmatrix} = \begin{pmatrix} -1 & 1 & 0 \\ 0 & 3 & 4 \\ 1 & -3 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = Ax$$

Kako se čita: i -ti **redak** matrice A su koeficijenti i -te komponente funkcije. Prvi redak $(-1, 1, 0)$ jer je $f_1 = -x_1 + 1 \cdot x_2 + 0 \cdot x_3$. Uočite da se koeficijent 0 mora napisati — prazno mjesto ne postoji.

2.2.5 Afine funkcije

[str. V1:17–19]

Definicija 2.5: Afina funkcija

Funkcija $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ je **afina** ako se može prikazati u obliku

$$f(x) = Ax + b$$

(afina funkcija = linearna funkcija + konstanta).

Kod afinih funkcija općenito **ne** vrijedi svojstvo aditivnosti i homogenosti (afino $\neq$ linear-
no).

Primjeri sa slajda [str. V1:17]:

$$f(x) = 5x_1 + 2x_2 - 7x_3 + 10x_4 + 6 = \begin{pmatrix} 5 & 2 & -7 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} + 6 = a^\top x + b$$

$$f(x) = \begin{pmatrix} 3x \\ x - 5 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix} x + \begin{pmatrix} 0 \\ -5 \end{pmatrix} = Ax + b$$

Slika sa slajda [str. V1:19]. Slajd prikazuje četiri pravca u ravnini $(x, f(x))$:

- $f_1(x) = a_1x + b_1$ i $f_2(x) = a_2x + b_2$ — **afine** funkcije; njihovi pravci *ne* prolaze kroz ishodište (jedan raste, drugi pada);
- $f_3(x) = a_3x$ i $f_4(x) = a_4x$ — **linearne** funkcije; njihovi pravci *prolaze kroz ishodište*.

Napomena: najčešća zabuna u cijelom kolegiju

U srednjoj školi se „linearna funkcija” obično zove $y = kx + l$. **To je afina funkcija.** U ovom kolegiju *linear*no strogo znači $f(0) = 0$, tj. pravac kroz ishodište. Razlika je bitna: kod konveksnih problema ograničenja jednakosti smiju biti *afina* ($a^\top x = b$), a ne samo linearna.

Zadatak 2.1 — Vježbe 1, Zadatak 1: linearne funkcije („superpozicija”)

[str. V1:20]

Postavka. Sile: w_1, w_2, w_3 ; progib: $s(w_1, w_2, w_3)$. Ako znamo da je

$$s(1, 0, 0) = 0,12, \quad s(0, 1, 0) = 0,31, \quad s(0, 0, 1) = 0,26,$$

i da je s **linearna** funkcija, koliko je $s(0,5; 1,1; 0,3)$?

Rješenje. (Izvornik upućuje na ploču; niže je izvod koji koristi isključivo definiciju *linear*nosti i matični prikaz sa str. V1:7 i V1:10.)

Korak 1 — što nam je zapravo dano. Vektori $e_1 = (1, 0, 0)^\top$, $e_2 = (0, 1, 0)^\top$, $e_3 = (0, 0, 1)^\top$ zovu se **jedinični vektori** baze. Dano nam je koliko iznosi progib kad djeluje

samo jedna jedinična sila, jedna po jedna.

Korak 2 — rastav ulaza. Bilo koji vektor sila rastavlja se na zbroj:

$$w = \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = w_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + w_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} + w_3 \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = w_1 e_1 + w_2 e_2 + w_3 e_3$$

Korak 3 — primjena aditivnosti ($s(x+y) = s(x) + s(y)$, primijenjeno dvaput):

$$s(w) = s(w_1 e_1 + w_2 e_2 + w_3 e_3) = s(w_1 e_1) + s(w_2 e_2) + s(w_3 e_3)$$

Korak 4 — primjena homogenosti ($s(\alpha x) = \alpha s(x)$, na svaki član):

$$s(w) = w_1 s(e_1) + w_2 s(e_2) + w_3 s(e_3)$$

To je upravo princip superpozicije: *ukupan progib je zbroj progiba od pojedinih sila.*

Korak 5 — uvrštavanje poznatih vrijednosti.

$$s(w) = 0,12 w_1 + 0,31 w_2 + 0,26 w_3 = \begin{pmatrix} 0,12 & 0,31 & 0,26 \end{pmatrix} w = a^\top w$$

uz $a = (0,12; 0,31; 0,26)^\top$. Time smo, usput, funkciju s zapisali u matričnom obliku sa str. V1:10.

Korak 6 — traženi broj. Za $w = (0,5; 1,1; 0,3)^\top$:

$$s(0,5; 1,1; 0,3) = 0,12 \cdot 0,5 + 0,31 \cdot 1,1 + 0,26 \cdot 0,3 \quad (2.2)$$

$$= 0,060 + 0,341 + 0,078 \quad (2.3)$$

$$= \boxed{0,479} \quad (2.4)$$

Kontrola pojedinih umnožaka: $0,12 \cdot 0,5 = 0,06$; $0,31 \cdot 1,1 = 0,31 + 0,031 = 0,341$; $0,26 \cdot 0,3 = 0,078$. Zbroj: $0,06 + 0,341 = 0,401$, pa $0,401 + 0,078 = 0,479$. ✓

Poanta zadatka. Za linearan sustav dovoljno je izmjeriti odziv na n jediničnih pobuda i onda znamo odziv na *bilo koju* kombinaciju — bez ijednog dodatnog mjerenja. To je temelj cijele linearne teorije konstrukcija i upravljanja.

2.3 Nivo krivulje

[str. V1:21]

Definicija 2.6: Nivo krivulja

Nivo krivulja funkcije $f: \mathbb{R}^n \rightarrow \mathbb{R}$ je skup

$$\mathcal{S}_c := \{x \mid f(x) = c\},$$

gdje konstanta c definira **nivo** (razinu).

Kako to zamisliti. Zamislite f kao visinu terena iznad točke x . Nivo krivulja je onda **izohipsa** na zemljovidu — linija koja spaja sve točke iste nadmorske visine. Hodanjem po nivo krivulji vrijednost funkcije se *ne mijenja*.

Primjer sa slajda [str. V1:21]: nivo krivulje funkcije $f(x_1, x_2) = x_1 x_2 e^{-x_1^2 - x_2^2}$. Slajd uz to daje

MATLAB kod kojim je slika napravljena:

```
[X,Y] = meshgrid(-2:0.1:2, -2:0.1:2);
Z = X.*Y.*exp(-X.^2-Y.^2);
[C,h] = contour(X,Y,Z);
set(h,'ShowText','on','TextStep',get(h,'LevelStep')*2)
```

Zadatak 2.2 — Vježbe 1, Zadatak 2: nivo krivulje linearnih funkcija

[str. V1:22 i V1:27]

Postavka. Za vektor $a = \begin{pmatrix} 2 & 1 \end{pmatrix}^\top$, skicirajte nivo krivulje funkcije $f(x) = a^\top x$.

Rješenje. (Izvornik upućuje na ploču; izvod niže koristi samo definiciju nivo krivulje sa str. V1:21 i matični prikaz sa str. V1:10.)

Korak 1 — raspis funkcije. Za $a = (2, 1)^\top$ i $x = (x_1, x_2)^\top$:

$$f(x) = a^\top x = \begin{pmatrix} 2 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 2x_1 + 1 \cdot x_2 = 2x_1 + x_2$$

Korak 2 — jednadžba nivo krivulje. Po definiciji, $\mathcal{S}_c = \{x \mid f(x) = c\}$, dakle

$$2x_1 + x_2 = c$$

Korak 3 — prepoznavanje oblika. Riješimo po x_2 :

$$x_2 = c - 2x_1$$

To je **pravac** s nagibom -2 i odsječkom c na osi x_2 .

Zaključak: nivo krivulje linearne funkcije su **paralelni pravci**. Nagib -2 ne ovisi o c — mijenja se samo odsječak, pa različiti nivoi daju samo pomaknute kopije istog pravca.

Korak 4 — konkretni pravci. Uvrstimo nekoliko vrijednosti c :

c	-4	-2	0	2	4
jednadžba	$x_2 = -4 - 2x_1$	$x_2 = -2 - 2x_1$	$x_2 = -2x_1$	$x_2 = 2 - 2x_1$	$x_2 = 4 - 2x_1$
sjecište s osi x_2	-4	-2	0	2	4
sjecište s osi x_1	-2	-1	0	1	2

Provjera jednog retka: za $c = 2$, sjecište s osi x_1 dobiva se za $x_2 = 0$: $2x_1 = 2 \Rightarrow x_1 = 1$. ✓

Korak 5 — gdje je tu vektor a ? Uzmimo dvije točke istog nivoa, npr. na pravcu $c = 0$: $P = (0, 0)$ i $Q = (1, -2)$. Vektor smjera tog pravca je $d = Q - P = (1, -2)^\top$. Sada izračunajmo:

$$a^\top d = \begin{pmatrix} 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = 2 \cdot 1 + 1 \cdot (-2) = 2 - 2 = 0$$

Skalarni produkt je nula, dakle (vidi odjeljak 2.4) **vektor a je okomit na nivo krivulje**. To vrijedi za svaku linearnu funkciju i sve njene nivo krivulje.

Korak 6 — u kojem smjeru f raste? Pomaknimo se iz $(0, 0)$ u smjeru a , za mali korak $\alpha > 0$: točka $x = \alpha a = (2\alpha, \alpha)$. Tada

$$f(\alpha a) = 2(2\alpha) + \alpha = 5\alpha > 0 = f(0, 0)$$

Dakle pomak u smjeru a **povećava f** : vektor a pokazuje u smjeru rasta. (U odjeljku 2.9 vidjet ćemo da je a upravo gradijent funkcije f .)

Kako to nacrtati rukom: nivo krivulje linearne funkcije

Korak 1. Nacrtajte osi x_1 (vodoravno) i x_2 (okomito), obje od -3 do 4 , s **jednakim mjerilom**.

Korak 2. Nacrtajte prvi pravac, onaj za $c = 0$: prolazi kroz ishodište i kroz točku $(1, -2)$. Označite ga s „ $c = 0$ ”.


Korak 3. Dodajte pravac za $c = 2$: isti nagib, ali podignut — siječe os x_2 u 2 i os x_1 u 1 . Uočite da je **paralelan** prethodnome; to je ključno zapažanje ovog zadatka.

Korak 4. Dodajte još pravce za $c = -4, -2, 4, 6, 8$ na isti način. Dobit ćete „ljestve” jednako razmaknutih paralelnih pravaca. Razmak je jednak jer su i razlike nivoa jednake (po 2).

Korak 5. Iz ishodišta nacrtajte vektor $a = (2, 1)$: dvije jedinice desno, jednu gore. Označite pravi kut između a i pravca $c = 0$ — upravo smo u koraku 5 računom pokazali da su okomiti.

Korak 6. Uz strelicu a napišite „smjer rasta f ”. Nivoi rastu kako se pomičemo u smjeru strelice: $c = 0 \rightarrow c = 2 \rightarrow c = 4 \rightarrow \dots$

Što graf znači. Da minimiziramo $f(x) = a^\top x$ na nekom dozvoljenom skupu, pomicali bismo se *suprotno* od a dokle god možemo. Zato kod linearnog programiranja (poglavlje 5) optimum uvijek završi na **rubu** dozvoljenog skupa — linearna funkcija nema unutarnji minimum.



Slika 2.1: Nivo krivulje funkcije $f(x) = a^\top x$ za $a = (2, 1)^\top$: paralelni pravci $2x_1 + x_2 = c$. Vektor a okomit je na njih i pokazuje u smjeru rasta.

2.4 Skalarni produkt vektora

Definicija 2.7: Skalarni produkt

Za dva vektora iste dimenzije $x, y \in \mathbb{R}^n$, **skalarni produkt** (unutarnji produkt, engl. *inner product*) definiran je:

$$\langle x, y \rangle := x^\top y = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

Alternativno:

$$\langle x, y \rangle = \|x\| \cdot \|y\| \cos(\varphi),$$

gdje je $\|x\| = \sqrt{x_1^2 + \cdots + x_n^2}$, a kut φ je kut između vektora.

Dvije formule, isti broj — i baš u tome je njihova vrijednost:

- **prva** je *računska*: daje broj iz komponenata, bez ikakve geometrije;
- **druga** je *geometrijska*: kaže da taj broj mjeri koliko su vektori „poravnati”. Duljine $\|x\|, \|y\|$ su uvijek pozitivne, pa **predznak skalarnog produkta ovisi samo o** $\cos \varphi$.

Ključna posljedica [str. V1:24]:

Teorem 2.2: Okomitost

Dva vektora x i y iz istog prostora su **okomita** ako i samo ako je njihov skalarni produkt jednak nuli:

$$x^\top y = y^\top x = 0$$

Zašto: $x^\top y = \|x\| \|y\| \cos \varphi$, a to je nula (uz $x, y \neq 0$) točno kad je $\cos \varphi = 0$, tj. kad je $\varphi = 90^\circ$.

Predznak skalarnog produkta — **slika sa slajda** [str. 36 i V1:25]. Slajd prikazuje tri situacije, u 2D i analogno u 3D. Fiksiramo y i gledamo gdje smije biti x :

Uvjet	Kut φ	Gdje leži x
$x^\top y > 0$	$\varphi < 90^\circ$	u poluprostoru <i>na strani</i> vektora y
$x^\top y = 0$	$\varphi = 90^\circ$	na hiperravnini okomitoj na y
$x^\top y < 0$	$\varphi > 90^\circ$	u poluprostoru <i>nasuprot</i> vektoru y

U 3D je „granica” ravnina, u n dimenzija hiperravnina — ali slika je uvijek ista. To je geometrijski temelj cijelog odjeljka 2.14.

Važno zapažanje sa slajda [str. V1:23]: za *fiksni* x , skalarni produkt $x^\top y$ je **skalarna linearna funkcija** od y . Time se zatvara krug: linearne funkcije = skalarni produkti s nekim fiksnim vektorom.

2.5 Klasifikacije optimizacijskih problema

[str. 6--11]

Polazimo od problema: *minimiziraj* $f(x)$ *uz ograničenja* $x \in \mathcal{F}$. Slajdovi ga dijele po tri kriterija.

2.5.1 Prema postojanju ograničenja

[str. 7]

- **Problem sa ograničenjima:** ako je $\mathcal{F}$ definiran ograničenjima tipa $g(x) \leq 0$, $h(x) = 0$.
- **Problem bez ograničenja:** npr. ako je $\mathcal{F} = \mathbb{R}^n$.

2.5.2 Prema karakteru projektnih varijabli / dozvoljenom skupu

[str. 8]

- **diskretan problem:** ako je $\mathcal{F}$ konačan skup;
- **kontinuiran problem:** ako $\mathcal{F}$ nije diskretan;
- **problem cjelobrojnog optimiranja** (*integer optimization*): ako su projektne varijable cijeli brojevi;
- **mješovit problem** s cjelobrojnim i kontinuiranim varijablama („*mixed integer problem*”), npr.:
 - „mixed integer linear programming (MILP)”,
 - „mixed integer quadratic programming (MIQP)”.

2.5.3 Prema karakteristikama funkcije cilja i ograničenja

[str. 9–10]

- Linearno programiranje nasuprot nelinearnom programiranju
- Konveksno optimiranje nasuprot nekonveksnom optimiranju

„**Stara podjela svijeta optimiranja**” [str. 9]. Slajd prikazuje shemu: veliki pravokutnik podijeljen na uski dio **LP** (linearno programiranje) i veliki dio **nelinearno programiranje (ne-LP)**. Preko granice je isprekidanom linijom nacrtan oblak označen *konveksno optimiranje* — koji obuhvaća LP i *dio* nelinearnog. Poruka: nekad se mislilo da je bitna granica ona između linearnog i nelinearnog.

„**Moderna podjela svijeta optimiranja**” [str. 10 i 53]. Druga shema: sve je podijeljeno na **konveksno optimiranje** i **nekonveksno optimiranje**. Unutar konveksnog dijela ugniježđeni su, jedan u drugome:

$$\text{LP} \subset \text{CQP} \subset \text{SDP} \subset \text{konveksno optimiranje}$$

gdje je (legenda sa slajda):

- **LP** = linearno programiranje (poglavlje 5),
- **CQP** = konično kvadratno programiranje (poglavlje 6),
- **SDP** = semidefinitno programiranje (poglavlje 6).

Teorem 2.3: Poruka predavanja [str. 52]

Velika razlika nije u tome je li problem linearan ili nelinearan, već je li konveksan ili nekonveksan!

To je jedna od najvažnijih rečenica u cijelom kolegiju. Razlog ćemo vidjeti u odjeljku 2.13: kod konveksnih problema *svaki lokalni minimum je ujedno globalni*, pa ih znamo pouzdano i brzo riješiti bez obzira na to jesu li linearni.

2.5.4 Još karakterizacija

[str. 11]

- **Stohastički problem:** ako je $\mathcal{F}$ stohastički karakteriziran (opisan vjerojatnostima).
- **Robusno optimiranje:** ako su f i $\mathcal{F}$ okarakterizirani **nepoznatim (ali ograničenim)** parametrima. To je tema poglavlja 8.

Razlika između to dvoje: stohastički pristup zna *razdiobu* nesigurnosti i optimira očekivanje; robusni pristup zna samo *granice* unutar kojih parametar leži i štiti se od *najgoreg* slučaja.

2.6 Primjeri klasa problema

[str. 12--21]

Slajd 13 najavljuje četiri primjera: I) diskretan, II) kontinuiran, III) cjelobrojni, IV) mješoviti.

2.6.1 Primjer I — diskretan optimizacijski problem

[str. 14]

Slajd prikazuje **rešetkastu konstrukciju** (nosač od 7 štapova, oslonjen na dva mjesta, s vertikalnom silom F u čvoru A).

Oznake sa slajda:

L_i	duljina i -tog štapa
D_i	presjek i -tog štapa
w	progib točke A uslijed zadane sile F
σ_i	naprezanje u i -tom štapu
$\mathcal{D}$	skup standardnih presjeka štapova

Optimizacijski problem:

$$\begin{aligned}
 \min_{D_1, \dots, D_5} \quad & \sum_{i=1}^7 L_i D_i && (\text{min masa konstrukcije}) \\
 \text{uz ograničenja} \quad & w \leq w_{\max} && (2.5) \\
 & \sigma_{i,\min} \leq \sigma_i \leq \sigma_{i,\max}, \quad i = 1, \dots, 7 \\
 & D_i \in \mathcal{D}, \quad i = 1, \dots, 7
 \end{aligned}$$

Objašnjenje:

- Funkcija cilja $\sum L_i D_i$ je **volumen** materijala (duljina puta presjek, zbrojeno po štapovima); pomnožena gustoćom to je masa. Zato piše „min masa konstrukcije”.
- $w \leq w_{\max}$: konstrukcija ne smije biti previše mekana.
- $\sigma_{i,\min} \leq \sigma_i \leq \sigma_{i,\max}$: nijedan štap ne smije biti prenapregnut (ni na vlak ni na tlak).
- $D_i \in \mathcal{D}$: **ovo je ono što problem čini diskretnim**. Presjeci se ne biraju iz kontinuuma, nego iz *kataloga* standardnih profila. Skup $\mathcal{D}$ je konačan.

Napomena

Na slajdu piše $\min_{D_1, \dots, D_5}$ iako suma i ograničenja idu do 7 (očita omaška u prezentaciji; varijabli je sedam).

2.6.2 Primjer II — kontinuiran optimizacijski problem

[str. 15]

Isti nosač, iste oznake (bez skupa $\mathcal{D}$), ali zadnje ograničenje se mijenja:

$$\begin{aligned} \min_{D_1, \dots, D_5} \quad & \sum_{i=1}^7 L_i D_i && (\text{min masa konstrukcije}) \\ \text{uz ograničenja} \quad & w \leq w_{\max} && \\ & \sigma_{i,\min} \leq \sigma_i \leq \sigma_{i,\max}, \quad i = 1, \dots, 7 && \\ & D_{i,\min} \leq D_i \leq D_{i,\max}, \quad i = 1, \dots, 7 && \end{aligned} \quad (2.6)$$

Jedina razlika je zadnji redak: umjesto „ D_i iz kataloga” sada je „ D_i bilo gdje između donje i gornje granice”. Time dozvoljeni skup postaje **kontinuiran**.

Napomena: zašto je ta razlika tako velika

Kontinuirani problem se rješava derivacijama i gradijentima — alatima cijelog ovog kolegija. Diskretni se *ne može* tako riješiti (nema derivacije po varijabli koja skače iz jedne vrijednosti u drugu) i općenito je *mnogo* teži: u najgorem slučaju treba probati sve kombinacije iz kataloga. U praksi se često prvo riješi kontinuirani problem, pa se rezultat „zaokruži” na najbliži standardni profil.

2.6.3 Primjer III — cjelobrojno optimiranje: broj stabilnosti grafa

[str. 16–17]

Pojmovi od nule. Graf $\Gamma = (V, E)$ sastoji se od:

- V — skup **vrhova** (čvorova),
- E — skup **bridova** (veza), $E \subseteq V \times V$.

Definicija 2.8: Broj stabilnosti grafa (engl. *stability number*)

Maksimalan broj elemenata u podskupu S čvorova grafa, gdje **nijedan par čvorova iz S nije povezan bridom** grafa.

Dakle tražimo najveću skupinu međusobno „nepovezanih” čvorova.

Formulacija (verzija sa slajda 16):

$$\begin{aligned} \max \quad & \sum_{i=1}^n x_i \\ \text{uz ograničenja} \quad & x_i x_j = 0 \quad \text{za sve } (x_i, x_j) \in E \\ & x_i \in \{0, 1\}, \quad i = 1, \dots, n \end{aligned} \quad (2.7)$$

Kako to funkcionira:

- Svakom čvoru i pridružimo varijablu x_i koja je 1 ako je čvor u skupu S , a 0 ako nije. Takve varijable zovu se **binarne** ili *indikatorske*.
- $\sum_i x_i$ je onda **broj odabranih čvorova** — to maksimiziramo.
- $x_i x_j = 0$ za svaki brid: umnožak dvaju brojeva iz $\{0, 1\}$ je 1 samo ako su *oba* jedinice. Traženjem da umnožak bude nula zabranjujemo da oba kraja istog brida budu odabrana — točno ono što definicija traži.

Verzija sa slajda 17 zamjenjuje uvjet $x_i \in \{0, 1\}$ jednadžbom:

$$\begin{aligned} \max \quad & \sum_{i=1}^n x_i \\ \text{uz ograničenja} \quad & x_i x_j = 0 \quad \text{za sve } (x_i, x_j) \in E \\ & x_i^2 - x_i = 0, \quad i = 1, \dots, n \end{aligned} \tag{2.8}$$

Zašto je to isto: $x_i^2 - x_i = 0 \Leftrightarrow x_i(x_i - 1) = 0 \Leftrightarrow x_i = 0$ ili $x_i = 1$. Dakle jedna kvadratna jednadžba zamjenjuje pripadnost diskretnom skupu. Time je problem zapisan **isključivo jednadžbama** — ali po cijenu da ta jednadžba više nije afina, pa problem (kao što ćemo vidjeti u odjeljku 2.19) **nije konveksan**.

Primjer primjene sa slajda: izbor (pod)alfabeta za robusnu komunikaciju u problemu komunikacijskog kanala.

2.6.4 Primjer IV — „mixed integer programming”

[str. 18--21]

Problem: upravljanje plinskom i parnom turbinom u kogeneracijskom postrojenju.

Varijable [str. 18]:

Kontinuirane varijable	
u_1	referentna vrijednost za radnu točku parne turbine
u_2	tok pare u mlin za papir (dio postrojenja)
Diskretne varijable	
u_{l1}	„on/off” varijabla ($\{1, 0\}$) za plinsku turbinu
u_{l2}	„on/off” varijabla ($\{1, 0\}$) za parnu turbinu
Izlazi iz sustava	
y_1	potrošnja goriva u plinskoj turbini
y_2	električna snaga iz parne turbine
y_3	električna snaga iz plinske turbine

Logički zahtjev sa slajda 18: u_{l1} i u_{l2} moraju zadovoljavati logičku relaciju

$$u_{l2} = 1 \implies u_{l1} = 1$$

(parna turbina može raditi samo ako radi i plinska — jer para dolazi od ispušnih plinova plinske turbine).

Ostali logički zahtjevi [str. 19]:

$$\begin{array}{ll}
 u_{l1} = 0 \implies u_1 = 0 & u_{l1} \in \{0, 1\} \\
 u_{l1} = 1 \implies u_{1,\min} \leq u_1 \leq u_{1,\max} & u_{l2} \in \{0, 1\} \\
 u_{l2} = 0 \implies u_2 = 0 & u_1 \in \mathbb{R} \\
 u_{l2} = 1 \implies u_{2,\min} \leq u_2 \leq u_{2,\max} & u_2 \in \mathbb{R}
 \end{array}$$

„Ako je turbina isključena, njezina upravljačka veličina mora biti nula; ako je uključena, mora biti unutar radnog raspona.”

Pretvorba logike u nejednadžbe [str. 19]. Sve gornje relacije mogu se formulirati u obliku ograničenja:

$$\begin{aligned}
 u_{l2} = 1 \Rightarrow u_{l1} = 1 & \iff u_{l2} - u_{l1} \leq 0 \\
 & \iff u_{l1}u_{1,\min} \leq u_1 \leq u_{l1}u_{1,\max} \\
 & \iff u_{l2}u_{2,\min} \leq u_2 \leq u_{l2}u_{2,\max}
 \end{aligned}$$

Zašto to radi:

- $u_{l2} - u_{l1} \leq 0$: jedina zabranjena kombinacija je $u_{l2} = 1, u_{l1} = 0$, koja bi dala $1 - 0 = 1 > 0$. Sve ostale $(0-0, 0-1, 1-1)$ daju ≤ 0 . ✓
- $u_{l1}u_{1,\min} \leq u_1 \leq u_{l1}u_{1,\max}$: ako je $u_{l1} = 0$, obje granice postaju 0, pa je prisilno $u_1 = 0$. Ako je $u_{l1} = 1$, granice su $u_{1,\min}$ i $u_{1,\max}$. Jedna nejednadžba pokriva oba slučaja. ✓

Matrični zapis [str. 20]. Sve se skupa piše kao $Mu \leq 0$:

$$\begin{pmatrix} -1 & 0 & u_{1,\min} & 0 \\ 1 & 0 & -u_{1,\max} & 0 \\ 0 & -1 & 0 & u_{2,\min} \\ 0 & 1 & 0 & -u_{2,\max} \\ 0 & 0 & -1 & 1 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \\ u_{l1} \\ u_{l2} \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad (2.9)$$

Čitanje redak po redak (uz $u = (u_1, u_2, u_{l1}, u_{l2})^\top$):

- redak 1: $-u_1 + u_{1,\min}u_{l1} \leq 0$, tj. $u_{l1}u_{1,\min} \leq u_1$;
- redak 2: $u_1 - u_{1,\max}u_{l1} \leq 0$, tj. $u_1 \leq u_{l1}u_{1,\max}$;
- redci 3 i 4: isto za u_2 i u_{l2} ;
- redak 5: $-u_{l1} + u_{l2} \leq 0$, tj. $u_{l2} - u_{l1} \leq 0$. ✓

Intermezzo: logičke relacije kao mješovita cjelobrojna ograničenja [str. 21]. Slajd donosi tablicu („TABLE I: Basic conversion of logic relations into mixed integer inequalities”) koja isti postupak daje za sve osnovne logičke veze. Prenosim je u cijelosti; δ su binarne varijable, S logičke tvrdnje, M i m gornja odn. donja granica veličine $a^\top x$, a ε mali pozitivni broj:

	relacija	logika	mješovite cjelobrojne nejednadžbe
P1	AND ($\wedge$)	$S_1 \wedge S_2$	$\delta_1 = 1; \delta_2 = 1$
P2		$S_3 \Leftrightarrow (S_1 \wedge S_2)$	$-\delta_1 + \delta_3 \leq 0; -\delta_2 + \delta_3 \leq 0;$ $\delta_1 + \delta_2 - \delta_3 \leq 1$
P3	OR ($\vee$)	$S_1 \vee S_2$	$\delta_1 + \delta_2 \geq 1$
P4	NOT ($\sim$)	$\sim S_1$	$\delta_1 = 0$
P5	IMPLY ($\Rightarrow$)	$S_1 \Rightarrow S_2$	$\delta_1 - \delta_2 \leq 0$
P6	IFF ($\Leftrightarrow$)	$S_1 \Leftrightarrow S_2$	$\delta_1 - \delta_2 = 0$
P7		$[a^\top x \leq 0] \Rightarrow [\delta = 1]$	$a^\top x \geq \varepsilon + (m - \varepsilon)\delta$
P8		$[\delta = 1] \Rightarrow [a^\top x \leq 0]$	$a^\top x \leq M - M\delta$
P9		$[a^\top x \leq 0] \Leftrightarrow [\delta = 1]$	$a^\top x \leq M - M\delta;$ $a^\top x \geq \varepsilon + (m - \varepsilon)\delta$
P10	Mixed product	$z = \delta \cdot a^\top x$	$z \leq M\delta; z \geq m\delta;$ $z \leq a^\top x - m(1 - \delta);$ $z \geq a^\top x - M(1 - \delta)$

Poanta cijelog primjera IV: proizvoljna logika pogona („ako ovo, onda ono”) može se prevesti u **linearne nejednadžbe** uz uvođenje binarnih varijabli. Time inženjerski „if--then” opis postaje MILP koji rješavač može riješiti.

2.7 Rješenje optimizacijskog problema

[str. 22--27]

2.7.1 Lokalni i globalni minimizator

[str. 23]

Definicija 2.9: Terminologija

- $x^* \in \mathcal{F}$ je **globalni minimizator** ako

$$f(x^*) \leq f(x) \quad \text{za sve } x \in \mathcal{F} \text{ i } x \neq x^*$$

- Točka $x^* \in \mathcal{F}$ je **lokalni minimizator** ako postoji **otvorena okolina** $N \subset \mathcal{F}$ oko x^* tako da vrijedi

$$f(x^*) \leq f(x) \quad \text{za sve } x \in N \text{ i } x \neq x^*$$

- x^* je **striktni globalni minimizator** ili **striktni lokalni minimizator** ako u gornjim definicijama zamijenimo $\leq$ sa $<$.

Primjer otvorene okoline oko x^* je skup

$$N = \{x \in \mathcal{F} \mid \|x - x^*\| < \epsilon\}$$

za neki (obično mali) $\epsilon \in \mathbb{R}$.

Kako to čitati. $\|x - x^*\|$ je udaljenost od x do x^* , pa je N zapravo mala **kugla** polumjera ϵ oko x^* . Riječ *otvorena* znači da rub kugle nije uključen (piše $<$, ne $\leq$).

Razlika u jednoj rečenici: globalni minimizator je najbolji *od svih*; lokalni je najbolji *samo u svom susjedstvu*. Lokalni minimizator može biti bitno lošiji od globalnog — a numerički algoritmi tipično nalaze samo lokalne.

Slika sa slajda [str. 24]: 1D primjer. Prikazan je graf jako „valovite” funkcije na intervalu $x \in [0, 10]$, s vrijednostima otprilike u rasponu $[-8, 8]$, i s četiri označene točke:

Oznaka na slajdu	Približan položaj
striktni lokalni minimum	$x \approx 4,3, f \approx -4$
striktni globalni minimum	$x \approx 7,4, f \approx -7$
striktni lokalni maksimum	$x \approx 2,1, f \approx 2$
striktni globalni maksimum	$x \approx 8,3, f \approx 7,8$

Poanta slike: funkcija ima *mnogo* lokalnih ekstrema, a samo po jedan globalni minimum i maksimum. Globalni minimum je ujedno i lokalni — obratno ne vrijedi.

Slika sa slajda [str. 25]: 2D primjer. Prikazana je 3D površina $f(x_1, x_2)$ s više „bregova” i „dolina” (vrijednosti otprilike 0,8–1,3), a ispod nje su nacrtane pripadne nivo krivulje. Vidi se nekoliko odvojenih zatvorenih „bazena”, tj. nekoliko lokalnih minimuma. Ovakav problem je **nekonveksan**.

2.7.2 Infimum i supremum

[str. 26–27]

Ovi pojmovi rješavaju tehnički problem: što ako se „najbolja vrijednost” nikad ne postigne?

Definicija 2.10: Infimum

Neka je $S \subseteq \mathbb{R}$. Broj γ je **donja granica** od S ako za svaki $x \in S$ vrijedi $\gamma \leq x$.

Infimum od S je **najveća donja granica** od S i označava se s $\inf S$.

Kada je $\inf S \in S$ kaže se da je „**infimum postignut**” (engl. *infimum is attained/achieved*).

Definicija 2.11: Supremum

Neka je $S \subseteq \mathbb{R}$. Broj η je **gornja granica** od S ako za svaki $x \in S$ vrijedi $x \leq \eta$.

Supremum od S je **najmanja gornja granica** od S i označava se s $\sup S$.

Kada je $\sup S \in S$ kaže se da je „**supremum postignut**”.

Primjer 1 sa slajda [str. 27]:

$$S = \{x \mid x > 0\}, \quad \inf S = 0, \quad \text{infimum nije postignut}$$

Razrada. Skup je otvorena polupravica $(0, \infty)$. Svaki $\gamma \leq 0$ je donja granica. Najveća takva je $\gamma = 0$, dakle $\inf S = 0$. Ali $0 \notin S$ (jer S traži strogo $x > 0$), pa infimum nije postignut — *ne postoji najmanji pozitivan broj*. Za svaki kandidat $x > 0$ postoji manji, npr. $x/2$.

Napomena o notaciji sa slajda: često u literaturi, kad je infimum postignut, piše se $\min S$ (minimum je infimum kad je postignut).

Primjer 2 sa slajda [str. 27]:

$$\inf \frac{1}{x} \quad \text{uz ograničenje} \quad 1 < x < 10, \quad \text{infimum nije postignut}$$

Razrada. Funkcija $1/x$ na intervalu $(1, 10)$ pada od (ne uključivo) 1 prema (ne uključivo) 0,1. Skup vrijednosti je otvoreni interval $(0,1; 1)$. Najveća donja granica je 0,1, dakle infimum je 0,1. Ali $x = 10$ nije dopušten, pa se ta vrijednost nikad ne postiže.

Napomena: zašto je to bitno

Zbog ovakvih slučajeva u optimizaciji se optimalna vrijednost formalno definira kao **infimum**, a ne minimum: $p^* = \inf\{f(x) \mid x \in \mathcal{F}\}$. Ako je dozvoljeni skup zatvoren i ograničen, a f neprekidna, infimum je uvijek postignut i tada bez straha pišemo min. Oznaku p^* za optimalnu vrijednost intenzivno koristimo u poglavlju 4.

2.8 Derivacija i Jakobijan

[str. 29--32]

Definicija 2.12: Jakobijan

Neka je $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferencijabilna funkcija u domeni svoje definicije. Tada je **Jakobijan** funkcije f u točki $x_0 \in \mathbb{R}^n$ definiran sljedećom $m \times n$ matricom:

$$Df(x_0) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(x_0) & \cdots & \frac{\partial f_1}{\partial x_n}(x_0) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(x_0) & \cdots & \frac{\partial f_m}{\partial x_n}(x_0) \end{pmatrix}$$

Objašnjenje od nule.

- **Parcijalna derivacija** $\partial f_i / \partial x_j$ znači: deriviraj f_i po x_j , a *sve ostale varijable tretiraj kao konstante*. Simbol ∂ („del”) koristi se umjesto d upravo da naglasi da ima još varijabli.
- **Struktura matrice:** i -ti redak pripada i -toj komponenti funkcije, j -ti stupac pripada j -toj varijabli. Otud dimenzija $m \times n$.

Kada funkcija ima Jakobijan [str. 29]: funkcija je **diferencijabilna** u x_0 ako parcijalne derivacije iz definicije Jakobijana postoje u x_0 . Kažemo da je funkcija diferencijabilna *u svojoj domeni*, ako je ta domena otvoreni skup i funkcija je diferencijabilna u svim točkama domene.

2.8.1 Linearizacija (aproksimacija prvog reda)

[str. 30]

Teorem 2.4: Linearizacija funkcije

Afina funkcija $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, definirana na sljedeći način

$$g(x) = f(x_0) + Df(x_0)(x - x_0)$$

je **aproksimacija prvog reda** funkcije f u točki x_0 .

Kako to čitati: „ako se malo pomaknem od x_0 , promjena funkcije je približno jednaka Jakobijanu puta pomak”. Prvi član $f(x_0)$ je vrijednost u polazištu, drugi član $Df(x_0)(x - x_0)$ je linearna korekcija. To je ista ideja kao tangenta na krivulju u 1D, samo u više dimenzija.

2.8.2 Primjer Jakobijana

[str. 31]

$f : \mathbb{R}^2 \rightarrow \mathbb{R}$ je zadana kako slijedi, uz $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$:

$$f(x) = x_2 e^{-x_1^2 - x_2^2}$$

Tada imamo $Df(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} & \frac{\partial f(x)}{\partial x_2} \end{pmatrix}$ gdje je

$$\frac{\partial f(x)}{\partial x_1} = -2x_1 x_2 e^{-x_1^2 - x_2^2}, \quad (2.10)$$

$$\frac{\partial f(x)}{\partial x_2} = e^{-x_1^2 - x_2^2} - 2x_2^2 e^{-x_1^2 - x_2^2}. \quad (2.11)$$

Raspis prve derivacije. Po x_1 je faktor x_2 konstanta, pa deriviramo samo eksponencijalu; po pravilu ulančanog deriviranja $(e^u)' = e^u \cdot u'$, uz $u = -x_1^2 - x_2^2$ i $\partial u / \partial x_1 = -2x_1$:

$$\frac{\partial f}{\partial x_1} = x_2 \cdot e^{-x_1^2 - x_2^2} \cdot (-2x_1) = -2x_1 x_2 e^{-x_1^2 - x_2^2} \quad \checkmark$$

Raspis druge derivacije. Po x_2 imamo umnožak dviju funkcija koje *obje* ovise o x_2 , pa koristimo pravilo umnoška $(uv)' = u'v + uv'$ uz $u = x_2$ i $v = e^{-x_1^2 - x_2^2}$:

$$\frac{\partial f}{\partial x_2} = 1 \cdot e^{-x_1^2 - x_2^2} + x_2 \cdot e^{-x_1^2 - x_2^2} \cdot (-2x_2) = e^{-x_1^2 - x_2^2} - 2x_2^2 e^{-x_1^2 - x_2^2} \quad \checkmark$$

Napomena: tipfeler na slajdu 31

Na slajdu su *obje* derivacije označene kao $\frac{\partial f(x)}{\partial x_1}$. Druga je zapravo $\frac{\partial f(x)}{\partial x_2}$ — vidi se iz samog izraza (nema faktora x_1 , a ima x_2^2) i iz rezultata koji slijedi.

Jakobijan u točki $x_0 = (x_1^0, x_2^0) = (1, 1)$:

$$Df(1, 1) = \begin{pmatrix} -2e^{-2} & -e^{-2} \end{pmatrix}$$

Uvrštavanje korak po korak. Za $x_1 = x_2 = 1$ je $-x_1^2 - x_2^2 = -1 - 1 = -2$, pa je $e^{-x_1^2 - x_2^2} = e^{-2}$.
Dalje:

$$\frac{\partial f}{\partial x_1}(1, 1) = -2 \cdot 1 \cdot 1 \cdot e^{-2} = -2e^{-2} \quad \checkmark \quad (2.12)$$

$$\frac{\partial f}{\partial x_2}(1, 1) = e^{-2} - 2 \cdot 1^2 \cdot e^{-2} = e^{-2} - 2e^{-2} = -e^{-2} \quad \checkmark \quad (2.13)$$

Uz to je $f(1, 1) = 1 \cdot e^{-2} = e^{-2}$.

Linearizacija funkcije f u x_0 :

$$g(x) = e^{-2} - 2e^{-2}(x_1 - x_1^0) - e^{-2}(x_2 - x_2^0)$$

Odakle: uvrstimo u $g(x) = f(x_0) + Df(x_0)(x - x_0)$:

$$g(x) = e^{-2} + \begin{pmatrix} -2e^{-2} & -e^{-2} \end{pmatrix} \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} = e^{-2} - 2e^{-2}(x_1 - 1) - e^{-2}(x_2 - 1)$$

Slika sa slajda [str. 32]. Prikazane su dvije plohe nad ravninom (x_1, x_2) :

- **plavo:** $f(x) = x_2 e^{-x_1^2 - x_2^2}$ — zakrivljena ploha s jednim „brijegom” i jednom „dolinom”;
- **crveno:** $g(x) = e^{-2} - 2e^{-2}(x_1 - 1) - e^{-2}(x_2 - 1)$ — **ravnina**.

Ravnina dodiruje plohu točno u točki $x_0 = (1, 1)$ i tamo joj je tangencijalna. Blizu te točke se dobro poklapaju, a što se dalje odmaknemo, to je odstupanje veće. To je slikoviti smisao „aproksimacije prvog reda”.

2.9 Gradijent

[str. 33--40]

Definicija 2.13: Gradijent

Neka je $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferencijabilna funkcija u domeni svoje definicije. **Gradijent** je definiran kao vektor

$$\nabla f(x) := [Df(x)]^\top := \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

Gradijent dakle preslikava točku $x \in \mathbb{R}^n$ u vektor $\nabla f(x) \in \mathbb{R}^n$.

Napomena sa slajda [str. 33]: uočite da je f ovdje **skalarna** funkcija (vrijednost $f(x)$ je skalar, tj. $f(x) \in \mathbb{R}$).

Napomena: Jakobijan vs. gradijent — ne miješati

Za skalarnu funkciju $f : \mathbb{R}^n \rightarrow \mathbb{R}$ Jakobijan $Df(x)$ je **redak** ($1 \times n$), a gradijent $\nabla f(x)$ je **stupac** ($n \times 1$). Razlikuju se samo transponiranjem, ali u formulama je bitno koji je koji — zato u izrazima poput $\nabla f(x)^\top d$ transponiranje mora biti na pravom mjestu.

Linearizacija preko gradijenta [str. 34]. Afina funkcija $g : \mathbb{R}^n \rightarrow \mathbb{R}$

$$g(x) = f(x_0) + \nabla f(x_0)^\top (x - x_0)$$

je aproksimacija prvog reda funkcije f u točki x_0 . (To je ista formula kao prije, samo zapisana gradijentom.)

2.9.1 Zašto gradijenti u optimizaciji?

[str. 37]

Neka $f(x)$ ima linearizaciju $g(x) = f(x_0) + [\nabla f(x_0)]^\top (x - x_0)$ u točki x_0 . Tada za $x = x_0 + d$, gdje je $\|d\|$ malena vrijednost, imamo

$$f(x_0 + d) \approx g(x_0 + d) = f(x_0) + [\nabla f(x_0)]^\top d$$

Međukorak: uvrstimo $x = x_0 + d$, pa je $x - x_0 = d$; drugi član postaje $[\nabla f(x_0)]^\top d$.

Zaključak sa slajda: za dovoljno malen „korak” d od x_0 , imamo

$$f(x_0 + d) < f(x_0) \quad \text{ako je} \quad [\nabla f(x_0)]^\top d < 0$$

Definicija 2.14: Smjer pada funkcije

Vektor $d \in \mathbb{R}^n$ je **smjer pada** funkcije u točki x ako vrijedi

$$[\nabla f(x)]^\top d \leq 0$$

Poruka sa slajda: ako znamo gradijent, znamo u kom smjeru ići ako tražimo minimum.

2.9.2 Važna svojstva gradijenta

[str. 38]

Teorem 2.5: Svojstva gradijenta

- Gradijent funkcije f u točki x daje nam **smjer najbržeg rasta** funkcije.
- Gradijent $\nabla f(x)$ je **ortogonalan (okomit)** na **tangentu** nivo krivulje $\mathcal{S}_c$ u bilo kojoj točki x za koju je $f(x) = c$.

Slajd 38 to ilustrira crtežom: u prostoru (x_1, x_2, x_3) nacrtan je zakrivljen „komad plohe” označen kao *nivo krivulja* $F(x) = c$, s jednom točkom na njoj, i strelica $\nabla F(x) = \text{grad } F$ koja iz te točke strši **okomito** na plohu.

2.9.3 Dokaz okomitosti

[str. 39]

Slajd dokazuje drugu tvrdnju. Prenosim izvod u cijelosti, s objašnjenjem svakog koraka.

Postavka. Neka je $g: \mathbb{R} \rightarrow \mathbb{R}^n$ funkcija koja parametrizira nivo krivulju $\mathcal{S}_c$, koja sadrži točke x za koje je $f(x) = c$.

(Sa slajda: možemo zamisliti da je t vrijeme, a $g(t)$ funkcija koja opisuje „putanju” točke u vremenu, gdje točka putuje po krivulji $\mathcal{S}$.)

Korak 1. Definirajmo $h(t) := f(g(t))$. To je vrijednost funkcije f duž putanje.

Korak 2. Budući da je $h(t) = f(g(t)) = c$ za sve t (putanja *ne napušta* nivo krivulju, pa je f na njoj stalno jednak c), funkcija h je **konstantna**, a derivacija konstante je nula:

$$\frac{dh(t)}{dt} = 0$$

Korak 3. Koristeći **pravilo ulančanog deriviranja** (deriviranje kompozicije: derivacija vanjske puta derivacija unutarnje):

$$0 = \frac{dh(t)}{dt} = Df(g(t)) Dg(t) = Df(x) d = \nabla f(x)^\top d$$

gdje je $d = Dg(t)$ **tangentni vektor** na krivulju $x = g(t)$ (ako je $g(t)$ putanja, onda je d vektor brzine).

Korak 4 — zaključak. Dobili smo $\nabla f(x)^\top d = 0$, dakle $\nabla f(x)$ i d su **međusobno okomiti vektori** (po teoremu o okomitosti iz odjeljka 2.4). Budući da je d tangenta na nivo krivulju, gradijent je okomit na nivo krivulju. ■

Napomena: povratak na Zadatak 2

U Zadatku 2.3 smo za $f(x) = a^\top x$ izračunom pokazali da je a okomit na nivo krivulje. Sada vidimo i *zašto*: gradijent linearne funkcije je $\nabla f(x) = a$ (jer je $\partial(a^\top x)/\partial x_i = a_i$), a gradijent je uvijek okomit na nivo krivulju.

2.9.4 Što nam gradijent govori — formalno

[str. 40]

Teorem 2.6: Smjerovi rasta i pada

Neka je funkcija cilja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ kontinuirana funkcija i neka su x i d vektori u $\mathbb{R}^n$. Tada vrijedi:

- ako je $d^\top \nabla f(x) \geq 0$, tada je $f(x + \alpha d) \geq f(x)$ za dovoljno malen $\alpha > 0$;
- ako je $d^\top \nabla f(x) \leq 0$, tada je $f(x + \alpha d) \leq f(x)$ za dovoljno malen $\alpha > 0$.

Zaključci sa slajda:

- Gradijenti nam govore u kojem smjeru funkcija f u točki x opada odnosno raste.
- **Smjerovi smanjenja** funkcije su svi oni vektori d za koje vrijedi $d^\top \nabla f(x) \leq 0$ — **ovo je „poluprostor“** (engl. *half-space*).

To je izravna primjena predznaka skalarnog produkta iz odjeljka 2.4: skup svih d koji zatvaraju tup kut s gradijentom je poluprostor. Formalnu definiciju poluprostora dajemo u odjeljku 2.14.

2.10 Hessian i Taylorov teorem

[str. 41--42]

Definicija 2.15: Hessian

Neka je $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dvostruko diferencijabilna funkcija. **Hessian** u točki $x_0 = (x_1^0, \dots, x_n^0)$ je definiran kao $n \times n$ matrica:

$$D^2 f(x_0) = \nabla^2 f(x_0) := \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(x_0) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(x_0) & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(x_0) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(x_0) & \frac{\partial^2 f}{\partial x_n \partial x_2}(x_0) & \dots & \frac{\partial^2 f}{\partial x_n \partial x_n}(x_0) \end{pmatrix}$$

Tvrdnja sa slajda: Hessian funkcije f u nekoj točki je **kvadratna i simetrična** matrica dimenzija $n \times n$.

Objašnjenje.

- Hessian je „derivacija gradijenta“ — druga derivacija skalarne funkcije više varijabli.
- $\partial^2 f / (\partial x_i \partial x_j)$ znači: deriviraj prvo po x_j , pa rezultat po x_i .
- **Simetričnost** znači $\partial^2 f / (\partial x_i \partial x_j) = \partial^2 f / (\partial x_j \partial x_i)$: redoslijed deriviranja nije važan (za dovoljno glatke funkcije). Zbog te simetrije Hessian ima samo realne svojstvene vrijednosti

— što je ključno za odjeljak 2.12.

Teorem 2.7: Taylorov teorem 1 [str. 42]

Neka funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ima kontinuiranu prvu derivaciju i neka je $d \in \mathbb{R}^n$. Tada vrijedi

$$f(x_0 + d) \approx f(x_0) + Df(x_0)d$$

kad je $\|d\|$ malena vrijednost, i

$$f(x_0 + d) = f(x_0) + Df(x_0 + td)d \quad \text{za neki } t \in (0, 1)$$

Teorem 2.8: Taylorov teorem 2 [str. 42]

Neka funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ima kontinuiranu drugu derivaciju i neka je $d \in \mathbb{R}^n$. Tada vrijedi

$$f(x_0 + d) \approx f(x_0) + Df(x_0)d + \frac{1}{2}d^\top D^2 f(x_0)d$$

kad je $\|d\|$ malena vrijednost, i

$$f(x_0 + d) = f(x_0) + Df(x_0 + td)d + \frac{1}{2}d^\top D^2 f(x_0 + td)d \quad \text{za neki } t \in (0, 1)$$

Kako to koristiti. Prva formula u svakom teoremu je *aproksimacija* (znak $\approx$) i vrijedi samo za male korake. Druga je *točna jednakost* (znak $=$), ali po cijenu da se derivacija računa u nekoj nepoznatoj međutočki $x_0 + td$, $0 < t < 1$.

Zašto nam treba drugi red. Aproksimacija prvog reda ne razlikuje minimum od maksimuma — u obje je gradijent nula, pa linearni član nestaje. Tek član $\frac{1}{2}d^\top D^2 f(x_0)d$ kaže zakrivljuje li se funkcija prema gore (minimum) ili prema dolje (maksimum). To je izravno motivacija za odjeljak 2.11.

2.11 Optimiranje bez ograničenja: uvjeti optimalnosti

[str. 43--45]

Pitanje na sva tri slajda glasi: **kako znati je li točka x^* lokalni minimum?**

Teorem 2.9: Nužni uvjeti prvog reda [str. 43]

Ako je x^* lokalni minimum i ako je f kontinuirano diferencijabilna funkcija (ima prvu derivaciju koja je kontinuirana) u nekoj otvorenoj okolini točke x^* , tada **nužno** vrijedi

$$\nabla f(x^*) = 0$$

Napomena: upozorenje sa slajda 43

I u lokalnom maksimumu vrijedi $\nabla f(x^*) = 0$! Uvjet $\nabla f = 0$ je samo *nužan*, a ne dovoljan: zadovoljavaju ga minimumi, maksimumi i sedlaste točke. Točke u kojima je $\nabla f = 0$ zovu se **stacionarne točke**.

Teorem 2.10: Nužni uvjeti drugog reda [str. 44]

Ako je x^* lokalni minimum od f i ako je $\nabla^2 f$ kontinuirana u nekoj otvorenoj okolini točke x^* , tada **nužno** vrijedi

$$\nabla f(x^*) = 0 \quad \text{i} \quad \nabla^2 f(x^*) \succeq 0$$

Ovdje $\nabla^2 f(x^*) \succeq 0$ znači da je Hessian matrica **pozitivno semidefinitna**.

Teorem 2.11: Dovoljni uvjeti drugog reda [str. 45]

Ako je $\nabla^2 f$ kontinuirana u nekoj otvorenoj okolini točke x^* i ako vrijedi

$$\nabla f(x^*) = 0 \quad \text{i} \quad \nabla^2 f(x^*) \succ 0,$$

tada je x^* **striktni lokalni minimizator** funkcije f .

Razlika između zadnja dva teorema u jednoj rečenici: nužni uvjet ima $\succeq$ (dopušta i nulu) i ide „od minimuma prema uvjetu”; dovoljni ima $\succ$ (strogo) i ide „od uvjeta prema minimumu”. Simboli $\succeq$ i $\succ$ objašnjeni su odmah u sljedećem odjeljku.

Veza s 1D slučajem. U jednoj dimenziji $\nabla f = f'$ i $\nabla^2 f = f''$, pa se teoremi svode na poznati recept iz srednje škole: $f' = 0$ i $f'' > 0 \Rightarrow$ minimum. Ovo je njegovo poopćenje na n dimenzija, gdje ulogu predznaka drugog derivata preuzima **definitnost matrice**.

2.12 Pozitivno i negativno definitne matrice

[str. 46--50]

Podsjetnik sa slajda 46: realna matrica (matrica čiji su elementi realni brojevi) H dimenzija $n \times n$ je **simetrična** ako vrijedi $H^\top = H$.

Definicija 2.16: Definitnost

- H je **pozitivno semidefinitna** matrica, i pišemo $H \succeq 0$, ako je H simetrična matrica i ako vrijedi

$$x^\top H x \geq 0 \quad \text{za sve vektore } x \in \mathbb{R}^n;$$

- H je **pozitivno definitna** matrica ($H \succ 0$) ako $x^\top H x > 0$ za sve $x \in \mathbb{R}^n$, $x \neq 0$;
- H je **negativno semidefinitna** matrica ($H \preceq 0$) ako $x^\top H x \leq 0$ za sve $x \in \mathbb{R}^n$;
- H je **negativno definitna** matrica ($H \prec 0$) ako $x^\top H x < 0$ za sve $x \in \mathbb{R}^n$, $x \neq 0$.

Kažemo da je matrica **indefinitna** ako nije ništa od gore navedenog.

Kako to zamisliti. Izraz $x^\top H x$ je broj (**kvadratna forma**) i poopćenje je izraza ax^2 iz jedne dimenzije. „Pozitivno definitna” znači „ponaša se kao ax^2 s $a > 0$ ” — ploha se svugdje zakrivljuje prema gore, pa je ishodište minimum. Zato je u teoremu o dovoljnim uvjetima traženo $\nabla^2 f \succ 0$.

Važna tvrdnja sa slajda 46: simetrične matrice nužno imaju **samo realne svojstvene vrijednosti** (dakle, nema kompleksnih brojeva kao svojstvenih vrijednosti). To omogućuje sljedeću karakterizaciju.

Teorem 2.12: Karakterizacija preko svojstvenih vrijednosti [str. 47]

- $H \succeq 0$ ako i samo ako su sve svojstvene vrijednosti od H **ne-negativne** (nula ili pozitivne);
- $H \succ 0$ ako i samo ako su sve svojstvene vrijednosti od H **pozitivne**;
- $H \preceq 0$ ako i samo ako su sve svojstvene vrijednosti od H **ne-pozitivne** (nula ili negativne);
- $H \prec 0$ ako i samo ako su sve svojstvene vrijednosti od H **negativne**.

Napomena: dvije zamke sa slajda 47

- Ako matrica **nije** pozitivno semidefinitna, **to ne znači da je negativno definitna!** Može biti indefinitna (dio svojstvenih vrijednosti pozitivan, dio negativan).
- **Pozitivno definitne matrice mogu imati negativne elemente!** Definitnost se *ne* očitava iz predznaka pojedinih elemenata — primjer koji slijedi to izravno pokazuje.

2.12.1 Primjer: određivanje definitnosti

[str. 48]

Zadatak. Odredite definitnost matrice A , gdje je

$$A = \begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix}$$

Rješenje. Svojstvene vrijednosti matrice A su one λ za koje je $\det(A - \lambda I) = 0$, gdje je I identična matrica (jedinice na dijagonali, nule drugdje).

$$\begin{vmatrix} 1 - \lambda & -1 \\ -1 & 3 - \lambda \end{vmatrix} = 0 \implies \lambda^2 - 4\lambda + 2 = 0$$

Raspis determinante (na slajdu nije prikazan). Determinanta matrice 2×2 je umnožak glavne dijagonale minus umnožak sporedne:

$$(1 - \lambda)(3 - \lambda) - (-1)(-1) = 3 - \lambda - 3\lambda + \lambda^2 - 1 \quad (2.14)$$

$$= \lambda^2 - 4\lambda + 2 \quad (2.15)$$

Svojstvene vrijednosti: $\lambda_1 = 2 + \sqrt{2}$, $\lambda_2 = 2 - \sqrt{2}$.*Raspis rješavanja kvadratne jednadžbe:*

$$\lambda_{1,2} = \frac{4 \pm \sqrt{16 - 4 \cdot 1 \cdot 2}}{2} = \frac{4 \pm \sqrt{8}}{2} = \frac{4 \pm 2\sqrt{2}}{2} = 2 \pm \sqrt{2}$$

Brojčano: $\sqrt{2} \approx 1,414$, pa je $\lambda_1 \approx 3,414 > 0$ i $\lambda_2 \approx 0,586 > 0$.**Zaključak: matrica je pozitivno definitna.** (Obje svojstvene vrijednosti su strogo pozitivne.) Uočite da matrica *ima* negativne elemente (-1) — upravo primjer iz napomene gore.**Računanje svojstvenih vrijednosti sa slajda:** u MATLAB-u `eig(A)`, u Mathematici `Eigenvalues[A]`.

2.12.2 Primjer: definitnost i minimum

[str. 49]

Matrica A iz prethodnog primjera jednaka je Hessianu sljedeće funkcije:

$$f(x_1, x_2) = \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 1 & -1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \text{tj.} \quad f(x_1, x_2) = 0,5(x_1^2 - 2x_1x_2 + 3x_2^2)$$

Slajd traži: *provjerite ovu tvrdnju!* Evo provjere.

Provjera 1 — raspis kvadratne forme. Prvo pomnožimo matricu s desnim vektorom:

$$\begin{bmatrix} 1 & -1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 - x_2 \\ -x_1 + 3x_2 \end{bmatrix}$$

pa pomnožimo lijevim (retčanim) vektorom:

$$\begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} x_1 - x_2 \\ -x_1 + 3x_2 \end{bmatrix} = x_1(x_1 - x_2) + x_2(-x_1 + 3x_2) \quad (2.16)$$

$$= x_1^2 - x_1x_2 - x_1x_2 + 3x_2^2 \quad (2.17)$$

$$= x_1^2 - 2x_1x_2 + 3x_2^2 \quad (2.18)$$

Uz faktor $\frac{1}{2}$ dobivamo točno $f(x_1, x_2) = 0,5(x_1^2 - 2x_1x_2 + 3x_2^2)$. ✓

Provjera 2 — Hessian je doista A . Iz $f = 0,5x_1^2 - x_1x_2 + 1,5x_2^2$:

$$\frac{\partial f}{\partial x_1} = x_1 - x_2, \quad \frac{\partial f}{\partial x_2} = -x_1 + 3x_2 \quad (2.19)$$

$$\frac{\partial^2 f}{\partial x_1^2} = 1, \quad \frac{\partial^2 f}{\partial x_1 \partial x_2} = -1 \quad (2.20)$$

$$\frac{\partial^2 f}{\partial x_2 \partial x_1} = -1, \quad \frac{\partial^2 f}{\partial x_2^2} = 3 \quad (2.21)$$

dakle $\nabla^2 f = \begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix} = A$ ✓, i to u *svakoj* točki (jer je f kvadratna, druge derivacije su konstante).

Provjera 3 — gradijent u ishodištu (slajd traži i to):

$$\nabla f(0, 0) = \begin{pmatrix} x_1 - x_2 \\ -x_1 + 3x_2 \end{pmatrix} \Big|_{(0,0)} = \begin{pmatrix} 0 - 0 \\ -0 + 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \checkmark$$

Zaključak sa slajda. Budući da je ∇f u točki $(0, 0)$ jednak nul-vektoru, te budući da je Hessian funkcije f svugdje pozitivno definitan (pa stoga i u točki $(0, 0)$), možemo zaključiti da funkcija f ima **striktni lokalni minimum** u $(0, 0)$.

To je izravna primjena teorema o dovoljnim uvjetima drugog reda [str. 45]. Slajd uz to prikazuje 3D graf te funkcije — glatku „zdjelu” s najnižom točkom u ishodištu.

2.12.3 Kriterij determinanti (Sylvesterov kriterij)

[str. 50]

Teorem 2.13: Kriterij vodećih glavnih minora

Matrica

$$M = \begin{pmatrix} m_{11} & m_{12} & \dots & m_{1n} \\ m_{21} & m_{22} & \dots & m_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & \dots & m_{nn} \end{pmatrix}$$

je **pozitivno definitna** ako i samo ako su sve determinante u sljedećem nizu **pozitivne**:

$$D_1 = m_{11}, \quad D_2 = \begin{vmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{vmatrix}, \quad D_3 = \begin{vmatrix} m_{11} & m_{12} & m_{13} \\ m_{21} & m_{22} & m_{23} \\ m_{31} & m_{32} & m_{33} \end{vmatrix}, \quad \dots \quad D_n = \det(M)$$

M je **negativno definitna** ako i samo ako $D_1 < 0$, $D_2 > 0$, $D_3 < 0$, $D_4 > 0$, ... (predznaci se izmjenjuju, počevši od minusa).

Što su D_k . To su determinante **gornjih lijevih** podmatrica dimenzija 1×1 , 2×2 , ..., $n \times n$. Zovu se *vodeći glavni minori*.

Provjera na primjeru sa str. 48. Za $A = \begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix}$:

$$D_1 = 1 > 0, \quad D_2 = 1 \cdot 3 - (-1)(-1) = 3 - 1 = 2 > 0$$

Obje su pozitivne $\Rightarrow A \succ 0$ — isti zaključak kao preko svojstvenih vrijednosti, ali bez rješavanja kvadratne jednadžbe. ✓

Napomena: koji kriterij koristiti

Za male matrice (2×2 , 3×3) kriterij determinanti je brži jer ne traži rješavanje karakteristične jednadžbe. Za veće matrice ili kad treba i *semidefinitnost*, koriste se svojstvene vrijednosti (**eig** u MATLAB-u). Pažnja: kriterij vodećih minora vrijedi za *definitnost*; za semidefinitnost bi trebalo provjeriti *sve* glavne minore, ne samo vodeće.

2.13 Konveksno optimiranje: skupovi

[str. 51--60]

2.13.1 Afin skup

[str. 54--55]

Definicija 2.17: Afin skup

Afin skup S definiran je sljedećim svojstvom: **pravac** koji prolazi kroz bilo koje dvije različite točke iz S se i sam u potpunosti nalazi u S .

Pravac koji prolazi kroz dvije točke $x_1, x_2 \in \mathbb{R}^n$, $x_1 \neq x_2$, je skup P , gdje je

$$P := \{ x \mid x = \theta x_1 + (1 - \theta)x_2 \}$$

i gdje je $\theta \in \mathbb{R}$.

Kako čitati parametrizaciju pravca. Izraz $\theta x_1 + (1 - \theta)x_2$ za razne θ „šeta” po pravcu kroz x_1 i x_2 :

- $\theta = 1$ daje x_1 ;
- $\theta = 0$ daje x_2 ;
- $\theta = 0,5$ daje polovište;
- $\theta > 1$ ili $\theta < 0$ daju točke *izvan* dužine, na produžecima — i baš to je ono što razlikuje pravac od dužine.

Uočite da koeficijenti θ i $1 - \theta$ uvijek daju zbroj 1.

Primjer sa slajda 54: 2D ravnina u 3D prostoru je afin skup. Ako uzmemo bilo koje dvije točke iz ravnine i povučemo pravac kroz njih, taj pravac se nužno nalazi u toj istoj ravnini.

Primjer sa slajda 55: sva rješenja sustava linearnih jednadžbi $\{x \mid Ax = b\}$ čine afin skup.

Dokaz (sa slajda, s međukoracima). Neka su x_1 i x_2 rješenja sustava $Ax = b$, tj. $Ax_1 = b$, $Ax_2 = b$. Tada za bilo koji $\theta \in \mathbb{R}$ imamo:

$$A(\theta x_1 + (1 - \theta)x_2) \stackrel{(1)}{=} \theta Ax_1 + (1 - \theta)Ax_2 \stackrel{(2)}{=} \theta b + (1 - \theta)b \stackrel{(3)}{=} b$$

gdje je: (1) linearnost množenja matricom; (2) uvrštavanje $Ax_1 = Ax_2 = b$; (3) $\theta b + b - \theta b = b$. Dakle i točka $\theta x_1 + (1 - \theta)x_2$ rješava sustav, pa cijeli pravac leži u skupu. ■

Obrat i posljedica (sa slajda 55). Vrijedi i obrnuto: *svaki afin skup može se prikazati kao skup rješenja nekog sustava linearnih jednadžbi.*

Dakle, ako u optimizacijskom problemu imamo **linearna ograničenja jednakosti**, dozvoljeni skup $\mathcal{F}$ je afin skup. Linearna ograničenja jednakosti i pripadajući afini skupovi igraju važnu ulogu u optimiranju: **kod konveksnih optimizacijskih problema, jedina ograničenja jednakosti su linearna ograničenja jednakosti.**

2.13.2 Konveksan skup

[str. 56--59]

Definicija 2.18: Konveksan skup

Konveksan skup S definiran je sljedećim svojstvom: **dužina** između bilo koje dvije različite točke iz S se i sama u potpunosti nalazi u S .

Dužina između dvije točke $x_1, x_2 \in \mathbb{R}^n$, $x_1 \neq x_2$, je skup D , gdje je

$$D := \{x \mid x = \theta x_1 + (1 - \theta)x_2\}$$

i gdje je $0 \leq \theta \leq 1$.

Formalno: skup S je konveksan skup ako

$$x_1, x_2 \in S \implies \theta x_1 + (1 - \theta)x_2 \in S \quad \text{za sve } \theta \in [0, 1]$$

Napomena: razlika afnog i konveksnog — samo jedan uvjet

Formula je *identična*; razlikuje se samo raspon parametra:

	raspon θ	geometrijski objekt
afin skup	$\theta \in \mathbb{R}$	cijeli pravac kroz dvije točke
konveksan skup	$\theta \in [0, 1]$	samo dužina između njih

Zato je **svaki afn skup ujedno konveksan**, ali ne obratno (npr. krug je konveksan, ali nije afn).

Primjeri sa slajda [str. 57]. Slajd prikazuje pet oblika:

Oblik na slajdu	Zaključak
dužina prekinuta u sredini (plave linije)	nije konveksan
neprekinuta dužina	konveksan
sedmerokut (ispunjen)	konveksan
„bubrežasti” oblik s udubljenjem	nije konveksan
kvadrat kojemu nedostaju uglovi	nije konveksan

Kod „bubrega” je na slici nacrtana spojnica dviju točaka koja *izlazi* iz skupa preko udubljenja — to je izravna povreda definicije. Kod kvadrata bez uglova problem su rubne točke koje ne pripadaju skupu.

Primjeri u 3D sa slajda [str. 58]: puna **kugla** je konveksna; **čvor** od isprepletenih torusa nije.

Teorem 2.14: Presjek konveksnih skupova [str. 59]

Presjek konveksnih skupova je konveksan skup.

Posljedica za optimizaciju (sa slajda). Gornje svojstvo je, uz ostalo, važno i zbog sljedeće posljedice za karakterizaciju dozvoljenog prostora $\mathcal{F}$: ako je $\mathcal{F}_i = \{x \mid g_i(x) \leq 0\}$ ili $\mathcal{F}_i = \{x \mid h_i(x) = 0\}$, i ako su svi $\mathcal{F}_i$, $i = 1, \dots, m$ konveksni, tada će i dozvoljeni skup

$$\mathcal{F} = \mathcal{F}_1 \cap \mathcal{F}_2 \cap \dots \cap \mathcal{F}_m$$

biti konveksan.

Zašto je to praktično najvažnija tvrdnja odjeljka. Konveksnost dozvoljenog skupa ne moramo provjeravati „na cijelom skupu” — dovoljno je provjeriti **svako ograničenje zasebno**. Ako je svako pojedino u redu, cjelina je automatski u redu.

2.13.3 Konveksna kombinacija i konveksna ljuska

[str. 60]

Definicija 2.19: Konveksna kombinacija

Konveksna kombinacija točaka (vektora) $x_1, x_2, \dots, x_n$ je točka (vektor) x u formi

$$x = \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

gdje je

$$\theta_1 + \theta_2 + \dots + \theta_n = 1 \quad \text{i} \quad \theta_i \geq 0, \quad i = 1, \dots, n$$

To je poopćenje dužine na više od dvije točke: težine su nenegativne i zbrajaju se u jedan (kao postoji). Za $n = 2$ dobivamo točno $\theta x_1 + (1 - \theta)x_2$ s $\theta \in [0, 1]$.

Definicija 2.20: Konveksna ljuska

Konveksna ljuska skupa S je skup svih konveksnih kombinacija točaka iz S .

Tvrdnje sa slajda:

- Konveksna ljuska skupa S je **najmanji konveksni skup koji sadrži S** .
- Skup je konveksan **ako i samo ako** je jednak svojoj konveksnoj ljusci.

Slikovito: zamislite da su točke skupa čavlići zabodeni u dasku. Ako oko svih njih napnete gumicu, oblik koji gumica opiše je konveksna ljuska.

2.14 Hiperravnine i poluprostori

[str. 65--66 i V1:26, V1:28]

Definicija 2.21: Hiperravnina

Hiperravnina je skup

$$H := \{x \in \mathbb{R}^n \mid a^\top x = b\}$$

za zadani $a \in \mathbb{R}^n$, $a \neq 0$ i $b \in \mathbb{R}$.

Što je to konkretno. U $\mathbb{R}^2$ je hiperravnina **pravac**; u $\mathbb{R}^3$ je **ravnina**; u $\mathbb{R}^n$ je „ravna ploha” dimenzije $n - 1$. Uvjet $a \neq 0$ je nužan — inače bi jednačnja bila $0 = b$, što je ili cijeli prostor ili prazan skup.

Slika sa slajda [str. 65]: **geometrijsko značenje**. Slajd prikazuje dva crteža.

Lijevi crtež. Nacrtan je kosi pravac (hiperravnina), vektor a iz ishodišta okomit na njega, i vektor x_0 do jedne točke na pravcu. Iz ishodišta je nacrtan i cijeli snop vektora x koji završavaju na tom pravcu. Ispod piše:

$$a^\top x = a^\top x_0 = b$$

Poruka: *svi* vektori koji završavaju na hiperravnini imaju **isti** skalarni produkt s a . Taj zajednički broj je b .

Desni crtež. Isti pravac, ali su označeni x_0 , proizvoljna točka x na pravcu, i njihova razlika $(x - x_0)$ koja *leži* u pravcu. Ispod piše:

$$a^\top (x - x_0) = 0$$

Poruka: a je okomit na svaki vektor koji leži unutar hiperravnine. Zato se a zove **vektor normale**.

Veza između dva zapisa: $a^\top (x - x_0) = a^\top x - a^\top x_0 = a^\top x - b$, pa je $a^\top (x - x_0) = 0$ isto što i $a^\top x = b$. ✓

Definicija 2.22: Poluprostor

Poluprostor je skup oblika

$$H := \{x \in \mathbb{R}^n \mid a^\top x \leq b\}$$

za zadani $a \in \mathbb{R}^n$, $a \neq 0$ i $b \in \mathbb{R}$.

Slika sa slajda [str. 66]. Nacrtna je kosi pravac, na njemu točka x_0 i iz nje strelica a okomito na pravac. Strana u koju pokazuje a označena je s $a^\top x \geq b$, a suprotna strana je osjenčana i označena s $a^\top x \leq b$.

Pravilo koje iz toga slijedi (i koje ćemo stalno koristiti pri crtanju dozvoljenih skupova):

Teorem 2.15: Koju stranu sjenčati

Hiperravnina $a^\top x = b$ dijeli prostor na dva dijela. Vektor a pokazuje u polovicu gdje je $a^\top x \geq b$. Za ograničenje oblika $a^\top x \leq b$ sjenča se strana **suprotna** od smjera vektora a .

Praktična provjera testnom točkom. Umjesto pamćenja pravila, uzmite bilo koju točku koja nije na granici (najlakše ishodište, ako smije) i uvrstite je u nejednadžbu. Ako je zadovoljena, ta točka je u dozvoljenoj polovici; ako nije, dozvoljena je druga polovica. Ovu tehniku smo već koristili u odjeljku 1.3.

Zadatak 2.3 — Vježbe 1, Zadatak 3: poluprstor

[str. V1:29]

Postavka (doslovno sa slajda). „Pronađite vektor a i skalar b takve da ograničenje $a^\top x \leq b$ definira sivo osjenčan poluprstor sa slike.”

Napomena: stanje izvornika

Slajd V1:29 sadrži **samo** tekst zadatka i riječi „na ploči” — nema ni slike na koju se poziva ni rješenja. Zato je niže uzet **konkretni primjer istog tipa**, riješen postupkom koji slijedi izravno iz definicije poluprostora [str. V1:28] i slike sa str. 66. Postupak je ono što treba naučiti; brojevi ovise o slici koju dobijete.

Primjer. Osjenčan je poluprstor čija granica prolazi točkama $(3, 0)$ i $(0, 2)$, a osjenčana je strana **prema ishodištu**.

Korak 1 — jednadžba granice. Granica je pravac kroz dvije zadane točke. Iz segmentnog oblika jednadžbe pravca $\frac{x_1}{p} + \frac{x_2}{q} = 1$ (gdje su p, q sjecišta s osima):

$$\frac{x_1}{3} + \frac{x_2}{2} = 1$$

Pomnožimo cijelu jednadžbu s 6 (najmanji zajednički višekratnik od 3 i 2) da uklonimo razlomke:

$$\frac{6x_1}{3} + \frac{6x_2}{2} = 6 \implies 2x_1 + 3x_2 = 6$$

Provjera na obje zadane točke:

- $(3, 0)$: $2 \cdot 3 + 3 \cdot 0 = 6 \checkmark$
- $(0, 2)$: $2 \cdot 0 + 3 \cdot 2 = 6 \checkmark$

Korak 2 — očitavanje a i b . Usporedimo s oblikom $a^\top x = b$:

$$\begin{pmatrix} 2 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 6 \implies a = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \quad b = 6$$

Korak 3 — provjera smjera nejednakosti. Trebamo provjeriti daje li $a^\top x \leq b$ osjenčanu stranu. Uvrstimo ishodište (ono je u osjenčanom dijelu):

$$a^\top \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 2 \cdot 0 + 3 \cdot 0 = 0 \leq 6 \quad \checkmark$$

Nejednakost je zadovoljena, dakle traženo ograničenje je

$$2x_1 + 3x_2 \leq 6, \quad a = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \quad b = 6$$

Korak 4 — što ako je osjenčana druga strana? Tada bi trebalo pomnožiti sve s -1 (što okreće smjer nejednakosti):

$$-2x_1 - 3x_2 \leq -6, \quad a = \begin{pmatrix} -2 \\ -3 \end{pmatrix}, \quad b = -6$$

Isti pravac, suprotna normala, suprotna polovica.

Napomena: rješenje nije jedinstveno

Par (a, b) nije jedinstven: množenje *bilo kojim* pozitivnim brojem daje isti poluprstor. Npr. $4x_1 + 6x_2 \leq 12$ i $x_1 + 1,5x_2 \leq 3$ opisuju potpuno isti skup. Pozitivan faktor smjer nejednakosti ne mijenja — samo negativan.

Kako to nacrtati rukom: poluprstor

Korak 1. Nacrtajte osi x_1 i x_2 , obje otprilike od -2 do 5 .


Korak 2. Ucrtaite dvije točke granice: $(3, 0)$ na osi x_1 i $(0, 2)$ na osi x_2 . Povucite pravac kroz njih — to je hiperravnina $a^\top x = b$.

Korak 3. Odaberite jednu točku na pravcu, npr. $x_0 = (1, 5; 1)$ (provjera: $2 \cdot 1,5 + 3 \cdot 1 = 3 + 3 = 6$ ✓). Iz nje nacrtajte strelicu $a = (2, 3)$: dvije jedinice desno, tri gore. Provjerite okom da je okomita na pravac.

Korak 4 — sjenčanje. Nejednakost je $a^\top x \leq b$, dakle sjenča se strana **suprotna** od smjera strelice a , tj. donja lijeva polovica — ona koja sadrži ishodište. Osjenčajte je.

Korak 5. Označite obje polovice: osjenčanu s $a^\top x \leq b$, drugu s $a^\top x \geq b$.

Što graf znači. Svako pojedinačno linearno ograničenje nejednakosti u optimizacijskom problemu „odreže” točno jedan ovakav poluprstor. Dozvoljeni skup je presjek svih tih poluprostora — što je tema sljedećeg zadatka.



Slika 2.2: Poluprostor $\{x \mid a^T x \leq b\}$ za $a = (2, 3)^T$, $b = 6$. Vektor normale a pokazuje u nedozvoljenu polovicu.

2.15 Poliedar i politop

[str. V1:30]

Definicija 2.23: Poliedarski skup

Presjek konačnog broja hiperravnina $\{x \mid A_J x = b_J\}$ i poluprostora $\{x \mid A_N x \leq b_N\}$ definira **poliedar** (engl. *polyhedron*).

Poliedar $P = \{x \mid A_N x \leq b_N, A_J x = b_J\}$ je **konveksan** skup.

Kompaktan (= zatvoren i ograničen) poliedar je **politop** (engl. *polytope*).

Objašnjenje pojmova:

- Indeks J označava *jednakosti*, indeks N *nejednakosti*. Svaki redak matrice A_N s pripadnim elementom vektora b_N daje jedan poluprostor.
- **Zatvoren** znači da skup sadrži svoj rub (nejednakosti su $\leq$, ne $<$).
- **Ograničen** znači da stane u neku dovoljno veliku kuglu — ne bježi u beskonačnost.
- Zašto je poliedar konveksan: svaki poluprostor je konveksan, svaka hiperravnina je konveksna (čak i afina), a *presjek konveksnih skupova je konveksan* [str. 59].

Primjeri. Trokut, kvadrat i pravilni šesterokut u ravnini su politopi. Kocka i tetraedar u prostoru su politopi. Poluprostor je poliedar, ali *nije* politop (nije ograničen). Traka između dva paralelna pravca je poliedar, ali nije politop.

Zadatak 2.4 — Vježbe 1, Zadatak 4: politop

[str. V1:31]

Postavka (doslovno sa slajda). „Pronađite matricu A i vektor b takve da ograničenje $Ax \leq b$ definira sivo osjenčan politop sa slike.”

Napomena: stanje izvornika

Kao i kod Zadatka 3, slajd V1:31 sadrži samo tekst i riječ „na ploči” — bez slike i bez rješenja. Niže je konkretan primjer istog tipa, riješen postupkom koji slijedi iz definicije poliedra [str. V1:30] i iz Zadatka 3.

Primjer. Osjenčan je četverokut s vrhovima $(0, 0)$, $(3, 0)$, $(3, 1)$, $(0, 4)$.

Postupak (opći recept). Politop je presjek poluprostora, pa se traži **jedno ograničenje po svakoj stranici**:

1. odredi pravac na kojem leži stranica;
2. zapiši ga u obliku $a_i^\top x = b_i$;
3. testnom točkom *iz unutrašnjosti* politopa provjeri smjer; ako nejednakost nije zadovoljena, pomnoži redak s -1 ;
4. složi sve $a_i^\top$ kao *retke* matrice A , a b_i u vektor b .

Kao testnu točku unutrašnjosti uzmimo $x_{\text{test}} = (1; 0,5)$.

Stranica 1 — od $(0, 0)$ do $(3, 0)$. Obje točke imaju $x_2 = 0$, pa je pravac $x_2 = 0$. Test: $x_{\text{test},2} = 0,5$, a treba biti ≤ 0 ? Ne. Dakle množimo s -1 :

$$-x_2 \leq 0 \quad (\text{test: } -0,5 \leq 0 \checkmark)$$

Stranica 2 — od $(0, 0)$ do $(0, 4)$. Obje točke imaju $x_1 = 0$, pa je pravac $x_1 = 0$. Isti zaključak:

$$-x_1 \leq 0 \quad (\text{test: } -1 \leq 0 \checkmark)$$

Stranica 3 — od $(0, 4)$ do $(3, 1)$. Nađimo pravac kroz te dvije točke. Nagib:

$$k = \frac{1 - 4}{3 - 0} = \frac{-3}{3} = -1$$

Odsječak na osi x_2 je 4 (jer pravac prolazi točkom $(0, 4)$), dakle $x_2 = -x_1 + 4$, odnosno

$$x_1 + x_2 = 4$$

Provjera na drugoj točki: $3 + 1 = 4 \checkmark$. Test unutrašnjosti: $1 + 0,5 = 1,5 \leq 4 \checkmark$, dakle predznak je već dobar:

$$x_1 + x_2 \leq 4$$

Stranica 4 — od $(3, 0)$ do $(3, 1)$. Obje točke imaju $x_1 = 3$, pa je pravac $x_1 = 3$. Test: $1 \leq 3 \checkmark$:

$$x_1 \leq 3$$

Slaganje u matrični oblik. Četiri ograničenja

$$-x_1 \leq 0, \quad -x_2 \leq 0, \quad x_1 + x_2 \leq 4, \quad x_1 \leq 3$$

zapisujemo tako da koeficijente svakog stavimo kao *redak*:

$$A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}, \quad b = \begin{pmatrix} 0 \\ 0 \\ 4 \\ 3 \end{pmatrix}$$

Kontrola — provjera svih vrhova. Svaki vrh mora zadovoljavati svih 4 nejednakosti:

vrh	$-x_1 \leq 0$	$-x_2 \leq 0$	$x_1 + x_2 \leq 4$	$x_1 \leq 3$
(0, 0)	$0 \leq 0 \checkmark$	$0 \leq 0 \checkmark$	$0 \leq 4 \checkmark$	$0 \leq 3 \checkmark$
(3, 0)	$-3 \leq 0 \checkmark$	$0 \leq 0 \checkmark$	$3 \leq 4 \checkmark$	$3 \leq 3 \checkmark$
(3, 1)	$-3 \leq 0 \checkmark$	$-1 \leq 0 \checkmark$	$4 \leq 4 \checkmark$	$3 \leq 3 \checkmark$
(0, 4)	$0 \leq 0 \checkmark$	$-4 \leq 0 \checkmark$	$4 \leq 4 \checkmark$	$0 \leq 3 \checkmark$

Uočite da je u svakom vrhu *barem dvoje* ograničenja zadovoljeno s jednakosti — upravo to i čini točku vrhom: sjecište dviju granica. Taj će pojam biti ključan u poglavlju 5.

Kako to nacrtati rukom: politop

Korak 1. Nacrtajte osi x_1 i x_2 , obje od -1 do 5 , jednako mjerilo.

Korak 2 — prvo ograničenje $-x_2 \leq 0$, tj. $x_2 \geq 0$. Granica je vodoravna os. Dopusšteno je **iznad** nje (jer x_2 mora biti nenegativan).


Korak 3 — drugo ograničenje $-x_1 \leq 0$, tj. $x_1 \geq 0$. Granica je okomita os. Dopusšteno je **desno** od nje. Presjek s korakom 2 je prvi kvadrant — beskonačan, dakle još nije politop.

Korak 4 — treće ograničenje $x_1 + x_2 \leq 4$. Granica je pravac kroz $(4, 0)$ i $(0, 4)$. Testna točka $(0, 0)$: $0 \leq 4 \checkmark$, dakle dopušteno je **ispod** pravca (strana prema ishodištu). Sada je područje trokut $(0, 0)$ – $(4, 0)$ – $(0, 4)$: ograničen, ali još nije traženi oblik.

Korak 5 — četvrto ograničenje $x_1 \leq 3$. Granica je okomit pravac kroz $x_1 = 3$. Dopusšteno je **lijevo** od njega. On „odsijeca” desni vrh trokuta $(4, 0)$ i stvara dva nova vrha: $(3, 0)$ i $(3, 1)$.

Korak 6 — sjenčanje. Osjenčajte preostali četverokut $(0, 0) \rightarrow (3, 0) \rightarrow (3, 1) \rightarrow (0, 4)$. To je politop.

Što graf znači. Svaka nejednakost „odsijeca” po jedan poluprostor; presjek svih njih je dozvoljeni skup. Kad su sva ograničenja linearna, dozvoljeni skup je uvijek ovakav „ravnoplošni” lik — poliedar. Ako je uz to ograničen, to je politop. Kod linearnog programiranja (poglavlje 5) optimum se uvijek nalazi u nekom **vrhu** ovakvog lika.



Slika 2.3: Polipot $\{x \mid Ax \leq b\}$ kao presjek četiriju poluprostora. U svakom vrhu sijeku se po dvije granice.

2.16 Konveksne i konkavne funkcije

[str. 61--64]

Dosad smo govorili o konveksnosti *skupova*. Sada isti pojam za *funkcije*.

Definicija 2.24: Konveksna funkcija [str. 61]

Funkcija $f : S \rightarrow \mathbb{R}$ je **konveksna funkcija** ako

- je S konveksan skup, i ako
- za sve $x_1, x_2 \in S$ i za svaki α gdje je $0 < \alpha < 1$ vrijedi

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2) \quad (2.22)$$

Funkcija f je **striktno konveksna** ako u (2.22) zamijenimo $\leq$ sa $<$.

Kako čitati nejednakost (2.22). Uzmite dvije točke na grafu funkcije i spojite ih ravnom crtom (**sekantom**).

- **Lijeva strana** $f(\alpha x_1 + (1 - \alpha)x_2)$ je vrijednost *funkcije* u nekoj točki između x_1 i x_2 .
- **Desna strana** $\alpha f(x_1) + (1 - \alpha)f(x_2)$ je vrijednost *sekante* u toj istoj točki.

Uvjet dakle glasi: **graf funkcije nikad nije iznad sekante** — „funkcija se drži ispod svojih tetiva”. Slikovito: funkcija ima oblik zdjele, ne kupole.

Napomena: zašto je uvjet „ S konveksan” dio definicije

Bez toga izraz $f(\alpha x_1 + (1 - \alpha)x_2)$ možda ne bi ni bio definiran — točka između x_1 i x_2 mogla bi ispasti izvan domene. Konveksnost domene osigurava da je cijela dužina u domeni.

Definicija 2.25: Konkavna funkcija [str. 62]

Funkcija $f : S \rightarrow \mathbb{R}$ je **konkavna funkcija** ako je $-f$ konveksna funkcija.

Napomena sa slajda: uočite da iz gornje definicije slijedi da je i za konkavnu funkciju domena S nužno konveksna.

Funkcija f je **striktno konkavna** ako je $-f$ striktno konveksna.

Konkavna funkcija je dakle „obrnuta zdjela” — kupola. Njezin graf nikad nije *ispod* sekante.

2.16.1 Primjeri konveksnih i nekonveksnih funkcija

[str. 63]

Konveksne funkcije	Nekonveksne funkcije
$f(x) = ax^2 + bx + c$ za $a > 0$	$f(x) = x^3$ na cijelom skupu $\mathbb{R}$
$f(x) = x $	$f(x) = - x $ (konkavna funkcija)
$f(x) = \ x\ $	$f(x) = \sqrt{x}$ na $\mathbb{R}_+$
$f(x) = \sin(x)$ na $[\pi, 2\pi]$	$f(x) = \sin(x)$ na $[0, \pi]$

Komentar uz svaki primjer:

- $ax^2 + bx + c$, $a > 0$: parabola otvorena prema gore — prototip zdjele. (Za $a < 0$ bila bi konkavna.)
- $|x|$: „V”-oblik. Konveksna je iako *nije derivabilna* u nuli — konveksnost ne traži glatkoću.
- $\|x\|$: bilo koja norma je konveksna. To dokazujemo u odjeljku 2.17.
- $\sin x$ na $[\pi, 2\pi]$: to je donja „grba” sinusa, zdjelasta. Na $[0, \pi]$ je gornja grba, dakle *konkavna*, a ne konveksna.
- x^3 na $\mathbb{R}$: konkavna je za $x < 0$, konveksna za $x > 0$ — dakle na cijelom $\mathbb{R}$ ni jedno ni drugo.
- $\sqrt{x}$: raste sve sporije, dakle kupolasta — konkavna.

Napomena: „nekonveksna” $\neq$ „konkavna”

Slajd u desnom stupcu nabraja funkcije koje *nisu konveksne*. Neke od njih *jesu* konkavne ($-|x|$, $\sqrt{x}$, $\sin$ na $[0, \pi]$), ali x^3 na $\mathbb{R}$ nije ni konveksna ni konkavna. „Nije konveksna” ne povlači „jest konkavna”.

Važan primjer sa slajda [str. 64]:**Teorem 2.16: Linearne i afine funkcije**

Linearne i afine funkcije su i **konveksne i konkavne istovremeno** (ali ne i striktno konveksne/konkavne). **To su jedine funkcije s takvim svojstvom.**

Zašto: kod afine funkcije graf *jest* pravac (odn. hiperravnina), pa sekanta leži točno *na* grafu. Nejednakost (2.22) vrijedi s jednakošću, dakle vrijedi i „ $\leq$ ” i „ $\geq$ ”. Zato je afina funkcija granični slučaj i konveksnosti i konkavnosti — i zato u konveksnim problemima ograničenja *jednakosti* smiju biti afina: uvjet $a^\top x = b$ je istovremeno $a^\top x \leq b$ i $-a^\top x \leq -b$, dakle dvije konveksne nejednakosti.

2.17 Vektorske norme

[str. V1:32–34]

Definicija 2.26: Norma

Norma je skalarna vrijednost koja služi kao **mjera veličine** vektora ili matrice.

Tzv. **p -norma** vektora $x \in \mathbb{R}^n$ (ili $\mathbb{C}^n$) definirana je:

$$\|x\|_p := \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}, \quad 1 \leq p < \infty,$$

$$\|x\|_\infty := \max_{1 \leq i \leq n} (|x_i|), \quad p = \infty$$

Euklidska norma (2-norma):

$$\|x\|_2 = \sqrt{x^*x} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

Tri norme koje ćemo najviše koristiti:

Oznaka	Formula	Značenje
$\ x\ _1$	$ x_1 + x_2 + \cdots + x_n $	zbroj apsolutnih vrijednosti („ <i>Manhattan</i> ”)
$\ x\ _2$	$\sqrt{x_1^2 + \cdots + x_n^2}$	obična duljina vektora (Pitagora)
$\ x\ _\infty$	$\max_i x_i $	najveća komponenta po apsolutnoj vrijednosti

Zašto ime „Manhattan”: u pravokutnoj mreži ulica put od ishodišta do točke (x_1, x_2) iznosi $|x_1| + |x_2|$ — ne može se ići dijagonalno kroz zgrade.

Zašto oznaka ∞ : kad p raste, u sumi $\sum |x_i|^p$ sve više prevladava *najveći* član, jer se on potencira najbrže. U granici ostaje samo on, pa $\|x\|_p \rightarrow \max_i |x_i|$.

Brojčani primjer. Za $x = (3, -4)^\top$:

$$\|x\|_1 = |3| + |-4| = 3 + 4 = 7 \quad (2.23)$$

$$\|x\|_2 = \sqrt{3^2 + (-4)^2} = \sqrt{9 + 16} = \sqrt{25} = 5 \quad (2.24)$$


$$\|x\|_\infty = \max(|3|, |-4|) = \max(3, 4) = 4 \quad (2.25)$$

Uočite poredak $\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1$ — to vrijedi uvijek.

Slika sa slajda [str. V1:33]: jedinične kugle. Slajd prikazuje u ravnini krivulje $\{x \mid \|x\|_p = 1\}$ za $p = 1; 1.5; 2; 3; 6; \infty$:

- $p = 1$: **romb** (kvadrat zarotiran za 45°) s vrhovima u $(\pm 1, 0)$ i $(0, \pm 1)$;
- $p = 2$: **kružnica** polumjera 1;
- rastući p : oblik se sve više „napuhuje” prema van;
- $p = \infty$: **kvadrat** sa stranicama $x_1 = \pm 1, x_2 = \pm 1$.

Svi ti oblici su **konveksni skupovi** — što je slikoviti dokaz da je svaka norma konveksna funkcija (nivo skupovi konveksne funkcije su konveksni, vidi odjeljak 2.18).



Slika 2.4: Jedinične kugle p -normi u $\mathbb{R}^2$: romb ($p = 1$), kružnica ($p = 2$) i kvadrat ($p = \infty$), s međuslučajevima.

Slika sa slajda [str. V1:34]: 3D slučaj. Prikazan je **oktaedar** (jedinična kugla 1-norme u $\mathbb{R}^3$) upisan u **kocku** (jedinična kugla ∞ -norme). Vrhovi oktaedra dodiruju sredine stranica kocke. Kugla 2-norme (obična sfera) bila bi između njih.

2.18 Važna svojstva konveksnih funkcija

[str. 67--70]

2.18.1 Dva svojstva sa slajda 67

Teorem 2.17: Svojstva konveksnih funkcija

- **Pozitivno semidefinitan Hessian** na cijelom S .
- **Nivo skupovi su konveksni skupovi** (ne vrijedi nužno i obrnuto: konveksni nivo skupovi $\not\Rightarrow$ konveksna funkcija).

Slajd 67 to ilustrira crtežom: nacrtane su tri ugniježdene zatvorene nivo krivulje (svaka konveksnog oblika), na jednoj od njih je označena točka x i strelica $\nabla f(x)$ koja iz nje izlazi okomito na krivulju.

Napomena o zagradi. Tvrdnja „nivo skupovi konveksni $\Rightarrow$ funkcija konveksna” *ne vrijedi*. Funkcije koje imaju konveksne nivo skupove, a same nisu konveksne, imaju svoje ime — sljedeći odjeljak.

2.18.2 Kvazikonveksne funkcije

[str. 68]

Definicija 2.27: Kvazikonveksna funkcija

Kvazikonveksne funkcije (koje nisu konveksne funkcije) imaju **konveksne nivo skupove**.

Slika sa slajda. Prikazana je funkcija jedne varijable koja: kreće s neke vrijednosti, pada do „ravnog dna”, ostaje neko vrijeme približno konstantna, pa naglo raste. Vodoravnim isprekidanim crtama označene su dvije razine α (niža) i β (viša), a na osi apscisa točke a, b, c .

Poanta slike: presjek grafa s bilo kojom vodoravnom razinom daje *jedan povezan interval* (npr. za razinu α interval oko dna, za razinu β širi interval) — a interval je konveksan skup. Funkcija ipak nije konveksna jer joj graf mjestimično „visi” iznad sekante.

Napomena: zašto nas kvazikonveksnost zanima

Kod kvazikonveksne funkcije još uvijek vrijedi da se minimum može tražiti „gledanjem nivo skupova”, pa postoje algoritmi (npr. bisekcija po razini) koji je pouzdano minimiziraju. Kvazikonveksnost je dakle *slabija*, ali još uvijek korisna pretpostavka.

2.18.3 Uvjeti prvog reda

[str. 69]

Teorem 2.18: Uvjeti prvog reda za konveksnost

Neka je $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferencijabilna funkcija s konveksnom domenom. Tada je f konveksna funkcija **ako i samo ako**

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x)$$

za sve x, y iz domene od f .

Kako to čitati. Desna strana je upravo **linearizacija** (tangenta) funkcije f u točki x , iz odjeljka 2.9. Uvjet kaže: **graf konveksne funkcije nikad nije ispod svoje tangente** — tangenta u bilo kojoj točki podupire funkciju odozdo.

Slajd 69 to crta: zakrivljena krivulja $f(y)$ i pravac $f(x) + \nabla f(x)^\top (y - x)$ koji je dodiruje u točki $(x, f(x))$ i cijelim ostatkom prolazi ispod nje.

Napomena: dvije „nikad ispod / nikad iznad” slike — ne zamijeniti

- Definicija (2.22): graf je **ispod sekante** (crte koja spaja dvije točke *na* grafu).
- Uvjet prvog reda: graf je **iznad tangente** (crte koja grafa dodiruje u jednoj točki).

Objе slike opisuju istu stvar — zakrivljenost prema gore.

Posljedica koja objašnjava zašto je konveksnost tako moćna. Ako je $\nabla f(x) = 0$ u nekoj točki x , uvjet prvog reda daje

$$f(y) \geq f(x) + 0^\top (y - x) = f(x) \quad \text{za sve } y$$

Dakle x je **globalni** minimum. Kod konveksnih funkcija stacionarna točka automatski je globalni minimum — nema „zamki” lokalnih minimuma.

2.18.4 Uvjeti drugog reda

[str. 70]

Teorem 2.19: Uvjeti drugog reda za konveksnost

Neka je $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferencijabilna funkcija s konveksnom domenom. Tada vrijedi:

- f je konveksna funkcija **ako i samo ako** $\nabla^2 f(x) \succeq 0$ za sve x u domeni;
- ako je $\nabla^2 f(x) \succ 0$ za sve x u domeni, tada je f **striktno konveksna** funkcija.

Ovo je najkorisniji praktični test konveksnosti: izračunaj Hessian i provjeri je li pozitivno semidefinitan (odjeljak 2.12).

Napomena: smjer druge tvrdnje

Prva tvrdnja je „ako i samo ako”, druga samo „ako”. Obrat druge *ne* vrijedi: $f(x) = x^4$ je striktno konveksna, ali $f''(0) = 0$, dakle Hessian nije svugdje strogo pozitivan.

Primjer primjene. Za $f(x) = \frac{1}{2}x^\top Qx + c^\top x + d$ Hessian je $\nabla^2 f = Q$ (konstantan). Dakle takva kvadratna funkcija je konveksna $\Leftrightarrow Q \succeq 0$, i striktno konveksna ako je $Q \succ 0$. Time smo dobili gotov kriterij za sve kvadratne probleme — koristit ćemo ga u poglavlju 5.

2.19 Konveksan optimizacijski problem

[str. 71–72 i V2:2–3]

Sve prethodno vodi do sljedeće definicije, koja se u izvorniku pojavljuje i na predavanju [str. 71–72] i na vježbama [str. V2:2–3], s identičnim sadržajem.

Definicija 2.28: Konveksan optimizacijski problem

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h_i(x) = 0, \quad i = 1, \dots, m \\ &&& g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{2.26}$$

gdje su $f(x)$ i $g_j(x)$, $j = 1, \dots, p$ **konveksne** funkcije, a $h_i(x)$, $i = 1, \dots, m$ su **afine** funkcije.

Budući da je svaka afina funkcija oblika $a_i^\top x - b_i$, isti se problem piše i ovako [str. 72 i V2:3]:

Definicija 2.29: Konveksan optimizacijski problem — eksplicitni oblik

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && a_i^\top x = b_i, \quad i = 1, \dots, m \\ &&& g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{2.27}$$

gdje su $f(x)$ i $g_j(x)$, $j = 1, \dots, p$ konveksne funkcije.

Kontrolna lista — je li problem konveksan? Provjerite tri stvari:

1. Je li funkcija cilja f **konveksna**? (Ako maksimizirate, pretvorite u $\min(-f)$ i onda provjerite.)

2. Jesu li *sve* funkcije nejednakosti g_j **konveksne**, i to u standardnoj formi $g_j(x) \leq 0$?
3. Jesu li *sve* funkcije jednakosti h_i **afine**? (Ne samo konveksne — **afine**.)

Napomena: najčešće zamke pri provjeri

- **Smjer nejednakosti je bitan.** Ako je g konveksna, skup $\{g(x) \leq 0\}$ je konveksan, ali $\{g(x) \geq 0\}$ općenito **nije**. Prvo prevedite sve u oblik „ ≤ 0 ”.
- **Jednakosti moraju biti afine.** Ograničenje $h(x) = 0$ s konveksnom, ali nelinearnom h opisuje zakrivljenu plohu — a ploha nije konveksan skup.
- **Konveksnost ovisi o zapisu, ne o skupu.** Isti dozvoljeni skup može biti zapisan nekonveksno; tada se problem često može *reformulirati* u konveksan (primjer 2) niže).

Zadatak 2.5 — Vježbe 2, Primjer 1: prepoznavanje konveksnih problema

[str. V2:4--5]

Postavka. Koji od sljedećih problema spadaju u konveksne opt. probleme?

1. $\min_x \{2x^2 - 3x + 1 \mid 0 \leq x \leq 10\}$
2. $\min_x \{2x^2 - 3x + 1 \mid x^2 - 1 \geq 0, x \geq 1\}$
3. $\min_x \{x^4 - 3x + 1 \mid x(x - 1) = 0\}$
4. $\min_x \{x^4 - 3x + 1 \mid x \in \{0, 1\}\}$
5. $\min_{x \in \mathbb{R}^3} \left\{ \|x\|_2 \mid \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} x = 0, x_2 \leq 0 \right\}$
6. $\min_{x \in \mathbb{R}^3} (\|x\|_1 - \|x\|_2)$

Rješenja (doslovno sa slajda V2:5):

1. konveksan
2. nije konveksan, ali kad se reformulira u $\min_x \{2x^2 - 3x + 1 \mid x \geq 1\}$, je konveksan
3. nije konveksan
4. nije konveksan
5. konveksan
6. nije konveksan

Obrazloženja (slajd daje samo verdikte; obrazloženja niže slijede iz kontrolne liste gore i definicija s prethodnih slajdova).

1) $\min 2x^2 - 3x + 1$ **uz** $0 \leq x \leq 10$ — **konveksan**.

- Cilj: $f(x) = 2x^2 - 3x + 1$; $f''(x) = 4 > 0$, dakle konveksna (uvjeti drugog reda [str. 70]; ovo je i primjer $ax^2 + bx + c$, $a > 0$ sa str. 63).
- Ograničenja u standardnoj formi: $0 \leq x$ postaje $-x \leq 0$; $x \leq 10$ postaje $x - 10 \leq 0$. Obje su **afine**, dakle konveksne.
- Sva tri uvjeta kontrolne liste su ispunjena. ✓

2) $\min 2x^2 - 3x + 1$ **uz** $x^2 - 1 \geq 0, x \geq 1$ — **nije konveksan (ali se daje popraviti)**.

- Cilj je konveksan (kao gore).
- Problem je prvo ograničenje. U standardnu formu: $x^2 - 1 \geq 0 \Leftrightarrow 1 - x^2 \leq 0$, dakle $g_1(x) = 1 - x^2$. Njegova druga derivacija je $g_1'' = -2 < 0$, dakle g_1 je **konkavna**, a ne konveksna. Kontrolna lista pada na koraku 2.
- Geometrijski: skup $\{x \mid x^2 \geq 1\}$ je $(-\infty, -1] \cup [1, \infty)$ — dva odvojena dijela, dakle

nije konveksan skup (dužina od -1 do 1 izlazi iz skupa).

- *Reformulacija*: presjek s drugim ograničenjem $x \geq 1$ daje $\mathcal{F} = \{x \geq 1\}$, jer je $[1, \infty)$ već sadržan u skupu $x^2 \geq 1$. Prvo ograničenje je dakle **suvišno** i može se izbaciti. Ostaje $\min_x \{2x^2 - 3x + 1 \mid x \geq 1\}$ — konveksan problem s afnim ograničenjem $1 - x \leq 0$. ✓

- **Poanta**: isti dozvoljeni skup, dva zapisa — jedan konveksan, drugi ne. Uvijek se isplati pojednostaviti zapis prije nego zaključite da problem nije konveksan.

3) $\min x^4 - 3x + 1$ uz $x(x - 1) = 0$ — **nije konveksan**.

- Cilj *jest* konveksan: $f(x) = x^4 - 3x + 1$, $f'' = 12x^2 \geq 0$ za sve x .
- Ali ograničenje jednakosti je $h(x) = x(x - 1) = x^2 - x$, što je **kvadratna**, dakle **nije afina**. Kontrolna lista pada na koraku 3.
- *Geometrijski*: $x(x - 1) = 0$ znači $x = 0$ ili $x = 1$ — dvije izolirane točke, što nije konveksan skup.

4) $\min x^4 - 3x + 1$ uz $x \in \{0, 1\}$ — **nije konveksan**.

- Ovo je *isti* problem kao 3), samo zapisan pripadnošću diskretnom skupu umjesto jednakšbom (usporedi slajdove 16 i 17 iz predavanja).
- Dozvoljeni skup $\{0, 1\}$ je diskretan, dakle nije konveksan. Ovo je **cjelobrojni** problem.

5) $\min \|x\|_2$ uz $\begin{pmatrix} 1 & 1 & 1 \end{pmatrix} x = 0$, $x_2 \leq 0$ — **konveksan**.

- *Cilj*: $\|x\|_2$ je norma, a norme su konveksne funkcije [str. 63]. ✓
- *Jednakost*: $\begin{pmatrix} 1 & 1 & 1 \end{pmatrix} x = 0$ je $x_1 + x_2 + x_3 = 0$, dakle oblika $a^\top x = b$ uz $a = (1, 1, 1)^\top$, $b = 0$ — **afina**. ✓
- *Nejednakost*: $x_2 \leq 0$ je afina (može se pisati kao $e_2^\top x \leq 0$). ✓
- Sva tri uvjeta ispunjena.
- *Usput, rješenje je očito*: $x^* = (0, 0, 0)$ zadovoljava oba ograničenja i daje $\|x\|_2 = 0$, što je najmanja moguća vrijednost norme.

6) $\min \|x\|_1 - \|x\|_2$ — **nije konveksan**.

- Problem *nema* ograničenja, pa je pitanje isključivo je li cilj konveksan.
- $\|x\|_1$ je konveksna, ali $-\|x\|_2$ je **konkavna** (negativ konveksne funkcije, po definiciji sa str. 62). **Razlika dviju konveksnih funkcija općenito nije konveksna** — zbroj konveksnih jest, ali razlika nije.
- *Konkretna provjera nejednakosti* (2.22) u $\mathbb{R}^2$: uzmimo $x_1 = (1, 0)^\top$, $x_2 = (0, 1)^\top$ i $\alpha = 0,5$. Označimo $f(x) = \|x\|_1 - \|x\|_2$.

$$f(x_1) = (|1| + |0|) - \sqrt{1^2 + 0^2} = 1 - 1 = 0 \quad (2.28)$$

$$f(x_2) = (|0| + |1|) - \sqrt{0^2 + 1^2} = 1 - 1 = 0 \quad (2.29)$$

Desna strana: $0,5 \cdot 0 + 0,5 \cdot 0 = 0$. Srednja točka: $0,5x_1 + 0,5x_2 = (0,5; 0,5)^\top$, pa

$$f(0,5; 0,5) = (0,5 + 0,5) - \sqrt{0,25 + 0,25} = 1 - \sqrt{0,5} = 1 - 0,7071 = 0,2929$$

Lijeva strana 0,2929 je **veća** od desne 0, dakle uvjet (2.22) je **prekršen** — funkcija nije konveksna. ✓

2.20 Norme kao konveksne funkcije i praktične reformulacije

[str. V2:6--11]

2.20.1 Kako izgledaju norme kao funkcije

[str. V2:6--8]

Slajdovi V2:6--8 prikazuju svaku od tri norme dvaput: kao 3D plohu nad ravninom (x_1, x_2) i kao nivo krivulje u toj ravnini.

Funkcija	3D ploha	Nivo krivulje
$f(x) = \ x\ _1 = \sum_{i=1}^n x_i $	„šator” s četiri ravne plohe, vrh (nula) u ishodištu	koncentrični rombovi
$f(x) = \ x\ _2 = \sqrt{\sum_{i=1}^n (x_i)^2}$	glatki stožac s vrhom u ishodištu	koncentrične kružnice
$f(x) = \ x\ _\infty = \max_{1 \leq i \leq n} (x_i)$	piramida s četiri ravne plohe	koncentrični kvadrati

Sve tri plohe su „zdjelastog” (točnije, stožastog) oblika s najnižom točkom u ishodištu — vizualna potvrda konveksnosti. Nivo krivulje su upravo kugle iz odjeljka 2.17, samo skalirane.

2.20.2 Minimizacija norme kao konveksan optimizacijski problem

[str. V2:9--11]

Ovo su tri vrlo korisne **reformulacije**: problem s normom u funkciji cilja prevodimo u oblik koji standardni rješavači izravno prihvaćaju. Sve tri imaju istu strukturu:

$$\begin{aligned} \min_x \quad & \|Ax + b\|_\bullet \\ \text{uz ograničenja} \quad & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned}$$

1-norma [str. V2:9]

$$\begin{aligned} \min_x \quad & \|Ax + b\|_1 \\ \text{uz ograničenja} \quad & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \quad \Longleftrightarrow \quad \begin{aligned} \min_{x, y} \quad & \mathbf{1}^\top y = \sum_i y_i \\ \text{uz ograničenja} \quad & -y \leq Ax + b \leq y \\ & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned}$$

gdje je (sa slajda) y vektor iste veličine kao i x , a $\mathbf{1}$ je vektor stupac sa svim elementima jednakim 1. **Funkcija cilja je linearna (pa stoga i konveksna).**

Zašto to radi — korak po korak.

- Označimo $r = Ax + b$ („rezidual”). Tada je $\|r\|_1 = \sum_i |r_i|$.
- Dvostruka nejednakost $-y_i \leq r_i \leq y_i$ znači točno $|r_i| \leq y_i$: apsolutna vrijednost je omeđena odozgo s y_i . (Ako je $r_i \geq 0$, veže desna nejednakost; ako je $r_i < 0$, lijeva.)

- Minimiziramo $\sum_i y_i$, dakle svaki y_i guramo što niže. Najniže što y_i smije biti je $|r_i|$.
- U optimumu je zato $y_i = |r_i|$ za svaki i , pa je $\sum_i y_i = \sum_i |r_i| = \|Ax + b\|_1$. Dva problema imaju istu optimalnu vrijednost. ✓
- **Dobitak:** apsolutne vrijednosti (koje nisu derivabilne) nestale su iz zapisa; ostale su same linearne funkcije. Ako su i h_i, g_j linearne, ovo je **LP** (poglavlje 5).

Napomena: napomena o dimenziji

Na slajdu piše da je y „iste veličine kao i x ”. Preciznije, y mora imati onoliko komponenata koliko ih ima rezidual $Ax + b$, tj. koliko A ima *redaka*. Kad je A kvadratna, to je isto.

2-norma [str. V2:10]

$$\begin{array}{ll} \min_x \|Ax + b\|_2 & \min_x (Ax + b)^\top (Ax + b) = x^\top \underbrace{A^\top A}_Q x + 2b^\top Ax + b^\top b \\ \text{uz ograničenja } h_i(x) = 0 & \iff \text{uz ograničenja } h_i(x) = 0 \\ g_j(x) \leq 0 & g_j(x) \leq 0 \end{array}$$

Budući da je matrica $Q = A^\top A$ nužno pozitivno semidefinitna, funkcija cilja je konveksna.

Zašto to radi — korak po korak.

- **Uklanjanje korijena:** $\|r\|_2 = \sqrt{r^\top r}$, a kvadriranje je strogo rastuća transformacija na nenegativnim brojevima, pa *ne mijenja položaj* minimuma (isti trik kao u odjeljku 1.8.3). Zato minimiziramo $\|r\|_2^2 = r^\top r$.
- **Raspis kvadratne forme:**

$$(Ax + b)^\top (Ax + b) = (x^\top A^\top + b^\top)(Ax + b) \quad (2.30)$$

$$= x^\top A^\top Ax + x^\top A^\top b + b^\top Ax + b^\top b \quad (2.31)$$

$$= x^\top A^\top Ax + 2b^\top Ax + b^\top b \quad (2.32)$$

Međukorak kod spajanja: $x^\top A^\top b$ je broj (1×1) , a broj je jednak svojem transponatu: $(x^\top A^\top b)^\top = b^\top Ax$. Zato su ta dva člana jednaka i zbrajaju se u $2b^\top Ax$.

- **Zašto je $Q = A^\top A \succeq 0$:** za bilo koji x ,

$$x^\top (A^\top A)x = (Ax)^\top (Ax) = \|Ax\|_2^2 \geq 0$$

jer je kvadrat norme uvijek nenegativan. To je točno definicija pozitivne semidefinitnosti [str. 46]. ✓

- **Dobitak:** cilj je kvadratna funkcija s $Q \succeq 0$, dakle konveksna (uvjeti drugog reda [str. 70]). Ako su ograničenja linearna, ovo je **QP** (poglavlje 5).
- Zadnji član $b^\top b$ je konstanta i ne utječe na arg min — može se i izostaviti.

∞ -norma [str. V2:11]

$$\begin{array}{ll} \min_x \|Ax + b\|_\infty & \min_{x,t} t \\ \text{uz ograničenja } h_i(x) = 0 & \iff \text{uz ograničenja } -t\mathbf{1} \leq Ax + b \leq t\mathbf{1} \\ g_j(x) \leq 0 & h_i(x) = 0 \\ & g_j(x) \leq 0 \end{array}$$

gdje je $t \in \mathbb{R}$ dodatna **skalarna** projektna varijabla, a $\mathbf{1}$ je vektor stupac sa svim elementima jednakim 1. **Funkcija cilja je linearna (pa stoga i konveksna).**

Zašto to radi — korak po korak.

- $\|r\|_\infty = \max_i |r_i|$ — najveća komponenta po apsolutnoj vrijednosti.
- Uvjet $-t\mathbf{1} \leq r \leq t\mathbf{1}$ znači $|r_i| \leq t$ za *svaki* i (isti t za sve!). To je isto što i $\max_i |r_i| \leq t$.
- Minimiziramo t , dakle guramo tu zajedničku gornju ogradu što niže. Najniže što smije biti je točno $\max_i |r_i|$.
- U optimumu je $t^* = \|Ax + b\|_\infty$. ✓
- **Razlika u odnosu na 1-normu:** tamo je svaka komponenta imala *svoju* varijablu y_i (vektor), ovdje sve dijele *jedan* t (skalar) — jer $\max$ traži jednu zajedničku ogradu, a suma pojedinačne.

Napomena: prepoznajte obrazac

Sve tri reformulacije koriste isti trik koji smo prvi put vidjeli kod problema dopustivosti (1.40): **uvođenje pomoćne varijable koja zamjenjuje $\max$ ili $|\cdot|$ običnom nejednakošću.** Kad god u funkciji cilja vidite $\max$, apsolutnu vrijednost ili normu, prvo posegnite za ovim trikom. On se ponavlja i u poglavljima 5 i 8.

Kada koju normu birati. Sve tri mjere „veličinu pogreške”, ali različito:

Norma	Što kažnjava	Tip problema
$\ \cdot\ _1$	zbroj svih odstupanja	LP
$\ \cdot\ _2$	kvadrati odstupanja (velika jače)	QP
$\ \cdot\ _\infty$	samo najgore odstupanje	LP

Ako je bitno da *nijedna* pojedinačna pogreška ne bude velika, bira se ∞ -norma. Ako je bitan ukupni zbroj, 1- ili 2-norma. Ovim se detaljno bavimo u Vježbama 4 (poglavlje 5).

2.21 Sažetak poglavlja

Što morate znati napamet:

1. **Linearno** $= f(x) = Ax$ (kroz ishodište); **afino** $= f(x) = Ax + b$. Razlika je bitna kod ograničenja jednakosti.
2. **Nivo krivulja** $\mathcal{S}_c = \{x \mid f(x) = c\}$; nivo krivulje linearne funkcije su paralelni pravci, a a je okomit na njih.
3. **Skalarni produkt** $x^\top y = \|x\| \|y\| \cos \varphi$; nula $\Leftrightarrow$ okomitost; predznak određuje polupros-tor.
4. **Gradijent** ∇f — smjer najbržeg rasta, okomit na nivo krivulju. Smjer pada: $\nabla f(x)^\top d \leq 0$.
5. **Hessian** $\nabla^2 f$ — simetrična matrica drugih derivacija.
6. **Uvjeti bez ograničenja:** nužno $\nabla f = 0$ i $\nabla^2 f \succeq 0$; dovoljno $\nabla f = 0$ i $\nabla^2 f \succ 0$.
7. **Definitnost:** preko svojstvenih vrijednosti ili vodećih glavnih minora ($D_1, D_2, \dots > 0$ za $\succ 0$).

8. **Afin skup** (pravac ostaje u skupu) vs. **konveksan skup** (dužina ostaje u skupu). Presjek konveksnih je konveksan.
9. **Hiperravnina** $a^\top x = b$, **poluprostor** $a^\top x \leq b$, **poliedar** = presjek konačno mnogo njih, **politop** = ograničen poliedar.
10. **Konveksna funkcija**: ispod sekante, iznad tangente, $\nabla^2 f \succeq 0$. Norme su konveksne.
11. **Konveksan problem**: f i g_j konveksne, h_i **afine**.
12. **Reformulacije normi** preko pomoćne varijable (y za 1-normu, kvadriranje za 2-normu, t za ∞ -normu).

Zašto je konveksnost prava granica. Kod konveksnog problema svaka stacionarna točka je globalni minimum (posljedica uvjeta prvog reda, odjeljak 2.18). Kod nekonveksnog problema algoritam može zapeti u lošem lokalnom minimumu i nikad ne saznamo koliko smo daleko od najboljeg rješenja. Zato je moderna podjela „konveksno vs. nekonveksno”, a ne „linearno vs. nelinearno” [str. 52].

Terminologija (hrvatski $\leftrightarrow$ engleski):

Hrvatski	Engleski
afina funkcija / afin skup	affine function / affine set
konveksan skup / funkcija	convex set / function
konveksna ljuska	convex hull
hiperravnina	hyperplane
poluprostor	half-space
poliedar / politop	polyhedron / polytope
gradijent	gradient
Hessian	Hessian
pozitivno (semi)definitna	positive (semi)definite
nivo krivulja / nivo skup	level curve / sublevel set
infimum / supremum	infimum / supremum
lokalni / globalni minimizator	local / global minimiser
cjelobrojno optimiranje	integer optimization

POGLAVLJE 3

Uvjeti optimalnosti

Izvor: 03_Uvjeti_optimalnosti.pdf, stranice 1--68 (obrađeno u cijelosti).

Ovo je najvažnije poglavlje kolegija: ovdje se izvede **KKT uvjeti**, koji su temelj svega što slijedi. Vježbe 3 se naslanjaju na ovo poglavlje, ali ih obrađujemo u poglavlju 4 jer njihovi zadaci traže i dualnost i analizu osjetljivosti.

3.1 Postavka: problem s ograničenjima

[str. 2]

$$\begin{array}{ll} \text{minimiziraj} & f(x) \\ \text{uz ograničenja} & h(x) = 0, \quad g(x) \leq 0 \end{array} \quad (3.1)$$

Uz definiciju dozvoljenog skupa $\mathcal{F} := \{x \mid h(x) = 0, g(x) \leq 0\}$, gornji problem se može zapisati na kompaktniji način:

$$\min_{x \in \mathcal{F}} f(x)$$

Zašto nam trebaju novi uvjeti. U poglavlju 2 smo za problem *bez* ograničenja dobili uvjet $\nabla f(x^*) = 0$ [str. 2:43]. Uz ograničenja to više **ne vrijedi**: optimum često leži na *rubu* dozvoljenog skupa, gdje gradijent nije nula — funkcija bi i dalje padala, ali nas ograničenje sprječava da idemo dalje. Cijelo ovo poglavlje gradi zamjenu za taj uvjet.

3.2 Dozvoljeni smjerovi i smjerovi pada

[str. 3--8]

Definicija 3.1: Dozvoljeni smjer [str. 3]

Svaki vektor $d \in \mathbb{R}^n$, gdje $d \neq 0$, zove se **dozvoljeni smjer** za točku $x \in \mathcal{F}$, ako postoji $\alpha_0 > 0$ tako da

$$x + \alpha d \in \mathcal{F} \quad \text{za sve } \alpha \text{ gdje je } 0 \leq \alpha \leq \alpha_0.$$

Dakle (sa slajda): d je dozvoljeni smjer za x u $\mathcal{F}$ ako možemo napraviti **mali korak** od x u smjeru d , tako da ostanemo u dozvoljenom skupu $\mathcal{F}$.

Napomena: zašto „mali korak” i zašto α_0

Ne traži se da cijela zraka $x + \alpha d$ ostane u $\mathcal{F}$ za *sve* $\alpha > 0$ — to bi bilo prestrogo (kod ograničenog skupa nijedan smjer ne bi prošao). Traži se samo da postoji *neka* duljina koraka α_0 , ma koliko mala, unutar koje ostajemo dopustivi. Broj α_0 smije ovisiti o d .

Definicija 3.2: Skup dozvoljenih smjerova [str. 4]

Neka je $D(x)$ skup svih dozvoljenih smjerova u x , tj. za $x \in \mathcal{F}$ neka je

$$D(x) := \{ d \mid d \neq 0, x + \alpha d \in \mathcal{F} \text{ za sve } 0 \leq \alpha \leq \alpha_0 \text{ i za neki } \alpha_0 > 0 \}.$$

Definicija 3.3: Skup smjerova pada [str. 5]

Neka je S skup svih **smjerova pada** funkcije cilja f u točki x , tj.

$$S(x) := \{ d \mid d^\top \nabla f(x) < 0 \}.$$

Ovo je pojam iz odjeljka 2.9: korak u smjeru d smanjuje f ako d zatvara tup kut s gradijentom.

Teorem 3.1: Nužni uvjeti optimalnosti prvog reda [str. 6]

Ako je x^* lokalni minimizator od f na skupu $\mathcal{F}$, i ako je f diferencijabilna funkcija u x^* , tada vrijedi

$$D(x^*) \cap S(x^*) = \emptyset$$

Alternativno, za svaki $d \in D(x^*)$ vrijedi da je $d^\top \nabla f(x^*) \geq 0$.

Objašnjenje sa slajda [str. 7]. Dakle, u točki lokalnog minimuma **presjek svih dozvoljenih smjerova i smjerova koji vode poboljšanju funkcije cilja je prazan**. Alternativno, ako je x^* minimizator optimizacijskog problema s ograničenjima, sa svakim korakom iz x^* u dozvoljenom smjeru, funkcija cilja **nužno raste**.

Zašto to mora vrijediti. Kad bi postojao smjer koji je istovremeno dozvoljen i silazan, mogli bismo napraviti mali korak u tom smjeru, ostati unutar $\mathcal{F}$ i dobiti *manju* vrijednost f . Ali onda x^* ne bi bio lokalni minimum — kontradikcija. Dakle takav smjer ne smije postojati: presjek mora biti prazan. ■

Napomena: oznaka $\emptyset$

$\emptyset$ označava **prazan skup** — skup bez ijednog elementa. Zapis $A \cap B = \emptyset$ znači „skupovi A i B nemaju nijedan zajednički element”.

Poseban slučaj: točka u unutrašnjosti [str. 8]. Ako se x^* dodatno nalazi u **unutrašnjosti** dozvoljenog skupa $\mathcal{F}$ (svaki d je dozvoljeni smjer), nužno vrijedi

$$\nabla f(x^*) = 0.$$

Zašto: ako su *svi* smjerovi dozvoljeni, uvjet $d^\top \nabla f(x^*) \geq 0$ mora vrijediti i za d i za $-d$. Iz $d^\top \nabla f \geq 0$ i $-d^\top \nabla f \geq 0$ slijedi $d^\top \nabla f = 0$ za sve d , a jedini vektor okomit na *sve* vektore je nul-vektor. Time smo iz općeg uvjeta izveli poznati uvjet za probleme bez ograničenja.

Napomena: oštro upozorenje sa slajda 8

Ovo su samo nužni uvjeti za optimalnost! Kod problema s ograničenjima, $d^\top \nabla f(x^*) \geq 0$ za sve $d \in D(x^*)$ **ne znači** da je x^* lokalni minimizator. Nužan uvjet služi za *izbacivanje* kandidata: točka koja ga ne zadovoljava sigurno nije optimum. Točka koja ga zadovoljava je samo *kandidat* i mora se dodatno provjeriti.

3.3 Primjer: sedlasta funkcija na disku

[str. 9--18]

Problem [str. 9]:

$$\min_{x \in \mathcal{F}} f(x), \quad \text{gdje je } f(x) = x_1^2 - x_2^2, \quad \mathcal{F} = \{x \mid x_1^2 + x_2^2 \leq 1\}$$

Slajd 9 prikazuje dvije slike: 3D plohu funkcije f (klasično **sedlo** — raste u smjeru x_1 , pada u smjeru x_2) i njezine nivo krivulje (hiperbole) s ucrtanom crvenom jediničnom kružnicom koja omeđuje $\mathcal{F}$.

Dozvoljeni skup je **jedinični disk** (krug s rubom), a funkcija cilja nema ni minimum ni maksimum u njegovoj unutrašnjosti — u ishodištu je *sedlo*. Optimum je stoga na rubu, pa je ovo idealan primjer za testiranje uvjeta iz prethodnog odjeljka.

3.3.1 Kandidat 1: $x^* = (0, 1)^\top$ — prolazi test

[str. 10--13]

Tvrđnja sa slajda [str. 10]: $x^* = \begin{pmatrix} 0 & 1 \end{pmatrix}^\top$ je **lokalni minimum** na rubu dozvoljenog područja $\mathcal{F}$.

Korak 1 — dozvoljeni smjerovi [str. 11]. Dozvoljeni smjerovi u x^* su svi vektori oblika $d = \begin{pmatrix} d_1 & d_2 \end{pmatrix}^\top$ sa $d_2 \leq 0$.

Zašto: točka $(0, 1)$ je na „vrhu” kružnice. Bilo koji korak s *pozitivnom* komponentom d_2 vodi izvan diska (jer bi x_2 postao veći od 1, a onda $x_1^2 + x_2^2 > 1$). Koraci s $d_2 \leq 0$ vode dolje ili vodoravno — za dovoljno mali α ostajemo unutar diska.

Korak 2 — gradijent [str. 12]. Gradijent funkcije cilja u x^* je

$$\nabla f(x^*) = \begin{pmatrix} 2x_1^* \\ -2x_2^* \end{pmatrix} = \begin{pmatrix} 0 \\ -2 \end{pmatrix}$$

Raspis: iz $f = x_1^2 - x_2^2$ slijedi $\partial f / \partial x_1 = 2x_1$ i $\partial f / \partial x_2 = -2x_2$. Uvrštavanje $x^* = (0, 1)$: $2 \cdot 0 = 0$ i $-2 \cdot 1 = -2$. ✓

Korak 3 — provjera uvjeta [str. 13]. Nužni uvjeti optimalnosti prvog reda za lokalni minimum u točki x^* :

$$d^\top \nabla f(x^*) = -2d_2 \geq 0$$

su **zadovoljeni** jer za sve dozvoljene smjerove vrijedi $d_2 \leq 0$.

Raspis skalarnog produkta:

$$d^\top \nabla f(x^*) = \begin{pmatrix} d_1 & d_2 \end{pmatrix} \begin{pmatrix} 0 \\ -2 \end{pmatrix} = d_1 \cdot 0 + d_2 \cdot (-2) = -2d_2$$

Ako je $d_2 \leq 0$, onda je $-2d_2 \geq 0$. ✓

3.3.2 Kandidat 2: $x^* = (1, 0)^\top$ — pada na testu

[str. 14--18]

Postavka [str. 14]. Promotrimo točku $x^* = \begin{pmatrix} 1 & 0 \end{pmatrix}^\top$ na rubu dozvoljenog područja $\mathcal{F}$.

Korak 1 — dozvoljeni smjerovi [str. 15]. Dozvoljeni smjerovi u x^* su svi vektori oblika $d = \begin{pmatrix} d_1 & d_2 \end{pmatrix}^\top$ sa $d_1 \leq 0$.

Zašto: $(1, 0)$ je na desnom rubu kružnice; korak udesno ($d_1 > 0$) izlazi iz diska.

Korak 2 — gradijent [str. 16]:

$$\nabla f(x^*) = \begin{pmatrix} 2x_1^* \\ -2x_2^* \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$$

Korak 3 — provjera [str. 17]. Nužni uvjeti optimalnosti prvog reda traže:

$$d^\top \nabla f(x^*) = 2d_1 \geq 0 \quad \text{za sve dozvoljene smjerove.}$$

Korak 4 — zaključak [str. 18]. Budući da je $d_1 \leq 0$ za dozvoljene smjerove, izraz $2d_1$ je negativan (npr. za $d = (-1, 0)^\top$ dobivamo $2 \cdot (-1) = -2 < 0$). Uvjet je prekršen, pa točka x^* ne može biti lokalni optimum.

Provjera zdravim razumom: krenimo iz $(1, 0)$ ulijevo, u $(1 - \alpha, 0)$. Tada je $f = (1 - \alpha)^2 - 0 = (1 - \alpha)^2 < 1 = f(1, 0)$ za mali $\alpha > 0$. Funkcija doista pada — točka nije minimum. ✓

Kako to nacrtati rukom: dozvoljeni smjerovi i gradijent na disku

Korak 1. Nacrtajte osi x_1 i x_2 od $-1,5$ do $1,5$, jednakim mjerilom.

Korak 2 — dozvoljeni skup. Nacrtajte kružnicu polumjera 1 oko ishodišta i osjenčajte njezinu unutrašnjost. To je $\mathcal{F}$: nejednakost $x_1^2 + x_2^2 \leq 1$ dopušta *unutrašnjost* (provjera: ishodište daje $0 \leq 1$ ✓).

Korak 3 — nivo krivulje funkcije cilja. Krivulje $x_1^2 - x_2^2 = c$ su **hiperbole**. Za $c = 0$ dobivamo $x_1^2 = x_2^2$, tj. dva pravca $x_2 = \pm x_1$ — nacrtajte ih prve, oni su „križ” kroz ishodište. Za $c > 0$ hiperbole se otvaraju lijevo-desno, za $c < 0$ gore-dolje.


Korak 4 — prva kandidatna točka. Označite $(0, 1)$ na vrhu kružnice. Iz nje nacrtajte gradijent $\nabla f = (0, -2)$: strelicu **ravno dolje**, prema unutrašnjosti diska.

Korak 5 — dozvoljeni smjerovi u toj točki. Iz $(0, 1)$ nacrtajte nekoliko kratkih strelica koje pokazuju *dolje*, *lijevo-dolje*, *desno-dolje* i *vodoravno*. Sve one imaju $d_2 \leq 0$. Uočite: nijedna ne pokazuje prema gore — gore je izvan diska.

Korak 6 — geometrijsko čitanje uvjeta. Uvjet $d^\top \nabla f \geq 0$ znači da svaka dozvoljena strelica zatvara s gradijentom kut $\leq 90^\circ$. Provjerite okom: gradijent pokazuje dolje, sve dozvoljene strelice imaju komponentu prema dolje ili su vodoravne, dakle nijedna nije „suprotna” gradijentu. Uvjet vrijedi.

Korak 7 — druga kandidatna točka. Označite $(1, 0)$ na desnom rubu. Nacrtajte gradijent $\nabla f = (2, 0)$: strelicu **ravno udesno**, prema *van* iz diska. Dozvoljene strelice pokazuju *ulijevo* — dakle suprotno od gradijenta, kut je 180° , pa je $d^\top \nabla f < 0$. To je smjer u kojem f pada, a dozvoljen je: točka nije optimum.

Što graf znači. Usporedba dviju točaka pokazuje bit uvjeta prvog reda: u optimumu gradijent mora „gurati” prema *van* iz dozvoljenog skupa (ili biti nula). Ako gradijent pokazuje prema unutra, uvijek postoji dozvoljeni smjer u kojem se cilj popravlja.



Slika 3.1: Sedlasta funkcija na jediničnom disku. U točki $(0, 1)$ (krug) gradijent (zeleno) pokazuje u disk, a svi dozvoljeni smjerovi (plavo) zatvaraju s njim kut $\leq 90^\circ$ — uvjet je zadovoljen. U točki $(1, 0)$ (kvadrat) gradijent pokazuje van, a dozvoljeni smjerovi su mu suprotni — uvjet je prekršen.

3.4 Problem s jednim ograničenjem jednakosti

[str. 19--32]

3.4.1 Postavka

[str. 19]

$$\begin{aligned} \min \quad & f(x) := x_1 + x_2 \\ \text{uz ograničenja} \quad & h(x) := 2 - x_1^2 - x_2^2 = 0 \end{aligned} \tag{3.2}$$

Grafičkom metodom: rješenje (minimizator) je $x^* = (-1, -1)$.

Pitanje sa slajda: *Kako sistematski karakterizirati optimalna rješenja?* — odnosno, kako doći do rješenja bez crtanja?

Napomena: predznak funkcije h

Na slajdu 19 je $h(x) = 2 - x_1^2 - x_2^2$, a već na sljedećem slajdu 20 piše $\mathcal{F} = \{x \mid h(x) = x_1^2 + x_2^2 - 2 = 0\}$ — dakle s obrnutim predznakom. To **nije greška**: slajd 25 izričito kaže da je smjer normale proizvoljan jer je $h(x) = 0$ ekvivalentno $-h(x) = 0$. Promjena predznaka mijenja samo *predznak* multiplikatora λ , ne i rješenje x^* . U ovoj skripti slijedimo predznak

sa slajda koji citiramo, i svaki put ga naznačimo.

3.4.2 Izvod uvjeta

[str. 20--22]

Dozvoljeni skup: $\mathcal{F} = \{x \mid h(x) = x_1^2 + x_2^2 - 2 = 0\}$.

U točki $x \in \mathcal{F}$, ako je d dozvoljeni smjer sa smanjenjem funkcije cilja, treba vrijediti:

$$f(x+d) \approx f(x) + \nabla f(x)^\top d < f(x), \quad (3.3)$$

$$h(x+d) \approx h(x) + \nabla h(x)^\top d = 0, \quad (3.4)$$

Odakle te dvije relacije. Obje su **linearizacije** (aproksimacija prvog reda, odjeljak 2.9) za mali pomak d :

- Prva: želimo da nova vrijednost cilja bude manja od stare.
- Druga: želimo ostati na krivulji ograničenja, dakle nova vrijednost h mora i dalje biti nula.

Pojednostavljenje [str. 21]. Takvi smjerovi d okarakterizirani su sljedećim svojstvima:

$$\nabla f(x)^\top d < 0 \quad \text{i} \quad \nabla h(x)^\top d = 0$$

Raspis prve: iz $f(x) + \nabla f(x)^\top d < f(x)$ oduzmemo $f(x)$ s obje strane $\Rightarrow \nabla f(x)^\top d < 0$.

Raspis druge: budući da je x već dopustiv, vrijedi $h(x) = 0$, pa iz $h(x) + \nabla h(x)^\top d = 0$ ostaje $\nabla h(x)^\top d = 0$.

Zaključak [str. 22]. U točki $x \in \mathcal{F}$ skup svih dozvoljenih smjerova sa smanjenjem funkcije cilja je skup $P(x)$, gdje je

$$P(x) = D(x) \cap S(x).$$


3.4.3 Geometrijska slika

[str. 23--26]

Slajdovi 23--26 grade jedan crtež u četiri koraka. Prikazana je kružnica $x_1^2 + x_2^2 = 2$ (dozvoljeni skup), preko nje kose paralelne nivo krivulje funkcije $f = x_1 + x_2$, i tri vrste strelica u točkama duž kružnice:

Boja	Značenje (doslovno sa slajdova)
zelene	$-\nabla f(x)$ [str. 23]
crvene	$\nabla h(x)$; <i>normale (okomice) na krivulju ograničenja dane su s</i> $\nabla h(x)$ [str. 24]. Smjer normale na krivulju ograničenja jednakosti može se uzeti proizvoljan jer je $h(x) = 0$ ekvivalentno $-h(x) = 0$ [str. 25]
plave	dozvoljeni smjerovi $d =$ okomice na normale $\nabla h(x)$, tj. $\nabla h(x)^\top d = 0$ [str. 26]

Kako čitati sliku. Zelene strelice pokazuju kamo bismo *htjeli* ići (smjer najbržeg pada cilja); one su svugdje jednake, jer je ∇f konstantan. Plave strelice pokazuju kamo *smijemo* ići (tangencijalno na kružnicu). U većini točaka zelena ima komponentu duž plave — tada se pomakom po kružnici cilj popravlja, pa ta točka nije optimum. Samo tamo gdje je zelena strelica **potpuno okomita** na plave (dakle kolinearna s crvenom) nema poboljšanja.



Slika 3.2: Rekonstrukcija crteža sa slajda 26. U optimumu $x^* = (-1, -1)$ zelena strelica $-\nabla f$ poklapa se sa smjerom crvene ∇h , pa nijedan plavi (dozvoljeni) smjer ne smanjuje cilj.

3.4.4 Uvjet kolinearnosti gradijenata

[str. 27--31]

Kandidati za minimizatore [str. 27]: za svaki d tako da je $\nabla h(x)^\top d = 0$, vrijedi $\nabla f(x)^\top d = 0$.

Zašto baš to: ako bi za neki dozvoljeni d bilo $\nabla f^\top d \neq 0$, onda bi ili d ili $-d$ (također dozvoljen, jer je i za njega $\nabla h^\top(-d) = 0$) dao $\nabla f^\top d < 0$, tj. pad cilja. Dakle nužno je $\nabla f^\top d = 0$ za sve dozvoljene d .

Ključni korak [str. 29]. Promotrimo slučaj kada je

$$\nabla f(x) = \lambda \nabla h(x)$$

za neku vrijednost $\lambda \in \mathbb{R}$ (dakle, kad su $\nabla f(x)$ i $\nabla h(x)$ **kolinearni**).

Napomena: kolinearni

Dva vektora su **kolinearna** (paralelna) ako je jedan skalarni višekratnik drugoga. Geometrijski leže na istom pravcu; mogu pokazivati u isti smjer ($\lambda > 0$) ili u suprotan ($\lambda < 0$).

Tada vrijedi [str. 30]:

$$(\nabla f(x)^\top - \lambda \nabla h(x)^\top) d = \nabla f(x)^\top d - \lambda \nabla h(x)^\top d = 0$$

što znači da za svaki d kad je $\nabla h(x)^\top d = 0$ tada vrijedi i da je $\nabla f(x)^\top d = 0$.

Raspis: lijeva zagrada je nula po pretpostavci kolinearnosti, pa je i cijeli umnožak nula. Drugi član $\lambda \nabla h(x)^\top d$ je također nula (jer je d dozvoljen). Iz $\nabla f^\top d - 0 = 0$ slijedi $\nabla f^\top d = 0$. ✓

Teorem 3.2: Nužan uvjet za optimum — jedno ograničenje jednakosti [str. 31]

Neka je x^* lokalni minimizator. Tada vrijedi

$$\nabla f(x^*) = \lambda \nabla h(x^*) \quad \text{za neki } \lambda \in \mathbb{R}.$$

Riječima: u optimumu gradijent funkcije cilja mora biti **paralelan** gradijentu ograničenja. To je algebarski zapis onoga što smo očitali sa slike: nivo krivulja cilja *dodiruje* (a ne siječe) krivulju ograničenja.

3.4.5 Provjera na primjeru

[str. 32]

Za naš primjer vrijedi:

$$\nabla f(x) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla h(x) = \begin{pmatrix} -2x_1 \\ -2x_2 \end{pmatrix}.$$

Raspis: $f = x_1 + x_2$ daje $\partial f / \partial x_1 = 1$, $\partial f / \partial x_2 = 1$. Za $h = 2 - x_1^2 - x_2^2$ (predznak sa slajda 19) je $\partial h / \partial x_1 = -2x_1$, $\partial h / \partial x_2 = -2x_2$. ✓

Za $x^* = (-1, -1)$ tada imamo

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \lambda^* \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \quad \text{što vrijedi za } \lambda^* = \frac{1}{2}.$$

Uvrštavanje: $\nabla h(-1, -1) = (-2 \cdot (-1), -2 \cdot (-1)) = (2, 2)$. Iz $1 = 2\lambda^*$ slijedi $\lambda^* = 1/2$. Ista vrijednost izlazi i iz druge komponente — što je dobar znak: da su komponente dale različite λ , vektori ne bi bili kolinearni. ✓

Napomena: ključno upozorenje sa slajda 32

Gornji uvjet je nužan ali ne i dovoljan! I za točku $x = (1, 1)$ imamo da je $\nabla f(x) = \lambda \nabla h(x)$, ali **to nije optimalna točka**.

Provjera: $\nabla h(1, 1) = (-2, -2)$, pa iz $(1, 1) = \lambda(-2, -2)$ slijedi $\lambda = -1/2$. Uvjet je zadovoljen. Ali $f(1, 1) = 2$, dok je $f(-1, -1) = -2$ — točka $(1, 1)$ je zapravo **maksimum** na kružnici.

Pouka: uvjet kolinearnosti hvata *sve* stacionarne točke na ograničenju — i minimume i maksimume. Nakon rješavanja uvijek treba usporediti vrijednosti f u svim kandidatima.

3.5 Lagrangeova funkcija

[str. 33--34]

Uvjet kolinearnosti je koristan, ali nezgodan za rješavanje. Sljedeći alat pakira sve nužne uvjete u jednu funkciju.

Problem [str. 33]:

$$\min f(x) \quad \text{uz ograničenje} \quad h(x) = 0 \quad (*)$$

Definicija 3.4: Lagrangeova funkcija

Lagrangeova funkcija za optimizacijski problem $(*)$ definirana je na sljedeći način:

$$L(x, \lambda) = f(x) + \lambda h(x)$$

Zašto je Lagrangeova funkcija korisna? [str. 34] Ako je x^* lokalni minimizator, tada vrijedi

$$\nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \lambda^* \nabla h(x^*) = 0 \quad \text{za neki } \lambda^* \quad (3.5)$$

$$\nabla_\lambda L(x^*, \lambda^*) = h(x^*) = 0 \quad (3.6)$$

Dakle, nužni uvjeti za optimalnost mogu se izvesti iz Lagrangeove funkcije.

Objašnjenje.

- $\nabla_x L$ znači „gradijent po varijablama x , uz λ fiksiran”. Analogno $\nabla_\lambda L$ je derivacija po λ , uz x fiksiran.
- Derivacija po λ vraća točno $h(x)$, jer je L linearna u λ : $\partial(\lambda h(x))/\partial\lambda = h(x)$. Time uvjet $\nabla_\lambda L = 0$ *automatski* ponovno nameće ograničenje.
- **Genijalnost trika:** problem s ograničenjem sveden je na traženje stacionarne točke jedne funkcije *bez* ograničenja — samo u prostoru veće dimenzije (x i λ).

Napomena: predznak λ : slajd 31 vs. slajd 34

Na slajdu 31 uvjet glasi $\nabla f = \lambda \nabla h$, a iz Lagrangeove funkcije na slajdu 34 dobiva se $\nabla f + \lambda \nabla h = 0$, tj. $\nabla f = -\lambda \nabla h$. **Radi se o istom uvjetu** — razlikuje se samo *predznak* multiplikatora ($\lambda_{\text{sl.34}} = -\lambda_{\text{sl.31}}$).

Za ograničenja *jednakosti* to je potpuno nevažno, jer λ smije biti bilo kojeg predznaka. Kod ograničenja *nejednakosti* predznak je bitan (vidi uvjet $\mu \geq 0$ u odjeljku 3.7), pa se ondje konzistentno koristi zapis s $+$, tj. $\nabla f + \mu \nabla g = 0$.

3.6 Više ograničenja jednakosti

[str. 35–40]

Problem [str. 35]:

$$\min f(x) \quad \text{uz ograničenja} \quad h_i(x) = 0, \quad i = 1 \dots m \quad (*)$$

3.6.1 Regularna točka

[str. 35]

Definicija 3.5: Regularna točka kod ograničenja jednakosti

Točka x^* koja ispunjava uvjete $h_i(x^*) = 0$, $i = 1, \dots, m$ je **regularna točka** ako su gradijenti $\nabla h_i(x^*)$ **linearno nezavisni**.

Objašnjenje sa slajda: dakle, ako je točka x^* regularna točka, tada nema paralelnih gradijenata $\nabla h_i(x^*)$, niti nema gradijenata koji se mogu izraziti kao **linearna kombinacija** ostalih gradijenata.

Napomena: linearna nezavisnost — od nule

Vektori $v_1, \dots, v_k$ su **linearno nezavisni** ako se nijedan od njih ne može napisati kao kombinacija ostalih; formalno, ako iz $c_1 v_1 + \dots + c_k v_k = 0$ nužno slijedi $c_1 = \dots = c_k = 0$. *Zašto nam to treba:* ako su gradijenti ograničenja zavisni, ograničenja se u toj točki „preklapaju” i geometrija degenerira — uvjeti optimalnosti tada mogu zakazati. Slajd 57 pokazuje upravo takav protuprimjer.

3.6.2 Lagrangeova funkcija i nužni uvjeti

[str. 36--37]

Definicija 3.6: Lagrangeova funkcija, više jednakosti [str. 36]

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i h_i(x)$$

$\lambda_1, \lambda_2, \dots, \lambda_m$ zovu se **Lagrangeovi množitelji**.

Uz uvjet da je x **regularna točka**, nužni uvjeti za optimalnost tada glase [str. 36]:

$$\frac{\partial L(x, \lambda)}{\partial x_i} = \frac{\partial f(x)}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial h_j(x)}{\partial x_i} = 0, \quad i = 1, \dots, n \quad (3.7)$$

$$\frac{\partial L(x, \lambda)}{\partial \lambda_i} = h_i(x) = 0, \quad i = 1, \dots, m \quad (3.8)$$

Kompaktniji zapis [str. 37]. Za problem (*), ako je x regularna točka, nužni uvjeti za optimalnost mogu se zapisati u sljedećem obliku:

$$h_i(x) = 0, \quad i = 1, \dots, m \quad (3.9)$$

$$\nabla f(x) + \sum_{i=1}^m \lambda_i \nabla h_i(x) = 0 \quad (3.10)$$

Geometrijska interpretacija [str. 37--38]: u točki optimuma x^* , vektor $\nabla f(x^*)$ je **linearna kombinacija** gradijenata funkcija ograničenja $\nabla h_i(x^*)$ u toj točki.

To je poopćenje uvjeta kolinearnosti: s jednim ograničenjem ∇f je morao biti *paralelan* s ∇h ; s više ograničenja mora ležati u *ravnini* (općenito potprostoru) koju razapinju gradijenti ograničenja.

3.6.3 Postupak traženja kandidata za optimum

[str. 39]

Teorem 3.3: Recept

Iz nužnih uvjeta optimalnosti

$$\frac{\partial L(x, \lambda)}{\partial x_i} = \frac{\partial f(x)}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial h_j(x)}{\partial x_i} = 0, \quad i = 1, \dots, n \quad (3.11)$$

$$\frac{\partial L(x, \lambda)}{\partial \lambda_i} = h_i(x) = 0, \quad i = 1, \dots, m \quad (3.12)$$

odredimo $m + n$ nepoznanica $x_1, \dots, x_n, \lambda_1, \dots, \lambda_m$.

Na ovaj način dobivamo točke kandidate za minimizatora. **(Ovo su samo nužni ali ne i dovoljni uvjeti!)**

Zašto se brojevi poklapaju: imamo n jednadžbi iz derivacija po x i m jednadžbi iz derivacija po λ — ukupno $n + m$ jednadžbi za $n + m$ nepoznanica. Sustav je time (općenito) određen.

3.6.4 Primjer: paralelepiped najvećeg volumena upisan u kuglu

[str. 40]

Zadatak (doslovno sa slajda). Odrediti paralelepiped maksimalnog volumena koji je sadržan u kugli polumjera r . Ishodište je u središtu kugle, a vrhovi paralelepipeda su na površini kugle.

Postavka geometrije (sa skice na slajdu). Paralelepiped je postavljen simetrično oko ishodišta, sa stranicama paralelnim osima. Ako je jedan njegov vrh u točki (x_1, x_2, x_3) (prvi oktant), onda su bridovi

$$a = 2x_1, \quad b = 2x_2, \quad c = 2x_3$$

Funkcija cilja:

$$V = F(x) = 8x_1x_2x_3$$

Odakle: volumen kvadra je $a \cdot b \cdot c = 2x_1 \cdot 2x_2 \cdot 2x_3 = 8x_1x_2x_3$. ✓

Nametnuta veza (ograničenje):

$$h(x) = x_1^2 + x_2^2 + x_3^2 - r^2 = 0$$

Odakle: vrh leži na sferi polumjera r , a udaljenost vrha od ishodišta je $\sqrt{x_1^2 + x_2^2 + x_3^2}$; izjednačena s r i kvadrirana daje gornji izraz.

Lagrangeova funkcija:

$$L(x, \lambda) = 8x_1x_2x_3 + \lambda(x_1^2 + x_2^2 + x_3^2 - r^2)$$

Slijedi (sa slajda):

$$\begin{aligned} \frac{\partial L}{\partial x_1} &= 8x_2x_3 + 2\lambda x_1 = 0 & / \cdot x_1 \\ \frac{\partial L}{\partial x_2} &= 8x_1x_3 + 2\lambda x_2 = 0 & / \cdot x_2 \quad (+) \\ \frac{\partial L}{\partial x_3} &= 8x_1x_2 + 2\lambda x_3 = 0 & / \cdot x_3 \end{aligned}$$

Provjera derivacija: u $8x_1x_2x_3$ derivacija po x_1 je $8x_2x_3$ (ostale varijable su konstante); u $\lambda(x_1^2 + \dots)$ derivacija po x_1 je $2\lambda x_1$. ✓

Trik sa slajda: svaka jednadžba se pomnoži naznačenom varijablom, pa se sve tri **zbroje** (oznaka (+)):

$$24x_1x_2x_3 + 2\lambda(x_1^2 + x_2^2 + x_3^2) = 0 \implies \lambda = -\frac{24x_1x_2x_3}{2r^2} = -\frac{3V}{2r^2}$$

Raspis zbrajanja:

$$x_1 \cdot (8x_2x_3 + 2\lambda x_1) = 8x_1x_2x_3 + 2\lambda x_1^2 = 0 \quad (3.13)$$

$$x_2 \cdot (8x_1x_3 + 2\lambda x_2) = 8x_1x_2x_3 + 2\lambda x_2^2 = 0 \quad (3.14)$$

$$x_3 \cdot (8x_1x_2 + 2\lambda x_3) = 8x_1x_2x_3 + 2\lambda x_3^2 = 0 \quad (3.15)$$

Zbroj: $3 \cdot 8x_1x_2x_3 + 2\lambda(x_1^2 + x_2^2 + x_3^2) = 0$, tj. $24x_1x_2x_3 + 2\lambda(x_1^2 + x_2^2 + x_3^2) = 0$. ✓

Zatim se iskoristi ograničenje $x_1^2 + x_2^2 + x_3^2 = r^2$:

$$24x_1x_2x_3 + 2\lambda r^2 = 0 \implies \lambda = -\frac{24x_1x_2x_3}{2r^2}$$

i uz $V = 8x_1x_2x_3$, brojnik je $3V$, pa je $\lambda = -\frac{3V}{2r^2}$. ✓

Uvrštenjem λ u $\partial L/\partial x_1$ slijedi:

$$8x_2x_3 \left(1 - \frac{3x_1^2}{r^2}\right) = 0 \implies x_1 = \pm \frac{r}{\sqrt{3}} = \frac{r}{\sqrt{3}}, \quad \text{i analogno: } x_2 = x_3 = \frac{r}{\sqrt{3}}$$

Raspis uvrštavanja:

$$8x_2x_3 + 2\lambda x_1 = 8x_2x_3 + 2\left(-\frac{24x_1x_2x_3}{2r^2}\right)x_1 \quad (3.16)$$

$$= 8x_2x_3 - \frac{24x_1^2x_2x_3}{r^2} \quad (3.17)$$

$$= 8x_2x_3 \left(1 - \frac{3x_1^2}{r^2}\right) \quad (3.18)$$

Umnožak je nula ako je $x_2x_3 = 0$ (odbačeno — tada je volumen nula) ili ako je zagrada nula:

$$1 = \frac{3x_1^2}{r^2} \implies x_1^2 = \frac{r^2}{3} \implies x_1 = \pm \frac{r}{\sqrt{3}}$$

Uzimamo pozitivni korijen jer je vrh u prvom oktantu. ✓

Volumen:

$$V_{\max} = \left(\frac{2r}{\sqrt{3}}\right)^3$$

Provjera: brid je $a = 2x_1 = 2r/\sqrt{3}$; ista vrijednost za b i c , pa je $V = a^3 = (2r/\sqrt{3})^3 = \frac{8r^3}{3\sqrt{3}}$. ✓

Zaključak: optimalan paralelepiped je **kocka**. To je tipičan ishod simetričnih problema — i lijep primjer kako Lagrangeova metoda riješi u tri retka ono što bi eliminacijom varijabli bilo mnogo dulje.

Napomena: maksimizacija Lagrangeovom metodom

Ovaj je zadatak *maksimizacija*, a nužni uvjeti su izvedeni za minimizaciju. To je u redu: uvjet $\nabla L = 0$ hvata *sve* stacionarne točke — i minimume i maksimume (usporedi napomenu uz slajd 32). Da je trebalo formalno slijediti standardnu formu, minimizirali bismo $-V$ (trik iz odjeljka 1.12); rješenje x^* bilo bi isto, a λ bi promijenio predznak.

3.7 Problem s jednim ograničenjem nejednakosti

[str. 41--51]

3.7.1 Postavka

[str. 41]

$$\begin{aligned} \min \quad & f(x) := x_1 + x_2 \\ \text{uz ograničenja} \quad & g(x) := x_1^2 + x_2^2 - 2 \leq 0 \end{aligned} \quad (3.19)$$

Grafičkom metodom: rješenje (minimizator) je $x^* = (-1, -1)$.

Uočite: isti cilj i isti rub kao u odjeljku 3.4, ali dozvoljeni skup je sada cijeli **disk** umjesto same kružnice. Rješenje je ispalo isto — ali sada moramo objasniti *zašto* optimum leži baš na rubu.

3.7.2 Izvod: dva slučaja

[str. 42--45]

Dozvoljeni skup: $\mathcal{F} = \{x \mid g(x) := x_1^2 + x_2^2 - 2 \leq 0\}$.

U točki $x \in \mathcal{F}$, ako je d dozvoljeni smjer sa smanjenjem funkcije cilja, treba vrijediti [str. 42]:

$$f(x+d) \approx f(x) + \nabla f(x)^\top d < f(x), \quad (3.20)$$

$$g(x+d) \approx g(x) + \nabla g(x)^\top d \leq 0. \quad (3.21)$$

Razlika u odnosu na jednakost: druga relacija sada ima ≤ 0 umjesto $= 0$, i $g(x)$ **ne** mora biti nula, pa se ne može jednostavno pokratiti. Zato uvodimo novi pojam:

Definicija 3.7: Aktivno i neaktivno ograničenje [str. 43]

Neka je $x \in \mathbb{R}^n$. Kažemo da je ograničenje $g(x) \leq 0$ **aktivno** u x ako vrijedi $g(x) = 0$. Ako pak vrijedi $g(x) < 0$, kažemo da je ograničenje $g(x) \leq 0$ **neaktivno** u x .

Slikovito: aktivno ograničenje znači „stojimo točno na ogradi”, a neaktivno „ograda je negdje daleko, trenutno nas ne dodiruje”.

Slajd 44--45 razlikuje dva slučaja:

1) Neaktivno ograničenje: $g(x) < 0$. d je dozvoljen smjer sa smanjenjem funkcije cilja u x ako vrijedi

$$g(x) + \nabla g(x)^\top d \leq 0, \quad \nabla f(x)^\top d < 0$$

što je, u slučaju kad je $\|d\|$ uzet dovoljno malen¹, ekvivalentno uvjetu

$$\nabla f(x)^\top d < 0.$$

2) Aktivno ograničenje: $g(x) = 0$. d je dozvoljen smjer sa smanjenjem funkcije cilja u x ako vrijedi

$$\nabla g(x)^\top d \leq 0, \quad \nabla f(x)^\top d < 0$$

Zašto je u slučaju 2 nestao $g(x)$: jer je $g(x) = 0$, pa uvjet $g(x) + \nabla g(x)^\top d \leq 0$ postaje $\nabla g(x)^\top d \leq 0$.

3.7.3 Nužni uvjeti za oba slučaja

[str. 46–48]

Osnovna ideja [str. 46]: kandidati za optimum su one točke x^* za koje je skup dozvoljenih smjerova sa smanjenjem funkcije cilja **prazan skup**.

1) Neaktivno ograničenje u x^* : $g(x^*) < 0$. Nužan uvjet za optimum je

$$\nabla f(x^*) = 0$$

jer je jedino tada skup $\{d \mid \nabla f(x)^\top d < 0\}$ nužno prazan.

Zašto: ako je $\nabla f \neq 0$, uvijek možemo uzeti $d = -\nabla f$ i dobiti $\nabla f^\top d = -\|\nabla f\|^2 < 0$ — dakle smjer pada postoji. Prazan skup dobivamo samo kad je gradijent nula. Ovo je zapravo poznati uvjet za probleme *bez* ograničenja — logično, jer nas ograničenje ovdje ni ne dodiruje.

2) Aktivno ograničenje u x^* : $g(x^*) = 0$ [str. 47]. Nužan uvjet za optimum glasi: za sve d za koje vrijedi $\nabla g(x)^\top d \leq 0$, mora nužno vrijediti i da je $\nabla f(x)^\top d \geq 0$. U tom slučaju je naime skup dozvoljenih smjerova sa smanjenjem funkcije cilja prazan skup.

Napomena: tipfeler na slajdu 47/48

Na slajdovima piše „ $\nabla f(x)^\top \geq 0$ ”; nedostaje d . Iz konteksta i iz izvoda na slajdu 48 jasno je da se misli na $\nabla f(x)^\top d \geq 0$.

Ključni korak [str. 48]. Promotrimo slučaj kad je

$$\nabla f(x^*) + \mu^* \nabla g(x^*) = 0 \quad \text{za neki } \mu^* \geq 0 \quad (**)$$

Tada vrijedi

$$(\nabla f(x^*)^\top + \mu^* \nabla g(x^*)^\top) d = 0 \quad \text{odnosno} \quad \nabla f(x^*)^\top d = -\mu^* \nabla g(x^*)^\top d$$

Dakle, za sve d za koje je $\nabla g(x^*)^\top d \leq 0$, u tom slučaju nužno vrijedi da je $\nabla f(x^*)^\top d \geq 0$.

Raspis zadnjeg zaključka — pazite na dva predznaka:

- $\nabla g(x^*)^\top d \leq 0$ (pretpostavka: d je dozvoljen),
- $\mu^* \geq 0$ (pretpostavka),
- dakle $\mu^* \nabla g(x^*)^\top d \leq 0$ (nenegativan puta nepozitivan),
- dakle $-\mu^* \nabla g(x^*)^\top d \geq 0$ (množenje s -1 okreće),

¹Fusnota sa slajda: za bilo koji smjer, uvjet $g(x) + \nabla g(x)^\top d \leq 0$ može se uvijek zadovoljiti ako je duljina vektora d dovoljno malena, jer je $g(x) < 0$.

- a to je upravo $\nabla f(x^*)^\top d$. ✓

Zaključak sa slajda: uvjet (**) je nužan uvjet da bi skup dozvoljenih smjerova sa smanjenjem funkcije cilja bio prazan skup.

Napomena: zašto baš $\mu \geq 0$, a λ smije biti bilo koji

Kod *jednakosti* dozvoljeni smjerovi zadovoljavaju $\nabla h^\top d = 0$ — simetrično, pa je predznak λ nevažan.

Kod *nejednakosti* dozvoljeni smjerovi zadovoljavaju $\nabla g^\top d \leq 0$ — *nesimetrično*. Gornji izvod prolazi samo ako je $\mu^* \geq 0$; s negativnim μ^* zaključak bi se okrenuo. Geometrijski: $-\nabla f$ mora pokazivati *van* iz dozvoljenog skupa, u istom smjeru kao ∇g .

3.7.4 Teorem: uvjeti za jedno ograničenje nejednakosti

[str. 49--50]

Teorem 3.4: Nužni uvjeti, jedno ograničenje nejednakosti

Za problem $\min f(x)$ uz ograničenje $g(x) \leq 0$: ako je x^* lokalni minimizator, tada postoji μ^* tako da su sljedeći uvjeti zadovoljeni:

$$\nabla f(x^*) + \mu^* \nabla g(x^*) = 0 \quad (\text{A1}) \quad (3.22)$$

$$\mu^* g(x^*) = 0 \quad (\text{A2}) \quad (3.23)$$

$$\mu^* \geq 0 \quad (\text{A3}) \quad (3.24)$$

Kako teorem pokriva oba slučaja [str. 50]. Uočimo da je:

- za $g(x^*) < 0$ (neaktivno), zbog (A2) imamo da je $\mu^* = 0$, pa (A1) postaje $\nabla f(x^*) = 0$;
- za $g(x^*) = 0$ (aktivno), slijedi da je $\mu^* \geq 0$ i $\nabla f(x^*) + \mu^* \nabla g(x^*) = 0$;

pa gornji teorem uključuje i slučaj aktivnog i slučaj neaktivnog ograničenja.

Definicija 3.8: Uvjet komplementarnosti [str. 50]

Uvjet (A2), $\mu^* g(x^*) = 0$, zove se **uvjet komplementarnosti** (engl. *complementary slackness*).

Kako čitati uvjet komplementarnosti. Umnožak dvaju brojeva je nula samo ako je barem jedan od njih nula. Dakle u optimumu za svako ograničenje vrijedi **barem jedno** od:

- $\mu^* = 0$ — ograničenje je „bez cijene”, ne utječe na rješenje;
- $g(x^*) = 0$ — ograničenje je aktivno, „stojimo na ogradi”.

Ne mogu istovremeno biti $\mu^* > 0$ i $g(x^*) < 0$. Ovo je *najkorisniji* uvjet u praksi: on nam govori koje kombinacije aktivnih ograničenja uopće trebamo isprobavati.

3.7.5 Zapis preko Lagrangeove funkcije

[str. 51]

Definicija 3.9: Lagrangeova funkcija za nejednakost

Za problem $\min f(x)$ uz $g(x) \leq 0$:

$$L(x, \mu) = f(x) + \mu g(x)$$

Ako je x^* lokalni minimizator, tada vrijedi:

$$\nabla_x L(x^*, \mu^*) = \nabla f(x^*) + \mu^* \nabla g(x^*) = 0 \quad (3.25)$$

$$g(x^*) \leq 0 \quad (3.26)$$

$$\mu^* g(x^*) = 0 \quad (3.27)$$

$$\mu^* \geq 0 \quad (3.28)$$

3.7.6 Rješavanje primjera sa slajda 41

Slajd 41 daje rješenje grafički; ovdje ga izvodimo iz gornjih uvjeta, jer je to postupak koji ćete koristiti na ispitu.

Zadano: $f(x) = x_1 + x_2$, $g(x) = x_1^2 + x_2^2 - 2 \leq 0$.

Gradijenti:

$$\nabla f(x) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla g(x) = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix}$$

Slučaj A — ograničenje neaktivno ($\mu^* = 0$). Tada (A1) traži $\nabla f(x^*) = 0$, tj. $(1, 1) = (0, 0)$ — **nemoguće**. Dakle ograničenje mora biti aktivno.

Poanta: to je algebarska potvrda geometrijske činjenice da linearna funkcija nema unutarnji minimum — uvijek se „gura” do ruba.

Slučaj B — ograničenje aktivno ($g(x^*) = 0$). Sustav:

$$1 + 2\mu^* x_1^* = 0 \quad (3.29)$$

$$1 + 2\mu^* x_2^* = 0 \quad (3.30)$$

$$(x_1^*)^2 + (x_2^*)^2 - 2 = 0 \quad (3.31)$$

Korak 1. Iz (3.29) i (3.30) (uz $\mu^* \neq 0$, što slijedi jer $\mu^* = 0$ vodi na $1 = 0$):

$$x_1^* = -\frac{1}{2\mu^*}, \quad x_2^* = -\frac{1}{2\mu^*}$$

dakle $x_1^* = x_2^*$.

Korak 2. Uvrstimo u (3.31):

$$2(x_1^*)^2 = 2 \implies (x_1^*)^2 = 1 \implies x_1^* = \pm 1$$

Korak 3 — izbor predznaka pomoću (A3). Iz $x_1^* = -1/(2\mu^*)$ i uvjeta $\mu^* \geq 0$ slijedi da x_1^* mora biti **negativan**. Dakle $x_1^* = x_2^* = -1$.

Korak 4 — vrijednost multiplikatora. Iz (3.29):

$$1 + 2\mu^*(-1) = 0 \implies 2\mu^* = 1 \implies \mu^* = \frac{1}{2} \geq 0 \quad \checkmark$$

Rezultat:

$$x^* = (-1, -1), \quad \mu^* = \frac{1}{2}, \quad f(x^*) = -2$$

što se poklapa s grafičkim rješenjem sa slajda 41. $\checkmark$

Napomena: usporedba s jednakošću

U odjeljku 3.4 isti je problem s *jednakošću* dao dvije stacionarne točke: $(-1, -1)$ (minimum) i $(1, 1)$ (maksimum). Ovdje je uvjet $\mu \geq 0$ **sam odbacio** točku $(1, 1)$. To je praktična prednost nejednakosti: predznak multiplikatora nosi informaciju o smjeru, pa maksimumi otpadaju automatski.

Kako to nacrtati rukom: KKT točka na disku

Korak 1. Nacrtajte osi x_1, x_2 od $-2,4$ do $2,4$, jednako mjerilo.

Korak 2 — dozvoljeni skup. Nacrtajte kružnicu polumjera $\sqrt{2} \approx 1,41$ oko ishodišta. Testna točka $(0, 0)$ daje $g = -2 \leq 0$ ✓, dakle dopuštena je **unutrašnjost**; osjenčajte je.

Korak 3 — nivo krivulje cilja. $f = x_1 + x_2 = c$ su paralelni pravci nagiba -1 . Nacrtajte ih za $c = -3, -2, -1, 0, 1, 2$. Označite ih; uočite da f pada kako se pomičemo prema *dolje-lijevo*.


Korak 4 — optimum. „Gurajte” pravac prema dolje-lijevo dok još dodiruje disk. Zadnji dodir je u točki $(-1, -1)$; tu nacrtajte punu točku. Provjera: $-1 - 1 = -2$, dakle taj pravac je $c = -2$.

Korak 5 — gradijent cilja. Iz $(-1, -1)$ nacrtajte $\nabla f = (1, 1)$: jedna jedinica desno, jedna gore — dakle prema *unutrašnjosti* diska. To je smjer rasta cilja.

Korak 6 — gradijent ograničenja. Iz iste točke nacrtajte $\nabla g = (2x_1, 2x_2) = (-2, -2)$: dvije jedinice lijevo, dvije dolje — dakle prema *van* iz diska, okomito na kružnicu.

Korak 7 — provjera KKT-a okom. Dvije strelice su **antiparalelne** (leže na istom pravcu, suprotnih smjerova). Baš to izražava (A1): $\nabla f = -\mu \nabla g$ uz $\mu = 1/2 > 0$. Duljina ∇f je upravo pola duljine ∇g — odatle $\mu = 1/2$.

Što graf znači. U KKT točki nivo krivulja cilja **tangira** rub dozvoljenog skupa, a gradijenti su antiparalelni. Da nisu, mogli bismo kliznuti po rubu i smanjiti cilj. Uvjet $\mu \geq 0$ znači da ∇f pokazuje *unutra*: cilj bi rastao kad bismo se vratili u unutrašnjost, pa je isplativo ostati priljubljen uz ogradu.



Slika 3.3: KKT točka za $\min x_1 + x_2$ uz $x_1^2 + x_2^2 \leq 2$. U $x^* = (-1, -1)$ gradijenti ∇f (zeleno) i ∇g (crveno) su antiparalelni, uz $\mu^* = \frac{1}{2} \geq 0$.

3.8 Više ograničenja nejednakosti

[str. 52--57]

Problem [str. 52]:

$$\min f(x) \quad \text{uz ograničenja} \quad g_i(x) \leq 0, \quad i = 1, \dots, p \quad (*)$$

Definicija 3.10: Lagrangeova funkcija [str. 52]

$$L(x, \mu) = f(x) + \sum_{i=1}^p \mu_i g_i(x)$$

Varijable $\mu = (\mu_1, \dots, \mu_p)$ zovu se **Lagrangeovi množitelji**.

Definicija 3.11: Regularna točka kod ograničenja nejednakosti [str. 53]

Neka je skup I skup indeksa svih ograničenja koja su **aktivna** u točki x^* , tj. neka je $I := \{i \mid g_i(x^*) = 0\}$. Tada je x^* **regularna točka** ako su gradijenti $\nabla g_i(x^*)$ linearno nezavisni za sve $i \in I$.

Objašnjenje sa slajda: dakle, ako je točka x^* regularna točka, tada među svim *aktivnim* ograničenjima nema paralelnih gradijenata $\nabla g_i(x^*)$, niti nema gradijenata koji se mogu izraziti kao linearna kombinacija gradijenata ostalih aktivnih ograničenja.

Napomena: samo aktivna ograničenja

Uočite da se u definiciju regularnosti **uključuju samo aktivna** ograničenja. Neaktivna ne igraju nikakvu ulogu — ona ionako imaju $\mu_i = 0$ i lokalno ne dodiruju rješenje.

Teorem 3.5: Nužni uvjeti, više nejednakosti [str. 54]

Neka je x^* regularna točka. Ako je $x^* \in \mathbb{R}^n$ lokalni minimizator, tada postoji $\mu^* = (\mu_1^*, \dots, \mu_p^*)$ tako da su sljedeći uvjeti zadovoljeni:

$$\frac{\partial L}{\partial x_i}(x^*, \mu^*) = \frac{\partial f}{\partial x_i}(x^*) + \sum_{j=1}^p \mu_j^* \frac{\partial g_j}{\partial x_i}(x^*) = 0, \quad i = 1, \dots, n \quad (3.32)$$

$$g_j(x^*) \leq 0, \quad j = 1, \dots, p \quad (3.33)$$

$$\mu_j^* g_j(x^*) = 0, \quad j = 1, \dots, p \quad (3.34)$$

$$\mu_j^* \geq 0, \quad j = 1, \dots, p \quad (3.35)$$

Kompaktniji zapis [str. 55]. Isti teorem, prva jednadžba zapisana vektorski:

$$\nabla f(x^*) + \sum_{j=1}^p \mu_j^* \nabla g_j(x^*) = 0 \quad (3.36)$$

$$g_j(x^*) \leq 0, \quad j = 1, \dots, p \quad (3.37)$$

$$\mu_j^* g_j(x^*) = 0, \quad j = 1, \dots, p \quad (3.38)$$

$$\mu_j^* \geq 0, \quad j = 1, \dots, p \quad (3.39)$$

3.8.1 Geometrijska interpretacija

[str. 56]

Slajd 56 prikazuje crtež u ravni (x_1, x_2) :

- dvije podebljane krivulje označene g_1 i g_2 — granice dvaju ograničenja; ružičasto osjenčano područje između njih je dozvoljeni skup S ;
- točka x^* u kojoj se te dvije granice sijeku — dakle *oba* ograničenja su ondje aktivna;
- iz x^* izlaze tri strelice: $\mu_1 \nabla g_1$ (prema gore), $\mu_2 \nabla g_2$ (prema gore-lijevo) i ∇F (prema dolje-desno);
- isprekidana krivulja $F(x^*)$ — nivo krivulja funkcije cilja kroz x^* , koja u toj točki dodiruje kut dozvoljenog skupa;
- zatvorena krivulja gore lijevo sa šrafiranom točkom u sredini — neograničeni minimum cilja, koji leži izvan dozvoljenog skupa.

Poruka slike: ∇F je uravnotežen zbrojem $\mu_1 \nabla g_1 + \mu_2 \nabla g_2$, uz $\mu_1, \mu_2 \geq 0$. Vektor $-\nabla F$ leži *unutar* stošca razapetog gradijentima aktivnih ograničenja. To je geometrijski sadržaj prvog KKT uvjeta kad je aktivno više ograničenja.

3.8.2 Važna iznimka: neregularna točka

[str. 57]

Tvrdnja sa slajda: *Uvjeti optimalnosti ne moraju biti zadovoljeni u neregularnoj točki.*

Slajd prikazuje sličan crtež, ali sada su u točki x^* gradijenti ∇g_1 i ∇g_2 **gotovo suprotni** (kolinearni), tj. linearno zavisni — dozvoljeni skup S ima ondje „šiljak”. Vektor ∇F pokazuje u smjeru koji se *ne* može prikazati kao nenegativna kombinacija ∇g_1 i ∇g_2 .

Zaključak: x^* jest optimum, ali KKT uvjeti u njemu **nemaju rješenje**. Zato u svim teoremima stoji pretpostavka regularnosti.

Napomena: praktična važnost

Pretpostavka regularnosti (u literaturi: *constraint qualification*) u praksi je gotovo uvijek ispunjena, pa se rijetko provjerava. Ali ako KKT sustav nema rješenje, a znate da optimum postoji — provjerite je li kandidatna točka možda neregularna.

3.9 KKT uvjeti: općenit slučaj

[str. 58–61]

Sada spajamo sve: i jednakosti i nejednakosti.

Optimizacijski problem [str. 58]:

$$\begin{aligned} &\text{minimiziraj} && f(x) \\ &\text{uz ograničenja} && h_i(x) = 0, \quad i = 1, \dots, m \\ & && g_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{3.40}$$

Definicija 3.12: Regularna točka — opći slučaj [str. 58]

Neka je x^* točka koja zadovoljava sva ograničenja i neka je skup J skup indeksa svih ograničenja nejednakosti koja su aktivna u x^* , tj. neka je $J := \{j \mid g_j(x^*) = 0\}$. Tada je x^* **regularna točka** ako su gradijenti $\nabla h_i(x^*)$, $i = 1, \dots, m$, i $\nabla g_j(x^*)$, $j \in J$, **linearno nezavisni**.

Dakle (sa slajda), ako je točka x^* regularna točka, tada među svim ograničenjima jednakosti i *aktivnim* ograničenjima nejednakosti nema paralelnih gradijenata niti gradijenata koji se mogu izraziti kao linearna kombinacija ostalih gradijenata iz tog skupa.

Teorem 3.6: Karush-Kuhn-Tucker uvjeti [str. 59]

Neka je x^* regularna točka. Ako je $x^* \in \mathbb{R}^n$ lokalni minimizator, tada postoje Lagrangeovi množitelji $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$ i $\mu^* = (\mu_1^*, \dots, \mu_p^*)$ tako da su sljedeći uvjeti zadovoljeni:

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(x^*) + \sum_{j=1}^p \mu_j^* \nabla g_j(x^*) = 0 \quad (\text{stacionarnost}) \tag{3.41}$$

$$h_i(x^*) = 0, \quad i = 1, \dots, m \tag{3.42}$$

$$g_j(x^*) \leq 0, \quad j = 1, \dots, p \tag{3.43}$$

$$\mu_j^* g_j(x^*) = 0, \quad j = 1, \dots, p \tag{3.44}$$

$$\mu_j^* \geq 0, \quad j = 1, \dots, p \tag{3.45}$$

Gornji uvjeti zovu se **Karush-Kuhn-Tucker nužni uvjeti optimalnosti** ili skraćeno **KKT uvjeti**.

Imena pojedinih skupina uvjeta (standardna terminologija, korisna za snalaženje u literaturi):

Uvjet	Naziv
$\nabla f + \sum \lambda_i \nabla h_i + \sum \mu_j \nabla g_j = 0$	stacionarnost ($\nabla_x L = 0$)
$h_i(x^*) = 0, g_j(x^*) \leq 0$	primarna dopustivost
$\mu_j^* \geq 0$	dualna dopustivost
$\mu_j^* g_j(x^*) = 0$	komplementarnost

Definicija 3.13: Lagrangeova funkcija — opći slučaj [str. 60]

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i h_i(x) + \sum_{i=1}^p \mu_i g_i(x)$$

Varijable $\lambda = (\lambda_1, \dots, \lambda_m)$ i $\mu = (\mu_1, \dots, \mu_p)$ zovu se **Lagrangeovi množitelji**.

Napomena: tipfeler na slajdu 60

Na slajdu piše $\lambda = (\lambda_1, \dots, \lambda_p)$; treba biti $(\lambda_1, \dots, \lambda_m)$, jer λ pripada ograničenjima jednakosti kojih ima m (usporedi slajd 59).

KKT uvjeti izraženi preko L [str. 61]. Slajd 61 ponavlja teorem, ali svaki uvjet pridružuje odgovarajućoj derivaciji Lagrangeove funkcije:

$$\nabla_x L(x^*, \lambda^*, \mu^*) = 0 \implies \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(x^*) + \sum_{j=1}^p \mu_j^* \nabla g_j(x^*) = 0 \quad (3.46)$$

$$\nabla_\lambda L(x^*, \lambda^*, \mu^*) = 0 \implies h_i(x^*) = 0, \quad i = 1, \dots, m \quad (3.47)$$

$$\nabla_\mu L(x^*, \lambda^*, \mu^*) \leq 0 \implies g_j(x^*) \leq 0, \quad j = 1, \dots, p \quad (3.48)$$

$$\mu_j^* g_j(x^*) = 0, \quad j = 1, \dots, p \quad (3.49)$$

$$\mu_j^* \geq 0, \quad j = 1, \dots, p \quad (3.50)$$

Praktični recept za rješavanje KKT sustava (postupak koji slijedi iz gornjih uvjeta i koji ćemo koristiti u poglavlju 4):

1. Napiši $L(x, \lambda, \mu)$.
2. Izračunaj $\nabla_x L = 0$ — to je n jednadžbi.
3. Dodaj sve jednakosti $h_i(x) = 0$ — m jednadžbi.
4. **Pretpostavi koja su nejednakosna ograničenja aktivna.** Za svako pretpostavljeno neaktivno stavi $\mu_j = 0$; za svako aktivno stavi $g_j(x) = 0$. (Ovo je „pogađanje aktivnog skupa”; kod p ograničenja ima najviše 2^p kombinacija, ali većina se odmah odbaci.)
5. Riješi dobiveni sustav jednadžbi.
6. **Provjeri** preostale uvjete: jesu li svi $\mu_j \geq 0$ i jesu li sva pretpostavljena neaktivna ograničenja doista zadovoljena ($g_j(x) < 0$)? Ako ne — pretpostavka o aktivnom skupu je bila pogrešna, vrati se na korak 4.
7. Usporedi f u svim preživjelim kandidatima.

Napomena: kada su KKT uvjeti i dovoljni

Za **konveksan** problem (odjeljak 2.19) KKT uvjeti nisu samo nužni nego i **dovoljni**: svaka točka koja ih zadovoljava je globalni optimum. To ćemo formalno vidjeti u poglavlju 4 [str. 4:19–23]. Zato se u praksi problemi trude formulirati konveksno — tada rješavanje KKT sustava daje *konačan* odgovor, bez dodatne provjere.

3.10 Fizikalna interpretacija Lagrangeovih množitelja

[str. 62–63]

Postavka [str. 62]. Čestica se giba po glatkoj površini zadanoj jednadžbom $h(x, y, z) = 0$, pod djelovanjem konzervativnog polja sila zadanog funkcijom $\Phi(x, y, z)$.

Sila potencijalnog polja:

$$F = \begin{pmatrix} F_x \\ F_y \\ F_z \end{pmatrix} = \begin{pmatrix} \frac{\partial \Phi}{\partial x} \\ \frac{\partial \Phi}{\partial y} \\ \frac{\partial \Phi}{\partial z} \end{pmatrix} = \nabla \Phi$$

Reakcija veze je u smjeru **normale** na površinu i proporcionalna je gradijentu veze:

$$F_n = \begin{pmatrix} N_x \\ N_y \\ N_z \end{pmatrix} = \lambda \nabla h$$

Jednadžba gibanja [str. 63]. Jednadžba gibanja čestice je

$$m a = F + F_n$$

gdje je m masa i $a = \begin{pmatrix} \ddot{x} & \ddot{y} & \ddot{z} \end{pmatrix}^\top$ akceleracija čestice, odnosno

$$m a = \nabla \Phi + \lambda \nabla h, \quad \text{uz ograničenje } g(x, y, z) = 0.$$

Za stacionarnu točku je $a = 0$, odnosno

$$\nabla \Phi + \lambda \nabla h = 0,$$

što predstavlja uvjet ravnoteže sila. Faktor proporcionalnosti λ je Lagrangeov množitelj za sljedeći optimizacijski problem:

$$\min \Phi(x, y, z) \quad \text{uz ogr. } h(x, y, z) = 0$$

Napomena: što ovo znači — i zašto je važno

Lagrangeov množitelj **nije puka matematička pomoćna varijabla**: on ima fizikalno značenje **sile reakcije veze**.

- Ograničenje $h(x) = 0$ je „podloga” koja tijelo drži.
- λ mjeri **koliko jako** ta podloga mora gurati da tijelo ostane na njoj.
- Ako je λ velik, ograničenje „radi teško” — njegovo popuštanje donijelo bi veliku korist.

Ta se ideja u poglavlju 4 formalizira kao **analiza osjetljivosti**: λ je derivacija optimalne vrijednosti po pomaku ograničenja. U ekonomiji se isti broj zove *sjenska cijena*.

Napomena o oznakama sa slajda 63: u zadnjem retku piše ograničenje $g(x, y, z) = 0$ iako se u ostatku izvoda koristi h ; radi se o istoj vezi.

3.11 Ravnotežni položaj preko minimizacije potencijalne energije

[str. 64--68]

Slajdovi 64--68 daju niz primjera oznake „Primjer”. **Svi su prikazani isključivo kao slike (skice i grafovi), bez ispisanih formula** — računi su očito rađeni na ploči. Zato ih ovdje opisujem točno onako kako izgledaju, uz naznaku kojim se aparatom iz ovog poglavlja rješavaju; formule ne izmišljam.

3.11.1 Primjer 1: uteg na opruzi [str. 64]

Skica prikazuje: vodoravnu šrafiranu stropnu plohu s objesištem; koordinatni sustav (x, y) s ishodištem u objesištu; oprugu koja visi prema dolje i na njezinu kraju kuglicu označenu m = masa utega. Sa strane je strelica prema dolje označena g , gravitacija. Kotirana je duljina L_0 = duljina neopterećene opruge.

Tip problema: minimizacija potencijalne energije **bez** ograničenja — uteg se slobodno spušta dok se sile ne izjednače. To je isti tip problema kao u odjeljku 1.6.5, samo s jednom oprugom.

3.11.2 Primjer 2: klizač na vertikalnoj vodilici [str. 65]

Skica dodaje **vertikalnu vodilicu** (šrafirani stup) na udaljenosti x_0 lijevo od objesišta. Masa se sada zove m = masa klizača i može se gibati *samo* po toj vodilici; kotirana je i visina $y_{\max}$. Opruga je razvučena ukoso, od objesišta do klizača.

Tip problema: minimizacija potencijalne energije **uz ograničenje jednakosti** $x = -x_0$ (klizač mora ostati na vodilici) — dakle točno Lagrangeova metoda iz odjeljka 3.5. Lagrangeov množitelj je vodoravna sila kojom vodilica djeluje na klizač (fizikalna interpretacija iz prethodnog odjeljka).

3.11.3 Primjeri 3 i 4: nivo krivulje energije s gradijentima [str. 66--67]

Slajdovi 66 i 67 pokraj iste skice prikazuju **konturni graf potencijalne energije** $V(x, y)$ u ravnini, s nivo krivuljama označenim brojevima $(-13, -14, -10, -8, -5, -3, -2, -1, 0, 3, 5 \dots)$ i nekoliko obojenih strelica iz jedne točke:

- **slajd 66:** plava okomita crta (vodilica, tj. ograničenje), crvena vodoravna crta, te iz označene crvene točke vodoravne strelice u oba smjera — zelena udesno i plava ulijevo;
- **slajd 67:** iz iste točke dodane su još dvije strelice — plava ukoso prema gore-lijevo i crvena prema dolje.

Kako to čitati u jeziku ovog poglavlja. Okomita plava crta je krivulja ograničenja (vodilica). Strelice su gradijenti: gradijent energije i gradijent ograničenja. Ravnotežni položaj je

ondje gdje se te dvije strelice poravnaju, tj. gdje je $\nabla V = -\lambda \nabla h$ — upravo uvjet sa slajda 31. Konturni graf pokazuje da nivo krivulja energije u toj točki **tangira** vodilicu.

3.11.4 Primjer 5: uteg na opruzi iznad kose podloge [str. 68]

Zadnja skica prikazuje uteg obješen o oprugu (kao u Primjeru 1), ali ispod njega je **kosa šrafirana ploha** zadana pravcem $y = ax + b$. Uteg ima vodoravnu podlogu s označenim točkama A i B , a L_0 je opet duljina neopterećene opruge.

Tip problema: minimizacija potencijalne energije **uz ograničenje nejednakosti** — uteg ne smije propasti kroz podlogu, dakle $y \geq ax + b$, odnosno u standardnoj formi $ax + b - y \leq 0$. Ovo je točno situacija iz odjeljka 3.7, s dva moguća ishoda:

- **ograničenje neaktivno** ($\mu = 0$): opruga je dovoljno kratka, uteg visi u zraku iznad podloge i ravnoteža je ista kao u Primjeru 1;
- **ograničenje aktivno** ($\mu > 0$): uteg leži na podlozi, a μ je **normalna reakcija podloge**.

Uvjet komplementarnosti $\mu g(x) = 0$ ovdje ima izravno fizikalno značenje: *podloga gura samo ako je tijelo dodiruje*. Ako tijelo lebdi, reakcija je nula; ako je reakcija pozitivna, tijelo nužno leži na podlozi.

3.12 Sažetak poglavlja

Glavni rezultat — KKT uvjeti. Za problem $\min f(x)$ uz $h_i(x) = 0$, $g_j(x) \leq 0$, u regularnom lokalnom minimizatoru x^* postoje λ^* , μ^* takvi da:

$\nabla f(x^*) + \sum_i \lambda_i^* \nabla h_i(x^*) + \sum_j \mu_j^* \nabla g_j(x^*) = 0$	stacionarnost
$h_i(x^*) = 0, \quad g_j(x^*) \leq 0$	primarna dopustivost
$\mu_j^* \geq 0$	dualna dopustivost
$\mu_j^* g_j(x^*) = 0$	komplementarnost

Logika izvoda, u pet koraka:

1. **Dozvoljeni smjer** = smjer u kojem se smije napraviti mali korak; **smjer pada** = smjer u kojem cilj opada.
2. U optimumu ta dva skupa nemaju presjek: $D(x^*) \cap S(x^*) = \emptyset$.
3. Za **jednakost**, dozvoljeni smjerovi su okomiti na ∇h ; prazan presjek $\Rightarrow \nabla f$ kolinearan s ∇h .
4. Za **nejednakost**, dozvoljeni smjerovi su na jednoj strani od ∇g ; prazan presjek $\Rightarrow \nabla f = -\mu \nabla g$ uz $\mu \geq 0$. Neaktivna ograničenja daju $\mu = 0$ — odatle komplementarnost.
5. **Lagrangeova funkcija** $L = f + \sum \lambda_i h_i + \sum \mu_j g_j$ pakira sve to: uvjeti su derivacije od L .

Tri stvari koje se najlakše zaborave:

1. KKT su **nužni, ne dovoljni** uvjeti (osim kod konveksnih problema). Uvijek usporedite f u svim kandidatima.
2. $\mu_j \geq 0$ vrijedi samo za **nejednakosti**; λ_i smije biti bilo kojeg predznaka.

3. Vrijede samo u **regularnoj** točki (linearno nezavisni gradijenti jednakosti i *aktivnih* nejednakosti).

Terminologija (hrvatski $\leftrightarrow$ engleski):

Hrvatski	Engleski
dozvoljeni smjer	feasible direction
smjer pada	descent direction
aktivno / neaktivno ograničenje	active / inactive constraint
regularna točka	regular point (constraint qualification)
Lagrangeov množitelj	Lagrange multiplier
Lagrangeova funkcija	Lagrangian
uvjet komplementarnosti	complementary slackness
stacionarnost	stationarity
primarna / dualna dopustivost	primal / dual feasibility
reakcija veze	constraint reaction force

POGLAVLJE 4

Lagrangeova dualnost

Poglavlje je u izradi.

POGLAVLJE 5

Linearno i kvadratno programiranje

Poglavlje je u izradi.

POGLAVLJE 6

Konicno kvadratno i semidefinitno programiranje

Poglavlje je u izradi.

POGLAVLJE 7

Dinamicki sustavi, Ljapunov, disipativnost

Poglavlje je u izradi.

POGLAVLJE 8

Robusno optimiranje

Poglavlje je u izradi.